Activity01: Introducción al modelo lineal

Marco Russo

February, 2026

Contents

1 Información del Estudiante **2**

2 Ejercicios iniciales **3**

2.1 1. 3

2.1.1 (a) Dibujar la nube de puntos con la instrucción plot(). 3

2.1.2 (b) Añadir la recta de regresión con la instrucción abline(). 4

2.1.3 (c) Dibujar el gráfico de residuos vs. valores ajustados con la función plot() aplicada al objeto lm. 5

2.1.4 (d) Añadir al gráfico de dispersión del apartado (a) la curva de regresión parabólica. . . 5

2.2 Ejercicio del libro de Faraway 11

2.2.1 2. (Ejercicio 2 pág. 12) 14

2.2.2 3. (∗) (Ejercicio 3 pág. 12) 17

2.2.3 4. (∗) (Ejercicio 4 pág. 12) 21

2.2.4 5. (∗) (Ejercicio 5 pág. 12) 23

2.3 Ejercicios del libro de Carmona 28

2.3.1 1. (∗) (Ejercicio 1.1 del Capítulo 1 página 24 28

2.3.2 2. (∗∗) (Ejercicio 1.2 del Capítulo 1 página 24) 29

2.3.3 3. (Ejercicio 1.3 del Capítulo 1 página 24 29

2.3.3.1 a) 29

2.3.3.2 (b) 31

2.3.3.3 (c) 32

2.3.3.4 (d) 34

2.3.4 4. (Ejercicio 1.4 del Capítulo 1 página 24) 35

2.3.4.1 (a) Regresión simple con datos hombres 35

2.3.4.2 b. Regresión con logaritmos (hombres) 37

2.3.4.3 (c) Repetiremos con los datos para mujeres 39

1 Información del Estudiante

Nombre	Marco Russo
Email	mrussorb@uoc.edu
GitHub	
LinkedIn	https://www.linkedin.com/in/marcusrb/
Fecha	February 24, 2026

2 Ejercicios iniciales

2.1 1.

```
heartbpm <- c(47.53, 48.27, 49.51, 51.09, 52.57, 54.30,
54.25, 54.45, 57.95, 60.92, 61.91, 77.92,
82.07, 82.95, 83.94, 86.96, 90.42, 92.93, 100.05)

metabol <- c(6.15, 6.31, 6.43, 6.78, 6.86, 6.90, 7.37, 7.41,
8.24, 9.22, 8.16, 12.61, 15.26, 13.09, 14.59,
17.35, 18.57, 19.00, 20.70)

vulture <- data.frame(heartbpm, metabol)

rm(heartbpm, metabol)
attach(vulture)
```

2.1.1 (a) Dibujar la nube de puntos con la instrucción plot().

```
plot(heartbpm, metabol,
     main = "Relación entre ritmo cardíaco y metabolismo",
     xlab = "Ritmo cardíaco (ppm)",
     ylab = "Metabolismo",
     pch = 19, col = "blue")
```

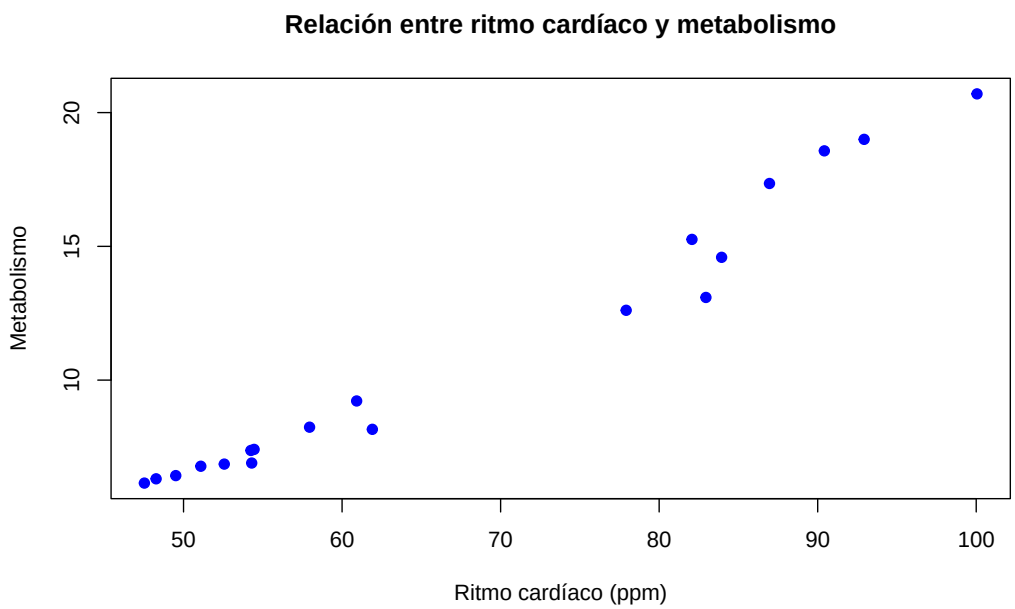


```
# Aplicamos el ajuste del modelo lineal
modelo_lineal <- lm(metabol ~ heartbpm)
summary(modelo_lineal)
```

```
##
```

```
## Call:
## lm(formula = metabol ~ heartbpm)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.20684 -0.25868  0.06332  0.65532  1.19349
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -7.7967     0.8481  -9.193 5.24e-08 ***
## heartbpm      0.2784     0.0121  23.002 3.01e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9144 on 17 degrees of freedom
## Multiple R-squared:  0.9689, Adjusted R-squared:  0.967
## F-statistic: 529.1 on 1 and 17 DF,  p-value: 3.01e-14
```

2.1.2 (b) Añadir la recta de regresión con la instrucción abline().

```r
plot(heartbpm, metabol,
     main = "Relación entre ritmo cardíaco y metabolismo",
     xlab = "Ritmo cardíaco (ppm)",
     ylab = "Metabolismo",
     pch = 19, col = "blue")
abline(modelo_lineal, col = "red", lwd = 2)
```

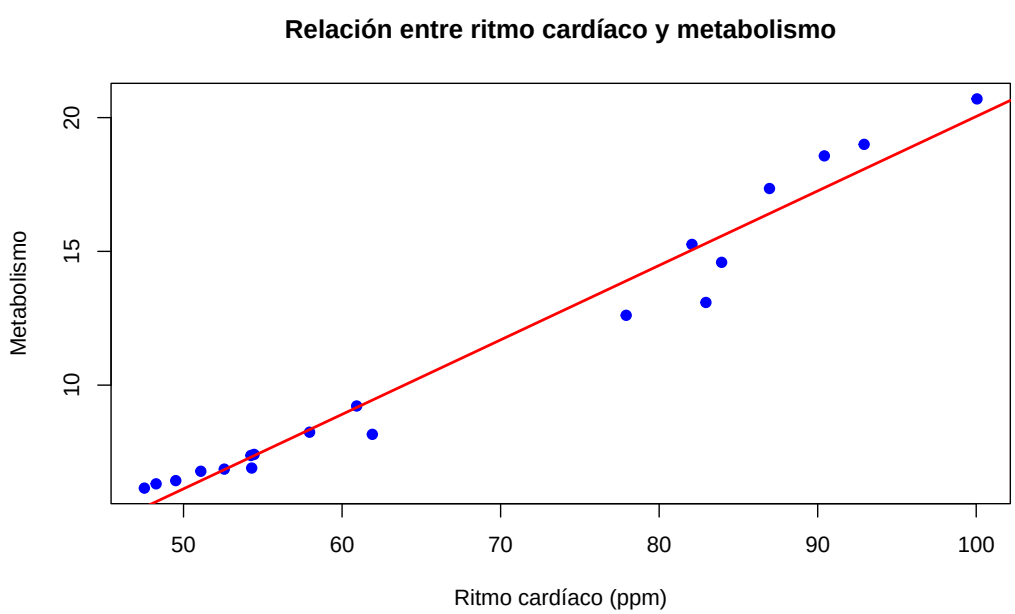

2.1.3 (c) Dibujar el gráfico de residuos vs. valores ajustados con la función plot() aplicada al objeto lm.

```
par(mfrow = c(1,1))
plot(modelo_lineal, which = 1,
     main = "Residuos vs Valores Ajustados (lineal)")
```

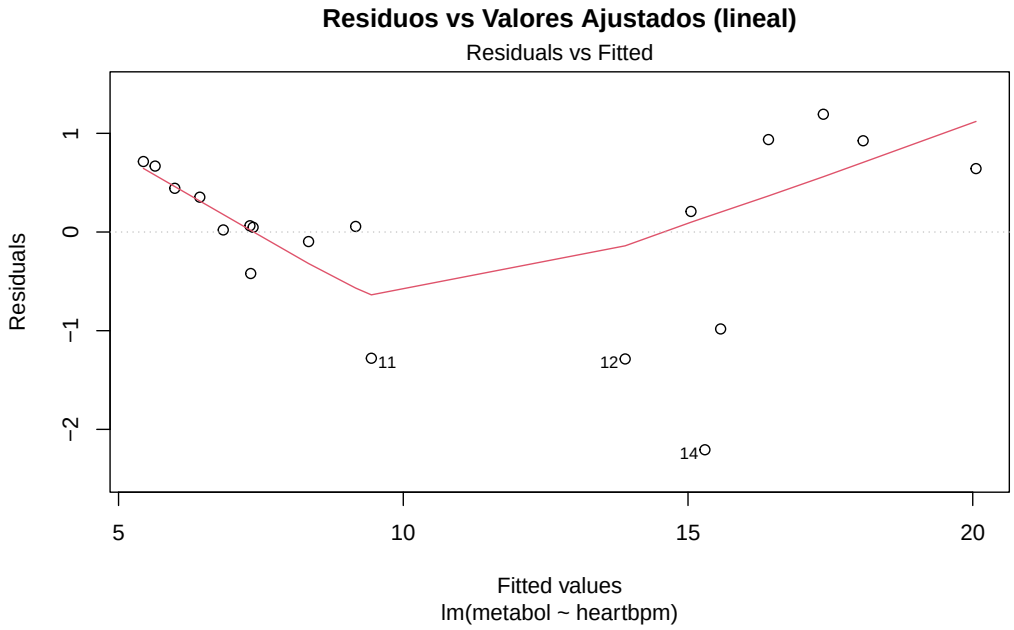

2.1.4 (d) Añadir al gráfico de dispersión del apartado (a) la curva de regresión parabólica.

Nota: Esto último se puede hacer con la instrucción lines() o con la instrucción curve(, add = TRUE).

```
# Creamos el ajuste del modelo cuadrático
modelo_cuad <- lm(metabol ~ heartbpm + I(heartbpm^2))
```

```
# Volveremos a dibujar con el punto b
plot(heartbpm, metabol,
     main = "Regresión lineal y parabólica",
     xlab = "Ritmo cardíaco (ppm)",
     ylab = "Metabolismo",
     pch = 19, col = "blue")
abline(modelo_lineal, col = "red", lwd = 2, lty = 2)
```

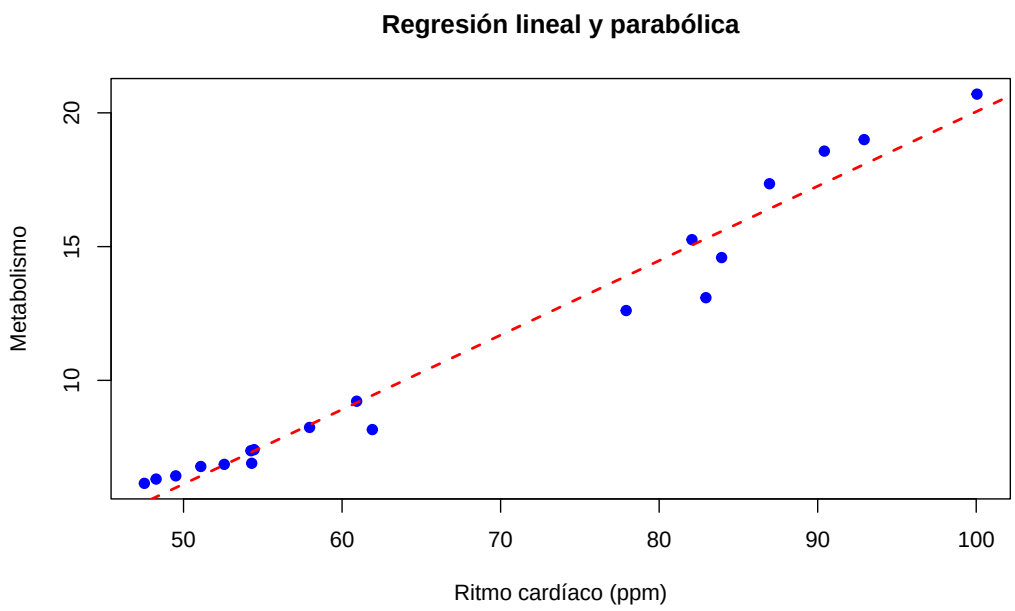


```r
# Añadiremos la curva parabólica usando lines() con puntos ordenados
# y finalmente ordenamos los valores de x para que la curva se dibuje correctamente
plot(heartbpm, metabol,
     main = "Regresión lineal y parabólica",
     xlab = "Ritmo cardíaco (ppm)",
     ylab = "Metabolismo",
     pch = 19, col = "blue")
abline(modelo_lineal, col = "red", lwd = 2, lty = 2)

x_ordenado <- sort(heartbpm)
y_parabola <- predict(modelo_cuad, newdata = data.frame(heartbpm = x_ordenado))
lines(x_ordenado, y_parabola, col = "green", lwd = 2)

# Aplicando la leyenda
legend("topleft",
       legend = c("Lineal", "Parabólica"),
       col = c("red", "green"),
       lwd = 2, lty = c(2,1))
```

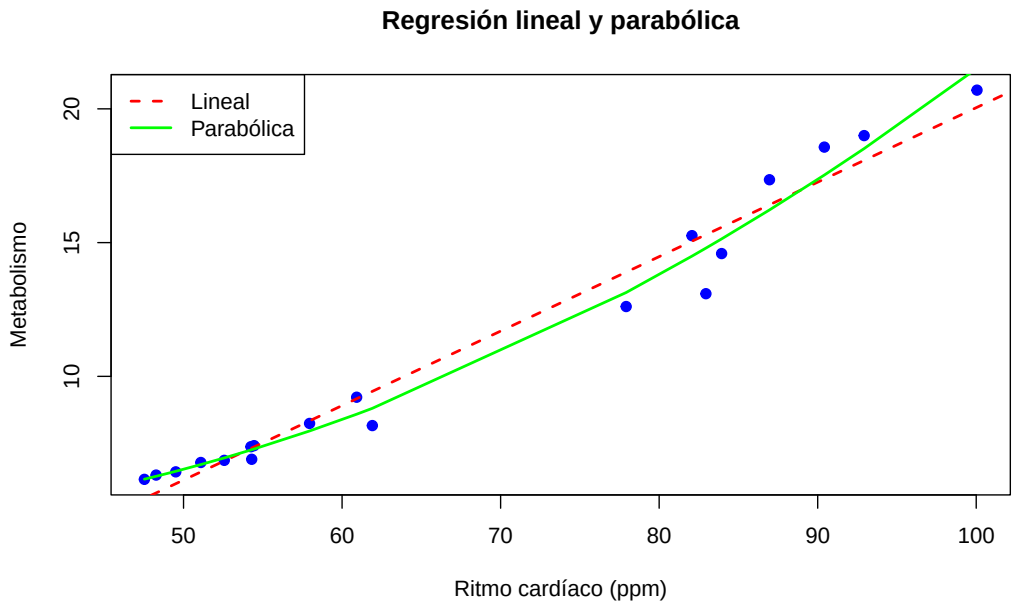

En caso de aplicar el último punto indicado: > Nota: Esto último se puede hacer con la instrucción lines() o con la instrucción curve(, add = TRUE).

```
plot(heartbpm, metabol,
     main = "Regresión lineal y parabólica",
     xlab = "Ritmo cardíaco (ppm)",
     ylab = "Metabolismo",
     pch = 19, col = "blue")

# Añadiremos la recta de regresión lineal
abline(modelo_lineal, col = "red", lwd = 2, lty = 2)

# Se aplica la curva parabólica con curve()
curve(predict(modelo_cuad, newdata = data.frame(heartbpm = x)),
      add = TRUE, col = "green", lwd = 2)

# Y finalmente añadimos la leyenda
legend("topleft",
       legend = c("Lineal", "Parabólica"),
       col = c("red", "green"),
       lwd = 2, lty = c(2, 1))
```

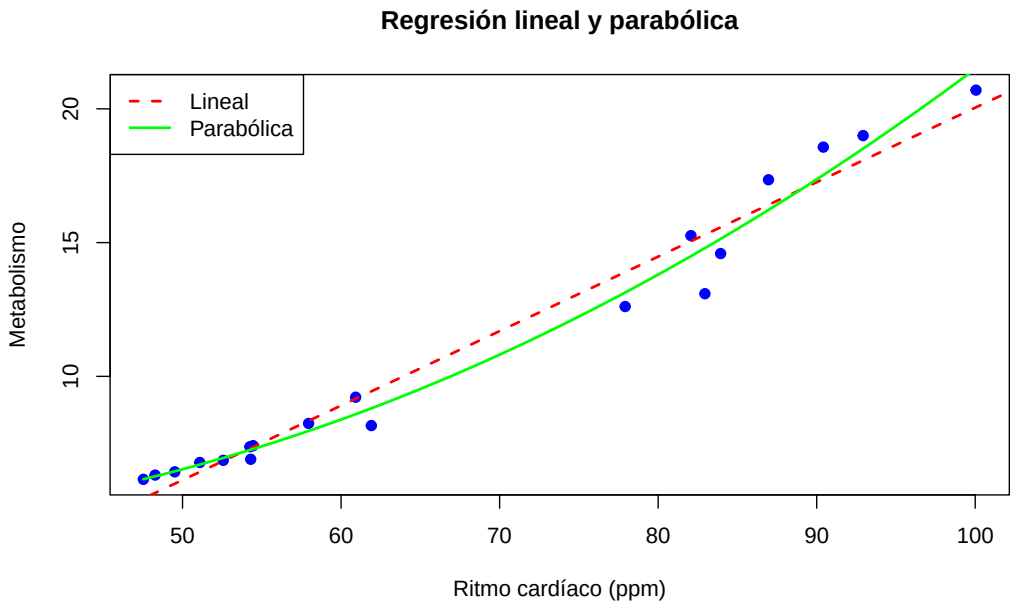

2.

Desde la tabla 1 Tensión Arterial Sistólica y Edad de 69 pacientes de Fisterra, se crea el dataframe correspondiente de los diferentes vectores - tension_sistolica - edad

```
# Numero pacientes
observaciones <- 1:69

# Vector: tension_sistolica
tension_sistolica <- c(
114,134,124,128,116,120,138,130,139,125,
132,130,140,144,110,148,124,136,150,120,
144,153,134,152,158,124,128,138,142,160,
135,138,142,145,149,
156,159,130,157,142,144,160,174,156,158,
174,150,154,165,164,168,140,170,185,154,
169,172,144,162,158,162,176,176,158,170,
172,184,175,180
)

# Vector: ddad
edad <- c(
17,18,19,19,20,21,21,22,23,25,
26,29,33,33,34,35,36,36,38,39,
39,40,41,41,41,42,42,42,44,44,
45,45,46,47,47,
47,47,48,48,50,50,51,51,52,53,
55,56,56,56,57,57,59,59,60,61,
61,62,63,64,65,65,65,66,67,67,
68,68,69,70
)
```

```r
# Creamos el dataframe
datos <- data.frame(
  Num = observaciones,
  Tension_Sistolica = tension_sistolica,
  Edad = edad
)

# View dataframe
datos
```

```
##    Num Tension_Sistolica Edad
## 1    1               114   17
## 2    2               134   18
## 3    3               124   19
## 4    4               128   19
## 5    5               116   20
## 6    6               120   21
## 7    7               138   21
## 8    8               130   22
## 9    9               139   23
## 10  10               125   25
## 11  11               132   26
## 12  12               130   29
## 13  13               140   33
## 14  14               144   33
## 15  15               110   34
## 16  16               148   35
## 17  17               124   36
## 18  18               136   36
## 19  19               150   38
## 20  20               120   39
## 21  21               144   39
## 22  22               153   40
## 23  23               134   41
## 24  24               152   41
## 25  25               158   41
## 26  26               124   42
## 27  27               128   42
## 28  28               138   42
## 29  29               142   44
## 30  30               160   44
## 31  31               135   45
## 32  32               138   45
## 33  33               142   46
## 34  34               145   47
## 35  35               149   47
## 36  36               156   47
## 37  37               159   47
## 38  38               130   48
## 39  39               157   48
## 40  40               142   50
## 41  41               144   50
## 42  42               160   51
## 43  43               174   51
```

```
## 44  44                156   52
## 45  45                158   53
## 46  46                174   55
## 47  47                150   56
## 48  48                154   56
## 49  49                165   56
## 50  50                164   57
## 51  51                168   57
## 52  52                140   59
## 53  53                170   59
## 54  54                185   60
## 55  55                154   61
## 56  56                169   61
## 57  57                172   62
## 58  58                144   63
## 59  59                162   64
## 60  60                158   65
## 61  61                162   65
## 62  62                176   65
## 63  63                176   66
## 64  64                158   67
## 65  65                170   67
## 66  66                172   68
## 67  67                184   68
## 68  68                175   69
## 69  69                180   70
```

```r
# Ajustaremos el modelo de regresión lineal obteniendo los coeficientes

# Ajustando el modelo
modelo <- lm(Tension_Sistolica ~ Edad, data=datos)

# Coeficientes
coef(modelo)
```

```
## (Intercept)        Edad
## 103.3526585   0.9835585
```

Tenemos que la tensión sistolica es igual a 103.35 + 0.98 por la Edad. Es decir que cada año adicional a la Edad, la tensión sistólica aumenta de un 0.98 mmHg

---

2.2 Ejercicio del libro de Faraway

1. (Ejercicio 1 cap. 1 pág. 12) *The dataset teengamb concerns a study of teenage gambling in Britain. Make a numerical and graphical summary of the data, commenting on any features that you find interesting. Limit the output you present to a quantity that a busy reader would find sufficient to get a basic understanding of the data.*

```r
# Cargamos los datos teengamb
data(teengamb)

# Observamos el encabezado
head(teengamb)
```

```
##   sex status income verbal gamble
## 1   1     51   2.00      8    0.0
## 2   1     28   2.50      8    0.0
## 3   1     37   2.00      6    0.0
## 4   1     28   7.00      4    7.3
## 5   1     65   2.00      8   19.6
## 6   1     61   3.47      6    0.1
```

```r
# Extraeremos un resumen estadístico
summary(teengamb)
```

```
##       sex             status          income           verbal
##  Min.   :0.0000   Min.   :18.00   Min.   : 0.600   Min.   : 1.00
##  1st Qu.:0.0000   1st Qu.:28.00   1st Qu.: 2.000   1st Qu.: 6.00
##  Median :0.0000   Median :43.00   Median : 3.250   Median : 7.00
##  Mean   :0.4043   Mean   :45.23   Mean   : 4.642   Mean   : 6.66
##  3rd Qu.:1.0000   3rd Qu.:61.50   3rd Qu.: 6.210   3rd Qu.: 8.00
##  Max.   :1.0000   Max.   :75.00   Max.   :15.000   Max.   :10.00
##      gamble
##  Min.   :  0.0
##  1st Qu.:  1.1
##  Median :  6.0
##  Mean   : 19.3
##  3rd Qu.: 19.4
##  Max.   :156.0
```

```r
# Observamos la estructura
str(teengamb)
```

```
## 'data.frame':    47 obs. of  5 variables:
##  $ sex   : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ status: int  51 28 37 28 65 61 28 27 43 18 ...
##  $ income: num  2 2.5 2 7 2 3.47 5.5 6.42 2 6 ...
##  $ verbal: int  8 8 6 4 8 6 7 5 6 7 ...
##  $ gamble: num  0 0 0 7.3 19.6 0.1 1.45 6.6 1.7 0.1 ...
```

Las variables obtenidas son extraidos desde: https://www.rdocumentation.org/packages/faraway/versions/1.0.9/topics/teengamb

Variables:

- sex: 0 = masculino, 1 = femenino
- status: estatus socioeconómico en una escala de 0-100
- income: ingresos semanales en libras esterlinas
- verbal: puntuación en test verbal (0-20)
- gamble: gasto anual en juego en libras

```r
# Aplicamos un gráfico de distribución de la variable target

hist(teengamb$gamble, main = "Histograma de gasto en juego", xlab = "Gamble (£)")
```

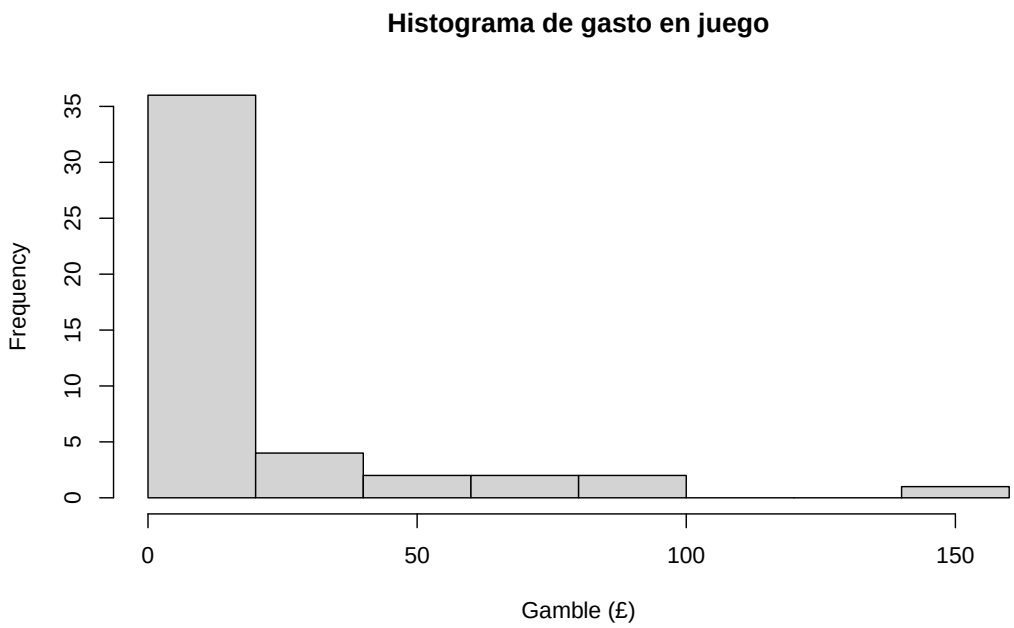


```r
boxplot(gamble ~ sex, data = teengamb, main = "Gasto en juego por sexo")
```

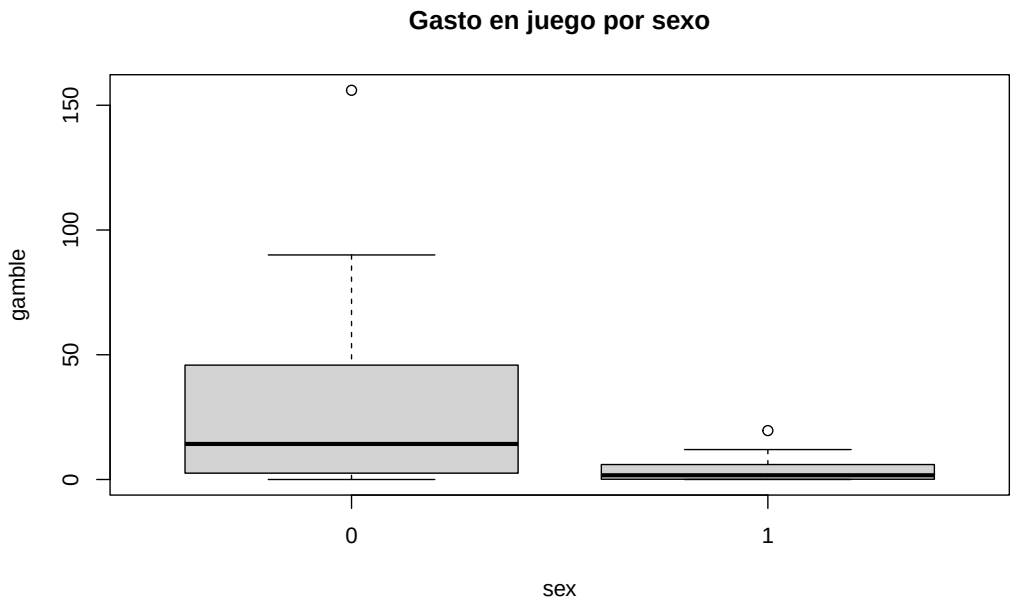


```
# Obtenemos las relaciones entre variables
pairs(teengamb[, -1], col = teengamb$sex + 1, main = "Matriz de dispersión")
```

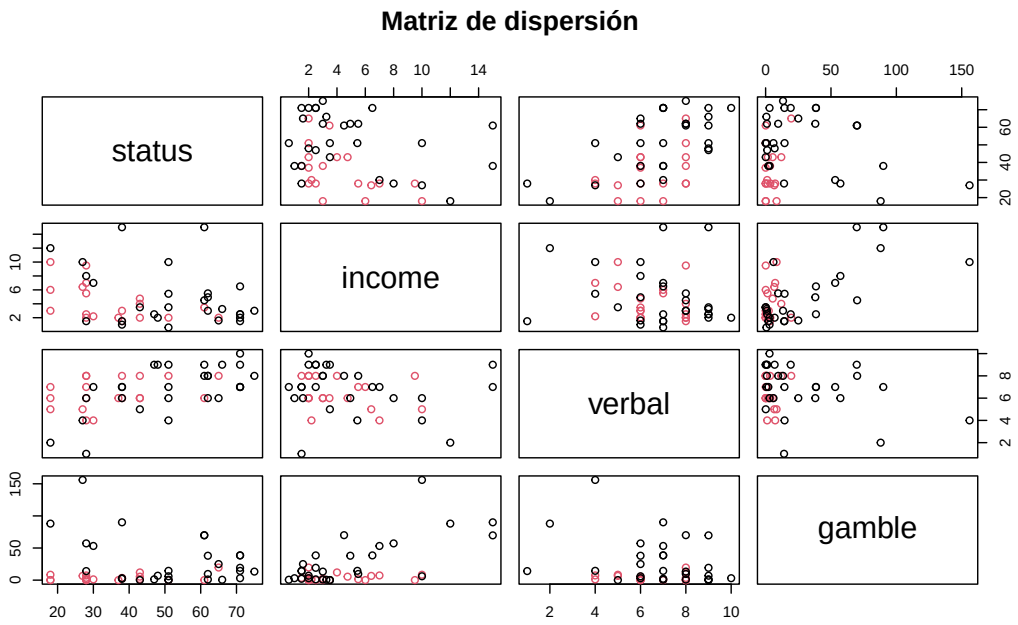

La variable gamble presenta una fuerte asimetría (media 19.3, mediana 6) con valores extremos (máximo 156). Se podría aplicar una transformación logarítmica en fase de modelado.

El resto de observaciones y comentarios: - Hay una diferencia entre género: los chicos (sexo=0) gastan más en juego que las chicas (sexo=1). - La correlación entre income y gamble parece positiva, aunque con outliers. - verbal muestra una relación negativa con el juego (a mayor puntuación verbal, menor gasto).

2.2.1 2. (Ejercicio 2 pág. 12)

The dataset uswages is drawn as a sample from the Current Population Survey in 1988. Make a numerical and graphical summary of the data as in the previous question.

```r
# Cargamos los datos uswages
data(uswages)

# Observamos los datos
head(uswages)
```

```
##         wage educ exper race smsa ne mw so we pt
## 6085  771.60   18    18    0    1  1  0  0  0  0
## 23701 617.28   15    20    0    1  0  0  0  1  0
## 16208 957.83   16     9    0    1  0  0  1  0  0
## 2720  617.28   12    24    0    1  1  0  0  0  0
## 9723  902.18   14    12    0    1  0  1  0  0  0
## 22239 299.15   12    33    0    1  0  0  0  1  0
```

```r
# Extraeremos el resumen estadístico
summary(uswages)
```

```
##       wage              educ           exper            race
##  Min.   :  50.39   Min.   : 0.00   Min.   :-2.00   Min.   :0.000
##  1st Qu.: 308.64   1st Qu.:12.00   1st Qu.: 8.00   1st Qu.:0.000
##  Median : 522.32   Median :12.00   Median :15.00   Median :0.000
##  Mean   : 608.12   Mean   :13.11   Mean   :18.41   Mean   :0.078
##  3rd Qu.: 783.48   3rd Qu.:16.00   3rd Qu.:27.00   3rd Qu.:0.000
##  Max.   :7716.05   Max.   :18.00   Max.   :59.00   Max.   :1.000
##       smsa             ne              mw               so
##  Min.   :0.000   Min.   :0.000   Min.   :0.0000   Min.   :0.0000
##  1st Qu.:1.000   1st Qu.:0.000   1st Qu.:0.0000   1st Qu.:0.0000
##  Median :1.000   Median :0.000   Median :0.0000   Median :0.0000
##  Mean   :0.756   Mean   :0.229   Mean   :0.2485   Mean   :0.3125
##  3rd Qu.:1.000   3rd Qu.:0.000   3rd Qu.:0.0000   3rd Qu.:1.0000
##  Max.   :1.000   Max.   :1.000   Max.   :1.0000   Max.   :1.0000
##        we             pt
##  Min.   :0.00   Min.   :0.0000
##  1st Qu.:0.00   1st Qu.:0.0000
##  Median :0.00   Median :0.0000
##  Mean   :0.21   Mean   :0.0925
##  3rd Qu.:0.00   3rd Qu.:0.0000
##  Max.   :1.00   Max.   :1.0000
```

Las variables obtenidas desde uswages son: https://www.rdocumentation.org/packages/faraway/versions/1.0.8/topics/uswages

- wage: Real weekly wages in dollars (deflated by personal consumption expenditures - 1992 base year)
- educ :Years of education
- exper: Years of experience
- race: 1 if Black, 0 if White (other races not in sample)
- smsa: 1 if living in Standard Metropolitan Statistical Area, 0 if not

- ne: 1 if living in the North East
- mw: 1 if living in the Midwest
- we: 1 if living in the West
- so: 1 if living in the South
- pt: 1 if working part time, 0 if not

```r
# Distribución del salario
hist(uswages$wage, breaks = 30, main = "Salario por hora", xlab = "wage ($)")
```

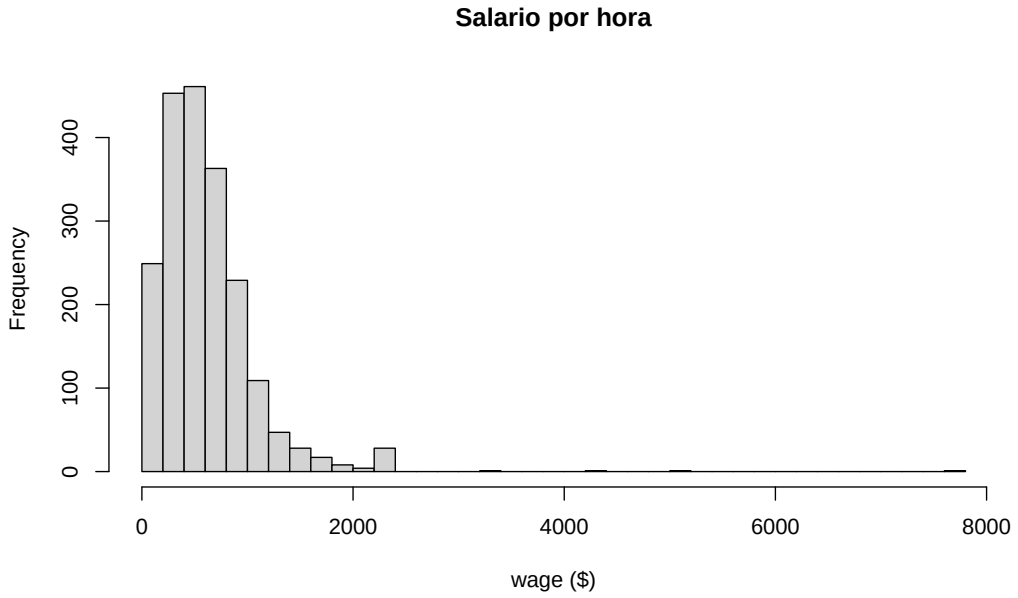


```r
# Mostramos el salario según raza y área metropolitana
boxplot(wage ~ race, data = uswages, main = "Salario por raza")
```

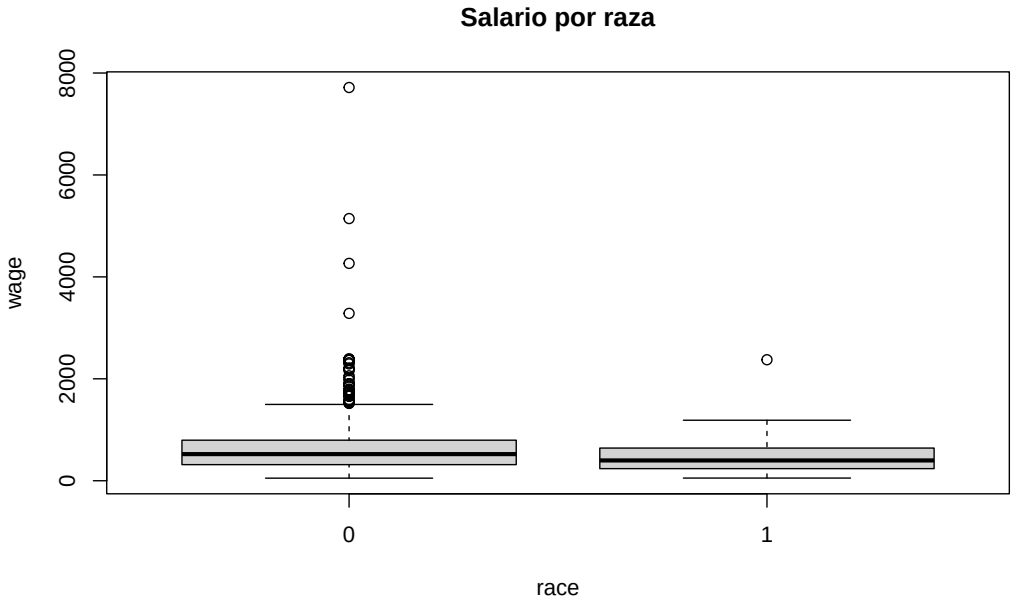

```r
boxplot(wage ~ smsa, data = uswages, main = "Salario según área metropolitana")
```

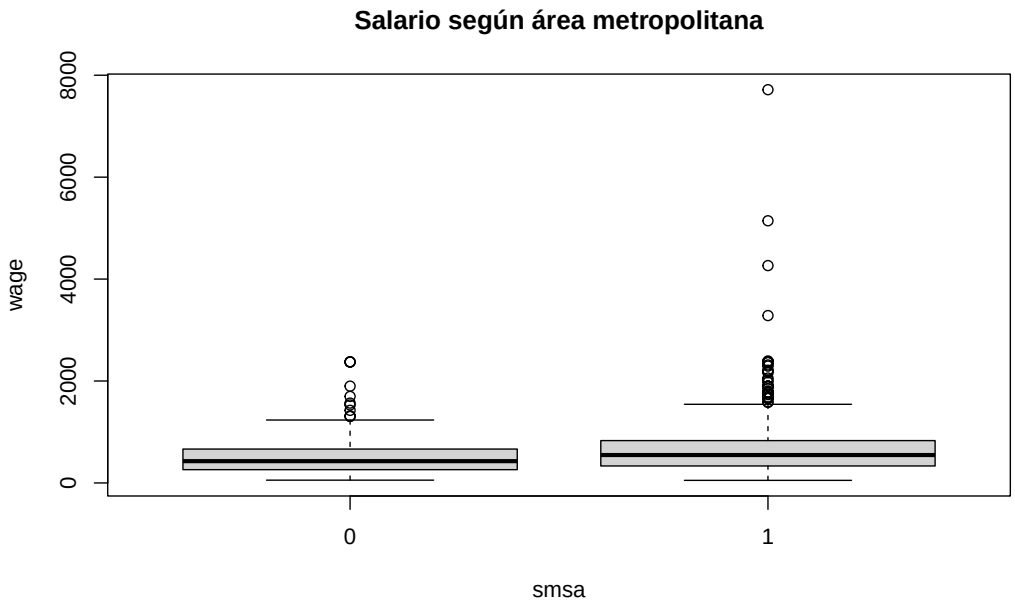


```r
# Representación de la relación con educación y experiencia
plot(wage ~ educ, data = uswages, pch = 16, cex = 0.5)
```

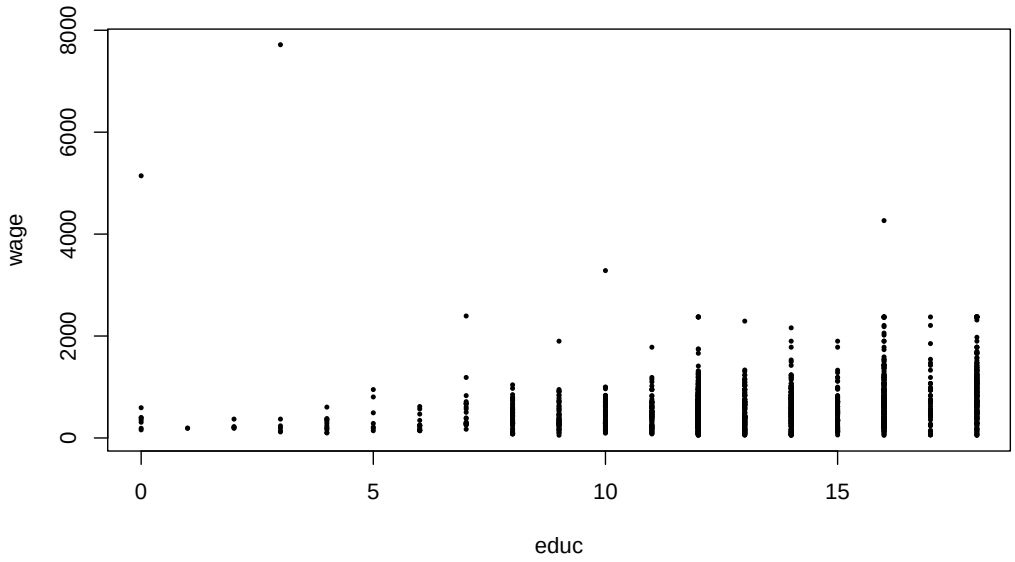


```r
plot(wage ~ exper, data = uswages, pch = 16, cex = 0.5)
```

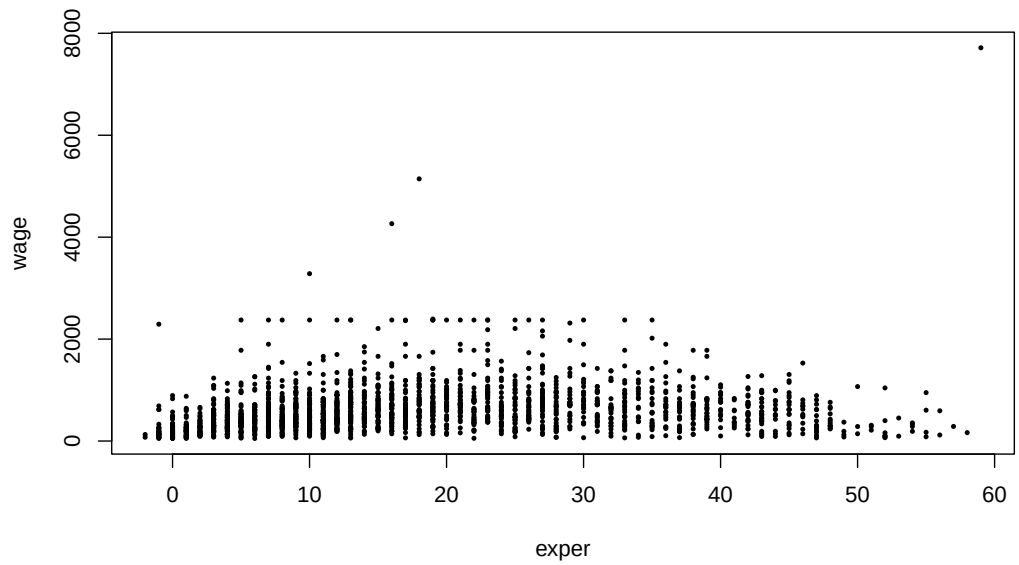

Las conclusiones que podemos extraer:

- El salario medio es 608.12 USD/h, con una cola derecha (valores altos hasta 7716 $).
- La mayoría de individuos son de raza blanca (1), y viven en áreas metropolitanas (smsa=1).
- Se observa una relación positiva entre salario y educación, aunque con mucha variabilidad.
- La experiencia también muestra una tendencia positiva, pero con una posible forma no lineal (meseta después de cierto tiempo).
- Diferencias salariales por raza: los blancos tienen salarios ligeramente superiores a los negros (2), aunque con solapamiento.

2.2.2 3. (∗) (Ejercicio 3 pág. 12)

The dataset prostate is from a study on 97 men with prostate cancer who were due to receive a radical prostatectomy. Make a numerical and graphical summary of the data as in the first question.

```r
# Cargamos los datos
data(prostate)

# Mostramos el encabezado
head(prostate)
```

```
##       lcavol lweight age      lbph svi      lcp gleason pgg45     lpsa
## 1 -0.5798185  2.7695  50 -1.386294   0 -1.38629       6     0 -0.43078
## 2 -0.9942523  3.3196  58 -1.386294   0 -1.38629       6     0 -0.16252
## 3 -0.5108256  2.6912  74 -1.386294   0 -1.38629       7    20 -0.16252
## 4 -1.2039728  3.2828  58 -1.386294   0 -1.38629       6     0 -0.16252
## 5  0.7514161  3.4324  62 -1.386294   0 -1.38629       6     0  0.37156
## 6 -1.0498221  3.2288  50 -1.386294   0 -1.38629       6     0  0.76547
```

```r
# Extraeremos los valores estadísticos
summary(prostate)
```

```
##      lcavol           lweight           age             lbph
##  Min.   :-1.3471   Min.   :2.375   Min.   :41.00   Min.   :-1.3863
##  1st Qu.: 0.5128   1st Qu.:3.376   1st Qu.:60.00   1st Qu.:-1.3863
##  Median : 1.4469   Median :3.623   Median :65.00   Median : 0.3001
##  Mean   : 1.3500   Mean   :3.653   Mean   :63.87   Mean   : 0.1004
##  3rd Qu.: 2.1270   3rd Qu.:3.878   3rd Qu.:68.00   3rd Qu.: 1.5581
##  Max.   : 3.8210   Max.   :6.108   Max.   :79.00   Max.   : 2.3263
##       svi              lcp             gleason          pgg45
##  Min.   :0.0000   Min.   :-1.3863   Min.   :6.000   Min.   :  0.00
##  1st Qu.:0.0000   1st Qu.:-1.3863   1st Qu.:6.000   1st Qu.:  0.00
##  Median :0.0000   Median :-0.7985   Median :7.000   Median : 15.00
##  Mean   :0.2165   Mean   :-0.1794   Mean   :6.753   Mean   : 24.38
##  3rd Qu.:0.0000   3rd Qu.: 1.1786   3rd Qu.:7.000   3rd Qu.: 40.00
##  Max.   :1.0000   Max.   : 2.9042   Max.   :9.000   Max.   :100.00
##       lpsa
##  Min.   :-0.4308
##  1st Qu.: 1.7317
##  Median : 2.5915
##  Mean   : 2.4784
##  3rd Qu.: 3.0564
##  Max.   : 5.5829
```

Las variables obtenidas son: https://www.rdocumentation.org/packages/faraway/versions/1.0.8/topics/prostate

lcavol

`log(cancer volume)`

lweight

`log(prostate weight)`

age

`age`

lbph

`log(benign prostatic hyperplasia amount)`

svi

`seminal vesicle invasion`

lcp

`log(capsular penetration)`

gleason

`Gleason score`

pgg45

`percentage Gleason scores 4 or 5`

lpsa

`log(prostate specific antigen)`

```
# Obtenemos la matriz de correlación
pairs(prostate[, c("lcavol", "lweight", "age", "lpsa")], main = "Relaciones principales")
```

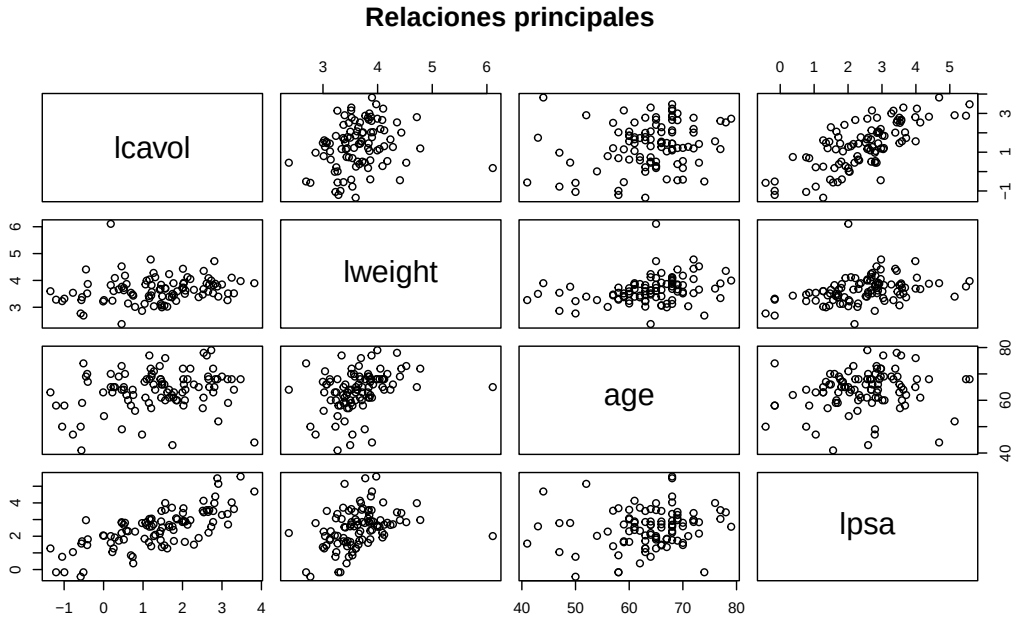


```
# Distribución de la respuesta
hist(prostate$lpsa, main = "log(PSA)")
```

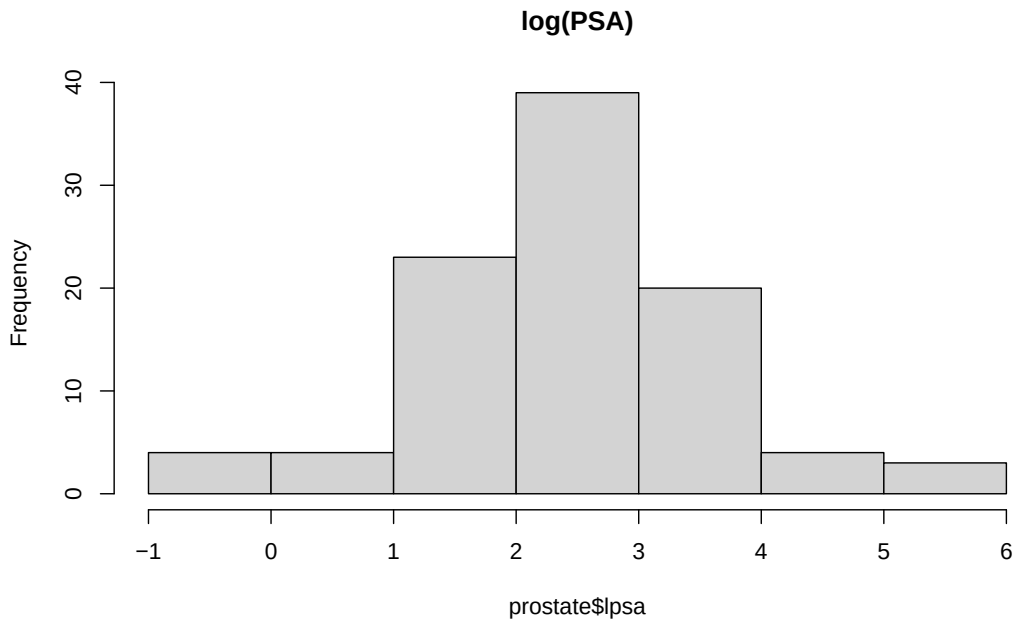


```
# Boxplot de lpsa según svi (invasión)
boxplot(lpsa ~ svi, data = prostate, main = "PSA según invasión")
```

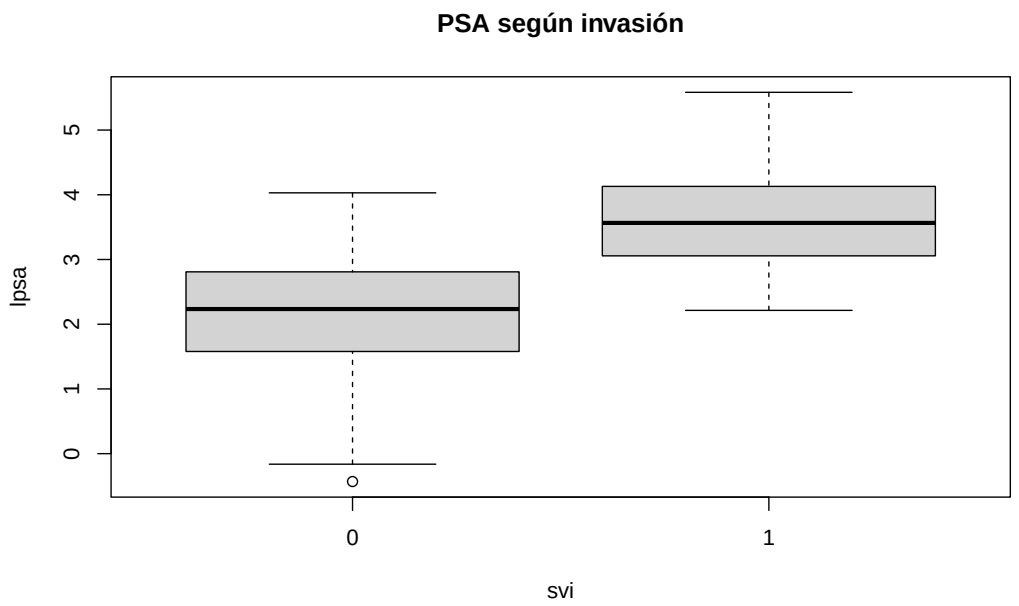

Aquí unas cuantas observaciones obtenidas:

- La variable respuesta lpsa (log del PSA) tiene una distribución aproximadamente normal.
- Existe una correlación positiva fuerte entre lcavol (log volumen) y lpsa, también con lcp.
- La invasión de vesículas seminales (svi) es un factor importante: los pacientes con invasión (svi=1) tienen valores de PSA más altos.
- gleason y pgg45 miden la agresividad del tumor; se espera que a mayor puntuación, mayor PSA.

2.2.3 4. (∗) (Ejercicio 4 pág. 12)

The dataset sat comes from a study entitled "Getting What You Pay For: The Debate Over Equity in Public School Expenditures." Make a numerical and graphical summary of the data as in the first question.

```r
# Cargamos los datos
data(sat)

# Una vista previa
head(sat)
```

```
##            expend ratio salary takers verbal math total
## Alabama     4.405  17.2 31.144      8    491  538  1029
## Alaska      8.963  17.6 47.951     47    445  489   934
## Arizona     4.778  19.3 32.175     27    448  496   944
## Arkansas    4.459  17.1 28.934      6    482  523  1005
## California  4.992  24.0 41.078     45    417  485   902
## Colorado    5.443  18.4 34.571     29    462  518   980
```

```r
# Mostramos los valores estadísticos
summary(sat)
```

```
##      expend          ratio           salary          takers
##  Min.   :3.656   Min.   :13.80   Min.   :25.99   Min.   : 4.00
##  1st Qu.:4.882   1st Qu.:15.22   1st Qu.:30.98   1st Qu.: 9.00
##  Median :5.768   Median :16.60   Median :33.29   Median :28.00
##  Mean   :5.905   Mean   :16.86   Mean   :34.83   Mean   :35.24
##  3rd Qu.:6.434   3rd Qu.:17.57   3rd Qu.:38.55   3rd Qu.:63.00
##  Max.   :9.774   Max.   :24.30   Max.   :50.05   Max.   :81.00
##      verbal           math           total
##  Min.   :401.0   Min.   :443.0   Min.   : 844.0
##  1st Qu.:427.2   1st Qu.:474.8   1st Qu.: 897.2
##  Median :448.0   Median :497.5   Median : 945.5
##  Mean   :457.1   Mean   :508.8   Mean   : 965.9
##  3rd Qu.:490.2   3rd Qu.:539.5   3rd Qu.:1032.0
##  Max.   :516.0   Max.   :592.0   Max.   :1107.0
```

Las variables obtenidas son: https://www.rdocumentation.org/packages/faraway/versions/1.0.8/topics/sat

expend

```
Current expenditure per pupil in average daily attendance in public elementary and secondary schools, 19
```

ratio

```
Average pupil/teacher ratio in public elementary and secondary schools, Fall 1994
```

salary

```
Estimated average annual salary of teachers in public elementary and secondary schools, 1994-95 (in thou
```

takers

```
Percentage of all eligible students taking the SAT, 1994-95
```

verbal

```
Average verbal SAT score, 1994-95
```

math

```
Average math SAT score, 1994-95
```

total

```
Average total score on the SAT, 1994-95
```

```r
# Graficamos la relación entre gasto y puntuaciones
plot(total ~ expend, data = sat, main = "SAT total vs. gasto por alumno")

# Añadimos las etiquetas de estados (si se conocen)
text(sat$expend, sat$total, labels = rownames(sat), cex = 0.6, pos = 4)
```

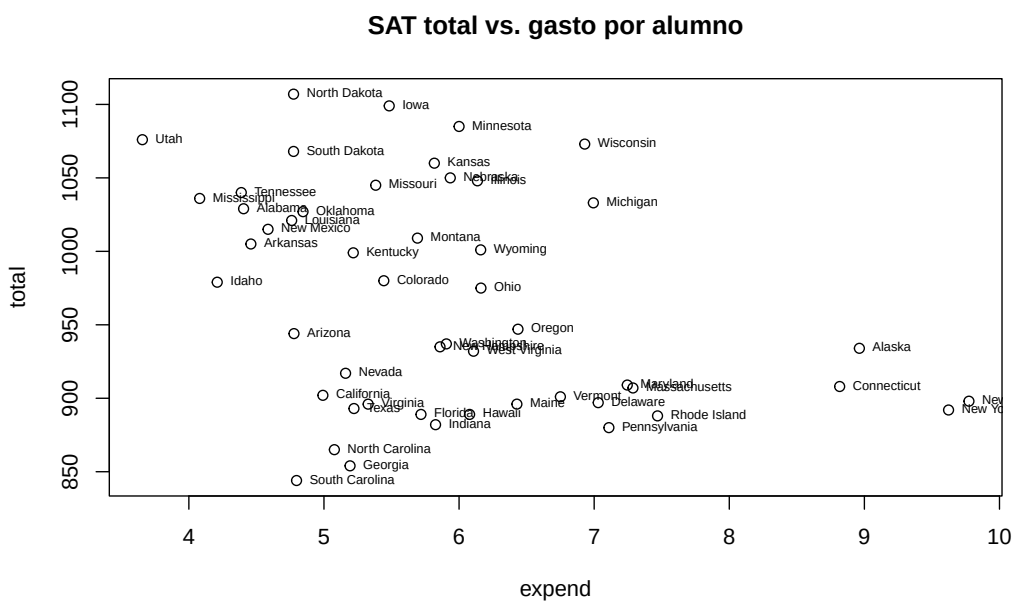


```r
# Graficamos la importancia del porcentaje de alumnos que toman el SAT
plot(total ~ takers, data = sat, main = "SAT total vs. % de participación")
```

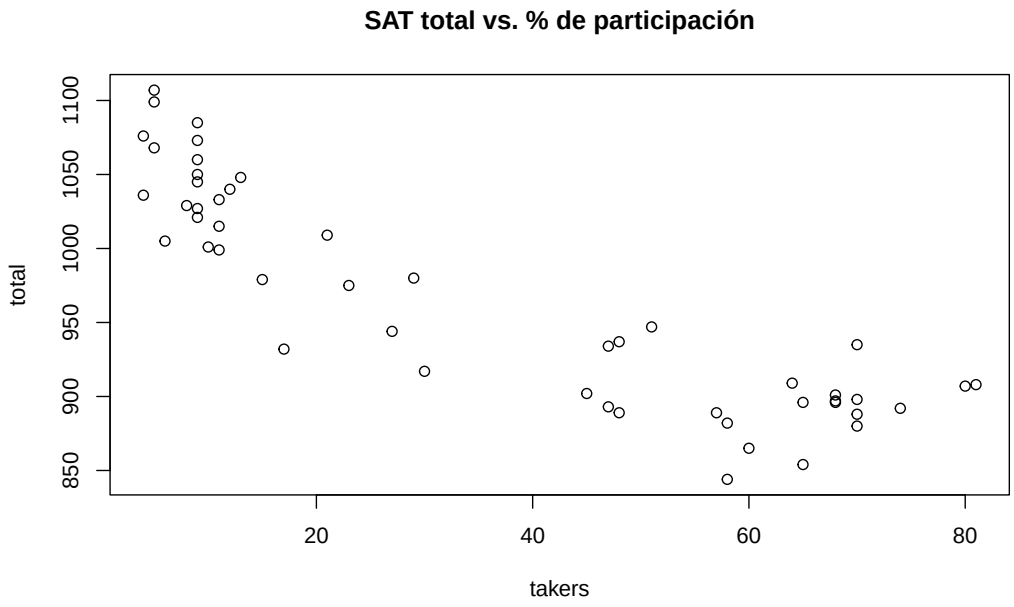

Alguna de las observaciones :

- La relación entre expend (gasto) y total SAT es débil o incluso ligeramente negativa. Esto se debe a que estados con mayor porcentaje de estudiantes que toman el SAT (como los de la costa este) tienden a tener puntuaciones más bajas, porque incluyen a estudiantes menos selectivos.
- El gráfico de total vs. takers muestra una fuerte correlación negativa: a mayor participación, menor puntuación media.
- Es un ejemplo clásico de variable de confusión: el gasto no está directamente relacionado con el rendimiento si no se controla por la tasa de participación.
- Algunos estados tienen valores extremos (ej. bajo gasto y alta puntuación, como Utah).

2.2.4 5. (∗) (Ejercicio 5 pág. 12)

The dataset divusa contains data on divorces in the United States from 1920 to 1996. Make a numerical and graphical summary of the data as in the first question.

```r
# Cargamos los datos
data(divusa)

# Obtenemos un extracto de los datos
head(divusa)
```

```
##   year divorce unemployed femlab marriage birth military
## 1 1920     8.0        5.2  22.70     92.0 117.9   3.2247
## 2 1921     7.2       11.7  22.79     83.0 119.8   3.5614
## 3 1922     6.6        6.7  22.88     79.7 111.2   2.4553
## 4 1923     7.1        2.4  22.97     85.2 110.5   2.2065
## 5 1924     7.2        5.0  23.06     80.3 110.9   2.2889
## 6 1925     7.2        3.2  23.15     79.2 106.6   2.1735
```

```r
# Extraemos los valores estadísticos
summary(divusa)
```

```
##       year         divorce        unemployed         femlab
##  Min.   :1920   Min.   : 6.10   Min.   : 1.200   Min.   :22.70
##  1st Qu.:1939   1st Qu.: 8.70   1st Qu.: 4.200   1st Qu.:27.47
##  Median :1958   Median :10.60   Median : 5.600   Median :37.10
##  Mean   :1958   Mean   :13.27   Mean   : 7.173   Mean   :38.58
##  3rd Qu.:1977   3rd Qu.:20.30   3rd Qu.: 7.500   3rd Qu.:47.80
##  Max.   :1996   Max.   :22.80   Max.   :24.900   Max.   :59.30
##     marriage          birth           military
##  Min.   : 49.70   Min.   : 65.30   Min.   : 1.940
##  1st Qu.: 61.90   1st Qu.: 68.90   1st Qu.: 3.469
##  Median : 74.10   Median : 85.90   Median : 9.102
##  Mean   : 72.97   Mean   : 88.89   Mean   :12.365
##  3rd Qu.: 80.00   3rd Qu.:107.30   3rd Qu.:14.266
##  Max.   :118.10   Max.   :122.90   Max.   :86.641
```

Las variables obtenidas son: https://www.rdocumentation.org/packages/faraway/versions/1.0.8/topics/divusa

A data frame with 77 observations on the following 7 variables.

year

```
the year from 1920-1996
```

divorce

```
divorce per 1000 women aged 15 or more
```

unemployed

```
unemployment rate
```

femlab

```
percent female participation in labor force aged 16+
```

marriage

```
marriages per 1000 unmarried women aged 16+
```

birth

```
births per 1000 women aged 15-44
```

military

```
military personnel per 1000 population
```

```r
# Graficamos la evolución temporal de la tasa de divorcios
plot(divorce ~ year, data = divusa, type = "l", main = "Tasa de divorcios en EE.UU.", ylab = "Divorcios

# Se añaden otras variables
lines(unemployed ~ year, data = divusa, col = 2)
lines(femlab ~ year, data = divusa, col = 3)
legend("topleft", legend = c("divorce", "unemployed", "femlab"), col = 1:3, lty = 1)
```

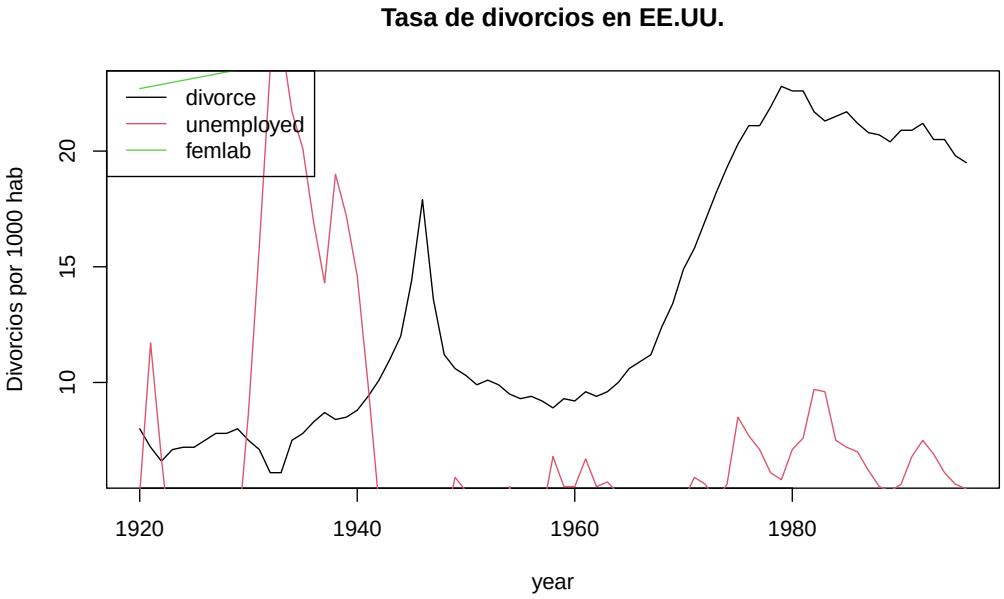


```r
# Obtenemos la matriz de correlación
pairs(divusa[, -1], main = "Relaciones entre indicadores")
```

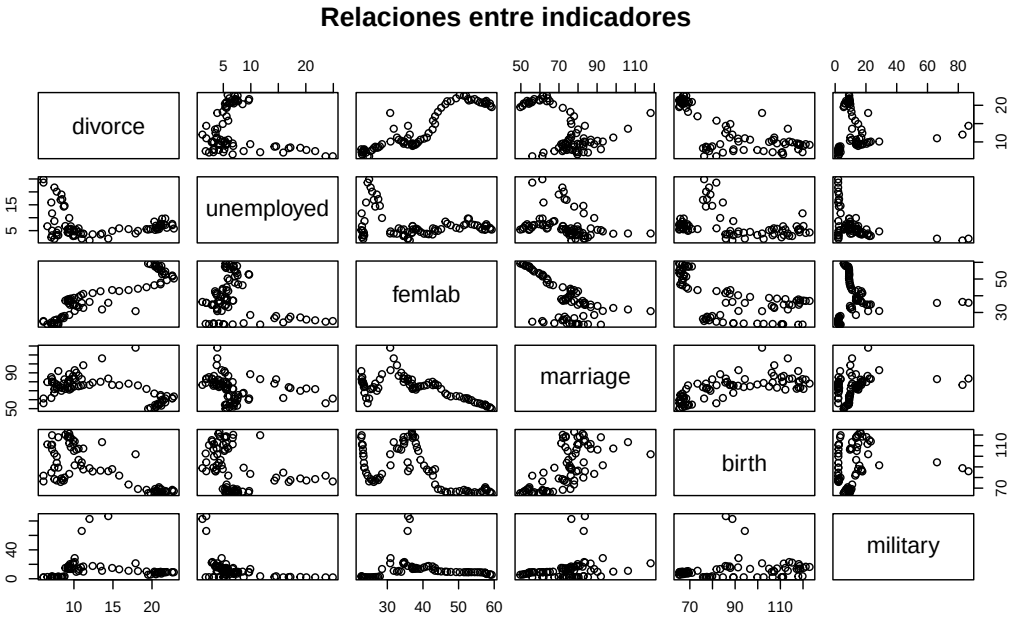

```r
# 1. Participación femenina en la fuerza laboral (femlab)
plot(femlab ~ year, data = divusa, type = "l", col = "blue", lwd = 2,
     main = "Participación femenina en la fuerza laboral",
     xlab = "Año", ylab = "% mujeres en fuerza laboral")
```

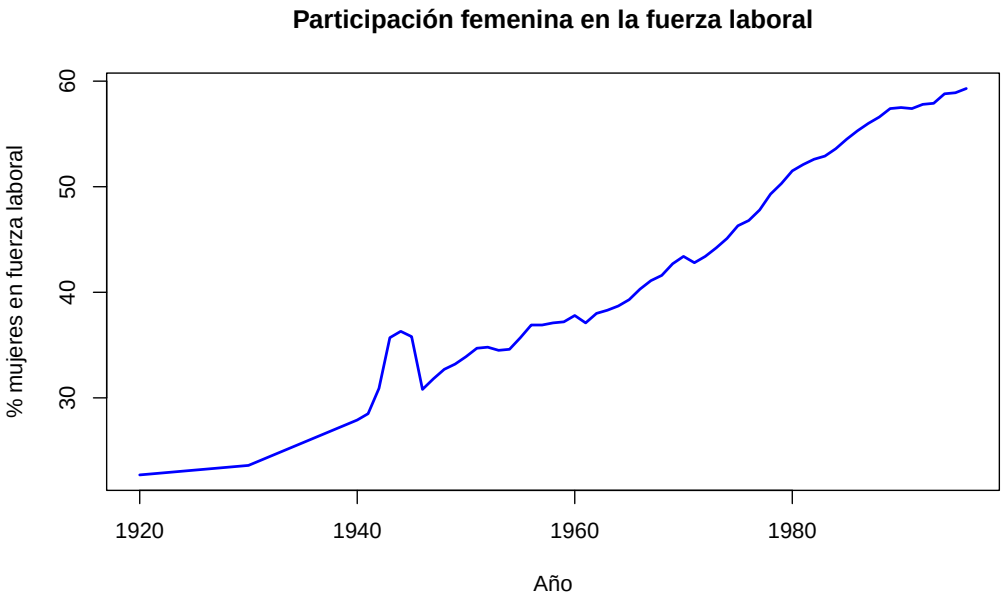


```r
# 2. Desempleo y divorcios (escalas diferentes, usar dos ejes)
plot(divorce ~ year, data = divusa, type = "l", col = "red", lwd = 2,
     main = "Desempleo y divorcios", xlab = "Año", ylab = "Tasa de divorcios (por 1000 hab)")
par(new = TRUE)
plot(unemployed ~ year, data = divusa, type = "l", col = "darkgreen", lwd = 2,
     axes = FALSE, xlab = "", ylab = "")
axis(side = 4, col = "darkgreen")
mtext("Tasa de desempleo (%)", side = 4, line = 2, col = "darkgreen")
legend("topleft", legend = c("Divorcios", "Desempleo"),
       col = c("red", "darkgreen"), lty = 1, lwd = 2)
```

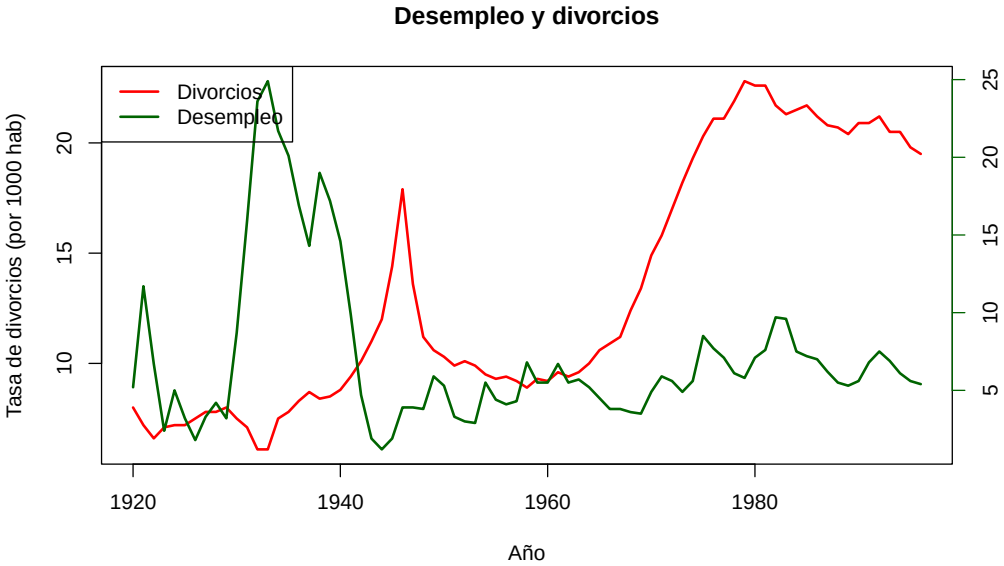

```r
# 3. Matrimonios y natalidad
plot(marriage ~ year, data = divusa, type = "l", col = "purple", lwd = 2,
     main = "Matrimonios y natalidad", xlab = "Año", ylab = "Tasa de matrimonios (por 1000 hab)")
par(new = TRUE)
plot(birth ~ year, data = divusa, type = "l", col = "orange", lwd = 2,
     axes = FALSE, xlab = "", ylab = "")
axis(side = 4, col = "orange")
mtext("Tasa de natalidad (por 1000 hab)", side = 4, line = 2, col = "orange")
legend("topright", legend = c("Matrimonios", "Natalidad"),
       col = c("purple", "orange"), lty = 1, lwd = 2)
```

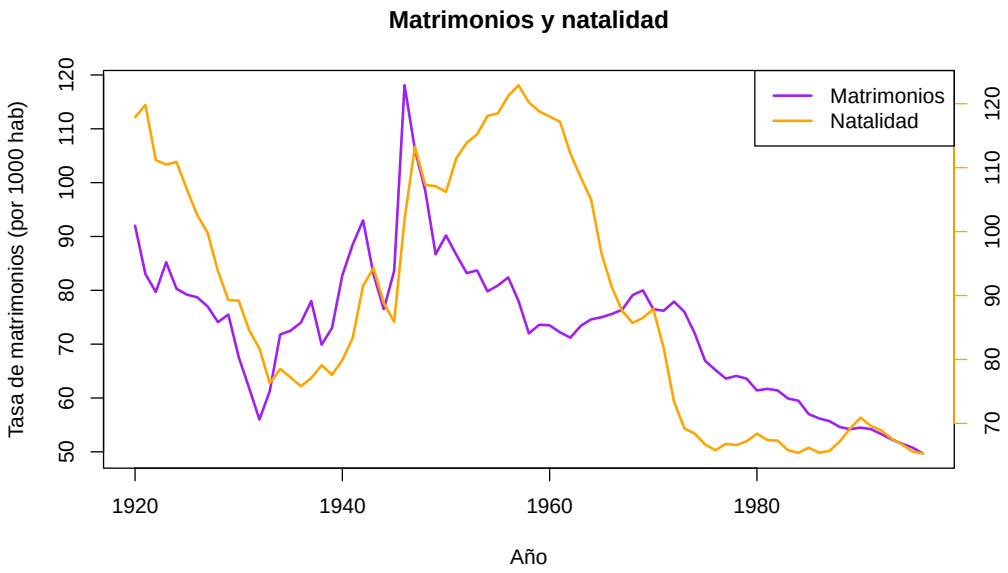

Aquí unos comentarios:

- La tasa de divorcios aumentó desde los años 30 hasta principios de los 50 (alrededor de 18), luego disminuyó ligeramente hasta finales de los 60 para aumentar hasta finales de los 70 e inicio 80.
- Se observa una tendencia similar en la participación femenina en la fuerza laboral (femlab), que crece constantemente.
- El desempleo tiene picos en las crisis (años 30) y un aumento gradual fine años 70. Sin embargo no muestra una relación directa clara con divorcios.
- La tasa de matrimonios y natalidad han ido disminuyendo en las últimas décadas. Tiene una relación directa por su interpretación gráfica.

2.3 Ejercicios del libro de Carmona

2.3.1 1. (∗) (Ejercicio 1.1 del Capítulo 1 página 24

Hallar las estimaciones de los parámetros en un modelo de regresión lineal simple, minimizando la suma de los cuadrados de los errores y Hallar también una expresión para las predicciones ˆyi y los residuos ei = yi − ˆyi. Nota: Este ejercicio está resuelto en el apéndice A del módulo El modelo lineal.

La función a minimizar es:

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Derivamos parcialmente respecto a β_0 y β_1 e igualamos a cero:

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^{n} x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Simplificando obtenemos las ecuaciones normales:

$$\begin{cases} n\beta_0 + \beta_1 \sum x_i = \sum y_i \\ \beta_0 \sum x_i + \beta_1 \sum x_i^2 = \sum x_i y_i \end{cases}$$

Resolviendo, se obtienen los estimadores mínimo-cuadráticos:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

donde $(\bar{x} = \frac{1}{n} \sum x_i), (\bar{y} = \frac{1}{n} \sum y_i)$.

Las predicciones son:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i = \bar{y} + \hat{\beta}_1 (x_i - \bar{x})$$

y los residuos:

$$e_i = y_i - \hat{y}_i$$

Por lo tanto, se verifica que $(\sum e_i = 0)$ y que los residuos no están correlacionados con los valores de (x_i) por la propiedades algebraicas.

2.3.2 2. (**) (Ejercicio 1.2 del Capítulo 1 página 24)

Hallar las estimaciones de los parámetros en un modelo de regresión parabólico, minimizando la suma de los cuadrados de los errores y Hallar también una expresión para las predicciones ˆyi y los residuos ei = yi − ˆyi

El modelo es $(y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i)$. Definimos las variables $(x_{i1} = x_i), (x_{i2} = x_i^2)$.

En forma matricial:

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon, \quad \mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}, \quad \beta = (\beta_0, \beta_1, \beta_2)'$$

Las ecuaciones normales son $(\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y})$. La solución es:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

siempre que $(\mathbf{X})$ tenga rango completo (lo cual ocurre si los (x_i) no son todos iguales y hay al menos tres valores distintos). Las predicciones son $(\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta})$ y los residuos $(\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}})$.

En componentes, el sistema normal es:

$$\begin{cases} n\hat{\beta}_0 + \hat{\beta}_1 \sum x_i + \hat{\beta}_2 \sum x_i^2 = \sum y_i \\ \hat{\beta}_0 \sum x_i + \hat{\beta}_1 \sum x_i^2 + \hat{\beta}_2 \sum x_i^3 = \sum x_i y_i \\ \hat{\beta}_0 \sum x_i^2 + \hat{\beta}_1 \sum x_i^3 + \hat{\beta}_2 \sum x_i^4 = \sum x_i^2 y_i \end{cases}$$

Por lo tanto no se obtiene una expresión cerrada tan simple como en el caso lineal, pero se resuelve numéricamente con los datos.

2.3.3 3. (Ejercicio 1.3 del Capítulo 1 página 24

Consideremos el problema de tráfico planteado en el apartado 1.2 de este capítulo, con la variable independiente densidad y la variable dependiente raíz cuadrada de la velocidad. Con los datos proporcionados en la tabla 1.1

```r
# Cargamos los datos que nos vienen indicados

dens <- c(12.7, 17.0, 66.0, 50.0, 87.8, 81.4, 75.6, 66.2, 81.1, 62.8,
          77.0, 89.6, 18.3, 19.1, 16.5, 22.2, 18.6, 66.0, 60.3, 56.0,
          66.3, 61.7, 66.6, 67.8)
vel <- c(62.4, 50.7, 17.1, 25.9, 12.4, 13.4, 13.7, 17.9, 13.8, 17.9,
         15.8, 12.6, 51.2, 50.8, 54.7, 46.5, 46.3, 16.9, 19.8, 21.2,
         18.3, 18.0, 16.6, 18.3)
rvel <- sqrt(vel)
```

2.3.3.1 a)

Los puntos: $(12.7, \sqrt{62.4})$ y $(87.8, \sqrt{12.4})$. Calculamos:

```r
x1 <- 12.7
y1 <- sqrt(62.4)
x2 <- 87.8
y2 <- sqrt(12.4)

pend <- (y2 - y1) / (x2 - x1)
inter <- y1 - pend * x1

cat("Recta: y =", inter, "+", pend, "* x\n")
```

```
## Recta: y = 8.639722 + -0.05829566 * x
```

Obtenemos aproximadamente: intercepto = 8.6397, pendiente = -0.0583.

Creamos el gráfico de dispersión y recta:

```r
plot(dens, rvel, pch=19, col="blue", xlab="Densidad", ylab="Raíz(velocidad)")
abline(a=inter, b=pend, col="red", lwd=2)
```

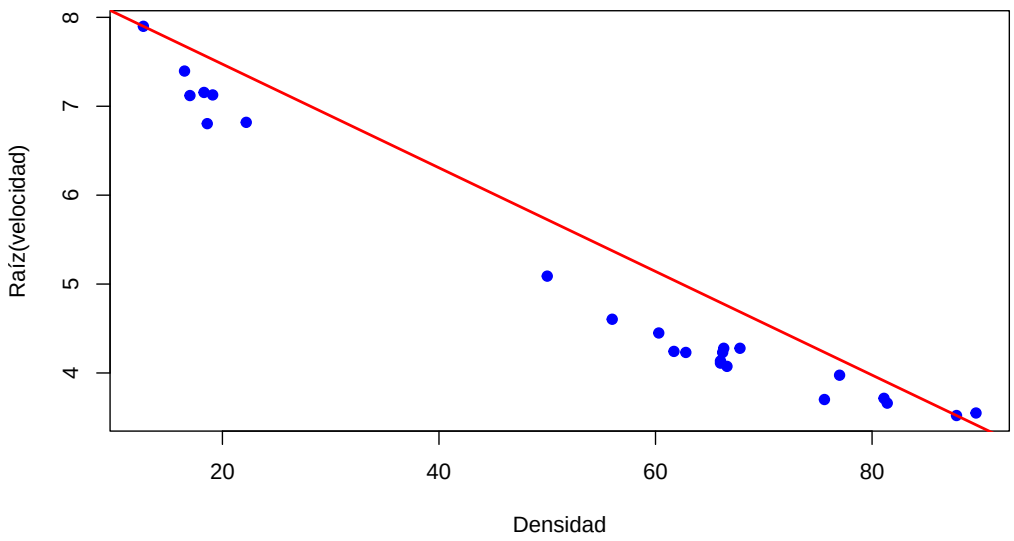

Calcularemos la suma de los residuos y suma de cuadrados:

```r
pred_recta <- inter + pend * dens
res_recta <- rvel - pred_recta
SCR_recta <- sum(res_recta^2)
cat("SCR recta inicial:", SCR_recta, "\n")
```

```
## SCR recta inicial: 6.689836
```

Gráficaremos los residuos:

```r
par(mfrow=c(1,2))
plot(dens, res_recta, main="Residuos vs densidad", ylab="residuos")
abline(h=0, col="gray")
plot(pred_recta, res_recta, main="Residuos vs predicciones", xlab="predicción")
abline(h=0, col="gray")
```

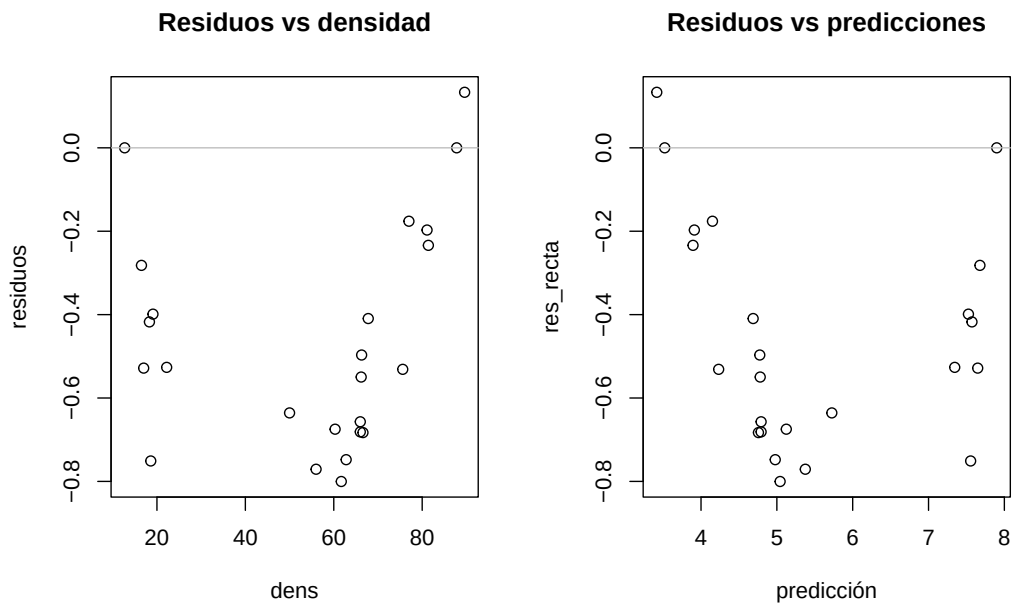

El resultados obtenido de la suma de los cuadrados de los residuos es ≈ 6.689836

2.3.3.2 (b) Hallamos la recta de regresión simple (mínimos cuadrados)

```r
modelo_lineal <- lm(rvel ~ dens)
summary(modelo_lineal)
```

```
##
## Call:
## lm(formula = rvel ~ dens)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.35337 -0.22722 -0.03566  0.18942  0.53349
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  8.089813   0.130629   61.93   <2e-16 ***
## dens        -0.056626   0.002177  -26.01   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2689 on 22 degrees of freedom
## Multiple R-squared:  0.9685, Adjusted R-squared:  0.9671
## F-statistic: 676.4 on 1 and 22 DF,  p-value: < 2.2e-16
```

```r
coef(modelo_lineal)
```

```
## (Intercept)        dens
##  8.08981299 -0.05662558
```

```r
pred_lineal <- fitted(modelo_lineal)
res_lineal <- resid(modelo_lineal)
SCR_lineal <- sum(res_lineal^2)
cat("SCR regresión lineal:", SCR_lineal, "\n")
```

```
## SCR regresión lineal: 1.591218
```

Los coeficientes son: ($\hat{\beta}_0 \approx 8.0898$), ($\hat{\beta}_1 \approx -0.05663$). SCR 1.591.

Para representar los gráficos de residuos, vamos a tener algo similar al punto anterior.

```r
# Configuramos para dos gráficos en una fila
par(mfrow = c(1, 2))

# Gráfico de residuos vs densidad
plot(dens, res_lineal,
     main = "Residuos vs Densidad (lineal)",
     xlab = "Densidad", ylab = "Residuos",
     pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2, lty = 2)

# Gráfico de residuos vs predicciones
plot(pred_lineal, res_lineal,
     main = "Residuos vs Predicciones (lineal)",
     xlab = "Predicciones", ylab = "Residuos",
     pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2, lty = 2)
```

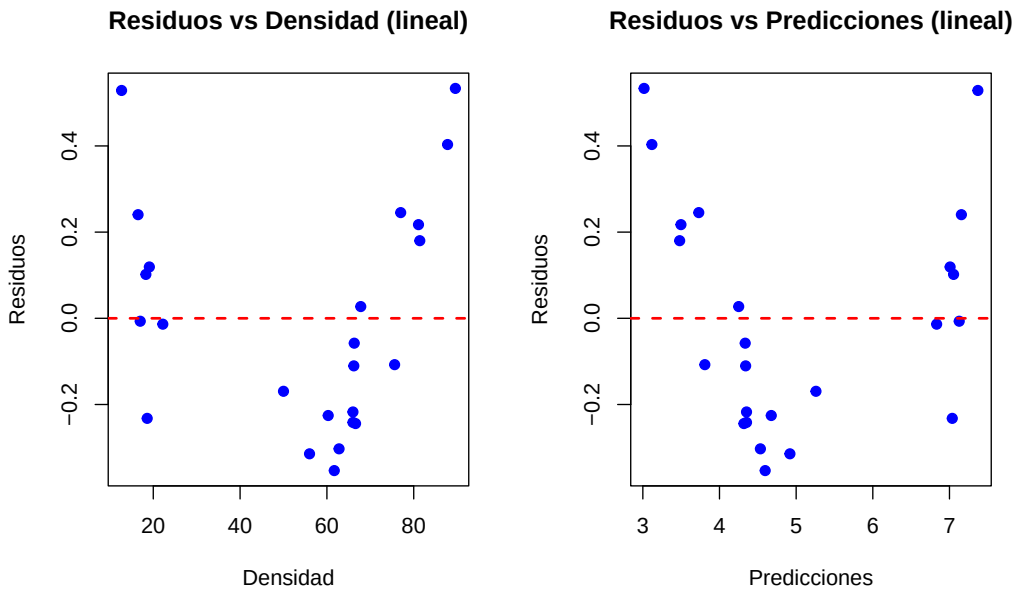


```r
par(mfrow = c(1, 1))
```

2.3.3.3 (c) Mejoramos el modelo anterior utilizando una Regresión parabólica

```r
modelo_parab <- lm(rvel ~ dens + I(dens^2))
summary(modelo_parab)
```

```
##
## Call:
## lm(formula = rvel ~ dens + I(dens^2))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.32089 -0.07209 -0.00047  0.06582  0.25368
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  8.881e+00  1.118e-01  79.469  < 2e-16 ***
## dens        -1.035e-01  5.567e-03 -18.593 1.60e-14 ***
## I(dens^2)    4.893e-04  5.705e-05   8.576 2.65e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1297 on 21 degrees of freedom
## Multiple R-squared:  0.993,  Adjusted R-squared:  0.9923
## F-statistic:  1490 on 2 and 21 DF,  p-value: < 2.2e-16
```

```r
pred_parab <- fitted(modelo_parab)
res_parab <- resid(modelo_parab)
SCR_parab <- sum(res_parab^2)
cat("SCR regresión parabólica:", SCR_parab, "\n")
```

```
## SCR regresión parabólica: 0.3534143
```

Coeficientes: ($\hat{\beta}_0 \approx 8.8814$), ($\hat{\beta}_1 \approx -0.1035$), ($\hat{\beta}_2 \approx 0.0004893$). La suma de los cuadrados de los residuos es SCR 0.353, claramente menor que el lineal.

Mostramos gráficamente los residuos

```r
# Configuramos para dos gráficos en una fila
par(mfrow = c(1, 2))

# Gráfico de residuos vs densidad
plot(dens, res_lineal,
     main = "Residuos vs Densidad (lineal)",
     xlab = "Densidad", ylab = "Residuos",
     pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2, lty = 2)

# Gráfico de residuos vs predicciones
plot(pred_parab, res_parab,
     main = "Residuos vs Predicciones (parabólica)",
     xlab = "Predicciones", ylab = "Residuos",
     pch = 19, col = "blue")
abline(h = 0, col = "red", lwd = 2, lty = 2)
```

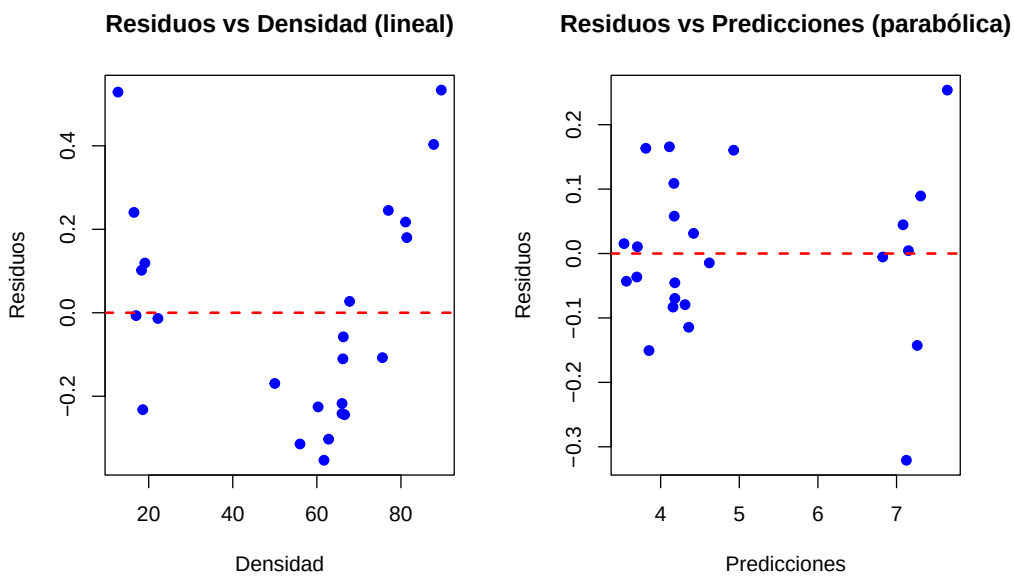


```r
par(mfrow = c(1, 1))
```

2.3.3.4 (d) Calculamos la capacidad de la carretera (máximo flujo)

El flujo es (F = velocidad $\times$ densidad = (raíz(vel))$^2 \times$ dens).

Usamos el modelo parabólico para predecir raíz(vel) en función de densidad:

$$\hat{r} = \hat{\beta}_0 + \hat{\beta}_1 d + \hat{\beta}_2 d^2$$

Luego ($\hat{v} = \hat{r}^2$) y ($\hat{F} = \hat{v} \cdot d = d \cdot (\hat{\beta}_0 + \hat{\beta}_1 d + \hat{\beta}_2 d^2)^2$).

Para hallar el máximo, podemos derivar numéricamente o evaluar en un rango.

```r
f_flujo <- function(d) {
  r <- coef(modelo_parab)[1] + coef(modelo_parab)[2]*d + coef(modelo_parab)[3]*d^2
  v <- r^2
  return(v * d)
}
d_vals <- seq(min(dens), max(dens), length=200)
flujo_vals <- sapply(d_vals, f_flujo)
d_opt <- d_vals[which.max(flujo_vals)]
cap_max <- max(flujo_vals)
cat("Densidad óptima:", d_opt, "veh/km\n")
```

```
## Densidad óptima: 43.61457 veh/km
```

```r
cat("Capacidad máxima:", cap_max, "veh/h (si velocidad en km/h, flujo en veh/h por carril)\n")
```

```
## Capacidad máxima: 1223.899 veh/h (si velocidad en km/h, flujo en veh/h por carril)
```

Resultado aproximado: densidad óptima alrededor de 44 veh/km y flujo máximo cercano a 1224 veh/h.

2.3.4 4. (Ejercicio 1.4 del Capítulo 1 página 24)

Tenemos la siguiente tabla de los mejores tiempos conseguidos en las pruebas de velocidad de las Olimpiades de Atlanda 1996.

```
dist <- c(100, 200, 400, 800, 1500, 5000, 10000, 42192)
hombres <- c(9.84, 19.32, 43.19, 102.58, 215.78, 787.96, 1627.34, 7956.00)
mujeres <- c(10.94, 22.12, 48.25, 117.73, 240.83, 899.88, 1861.63, 8765.00)
```

Si tomamos como variable regresora o independiente la distancia (metros) y como variable respuesta o dependiente el tiempo (segundos):

```
modelo_h <- lm(hombres ~ dist)
summary(modelo_h)
```

2.3.4.1 (a) Regresión simple con datos hombres

```
##
## Call:
## lm(formula = hombres ~ dist)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -186.35  -12.27   37.60   53.79   69.16
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -78.234245  38.827257  -2.015   0.0905 .
## dist          0.189193   0.002514  75.256 3.71e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 95.91 on 6 degrees of freedom
## Multiple R-squared:  0.9989, Adjusted R-squared:  0.9988
## F-statistic:  5663 on 1 and 6 DF,  p-value: 3.705e-10
```

```
pred_h <- fitted(modelo_h)
res_h <- resid(modelo_h)
SCR_h <- sum(res_h^2)
R2_h <- summary(modelo_h)$r.squared
cat("SCR hombres:", SCR_h, "\nR^2:", R2_h, "\n")
```

```
## SCR hombres: 55189
## R^2: 0.9989417
```

```
par(mfrow=c(1,2))
plot(dist, hombres, main="Hombres: tiempo vs distancia")
abline(modelo_h, col="red")
plot(dist, res_h, main="Residuos vs distancia")
abline(h=0, col="gray")
```

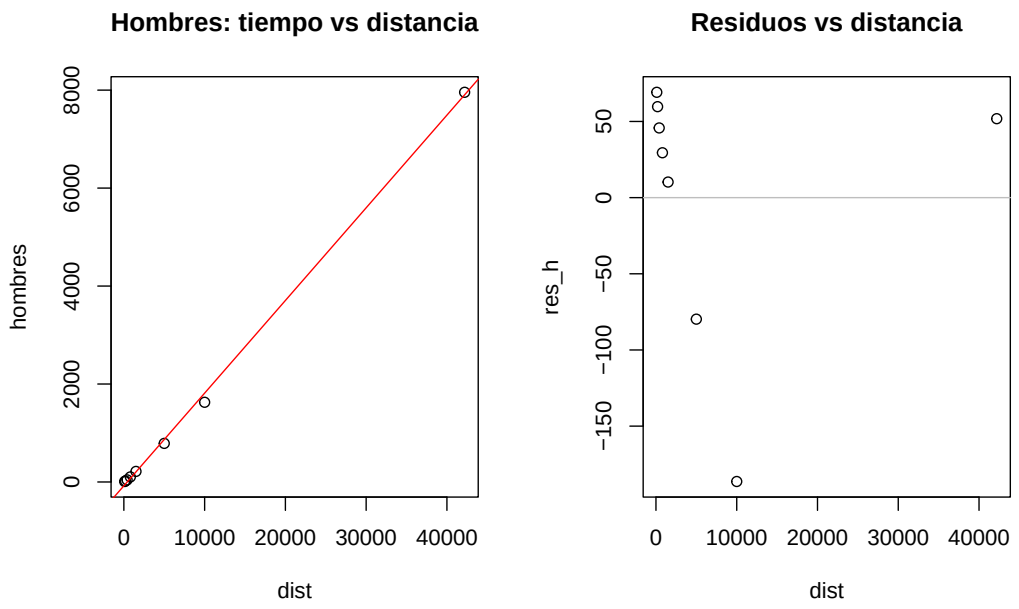


```
plot(pred_h, res_h, main="Residuos vs predicciones")
abline(h=0, col="gray")
```

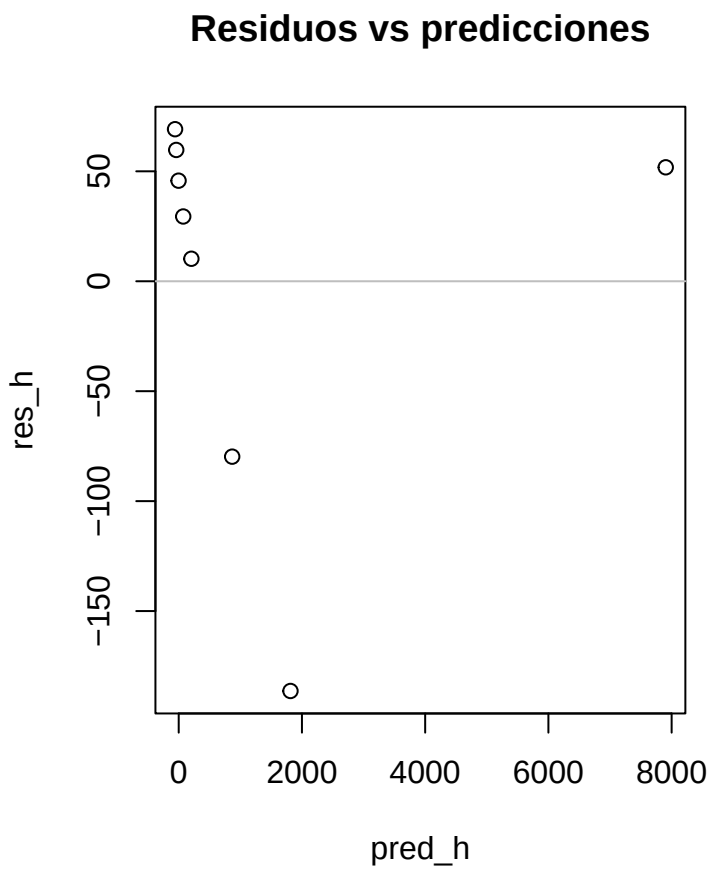

El R^2 es muy cercano a 1 (99.89%), por lo tanto el modelo lineal explica casi toda la variabilidad de los tiempos de los hombres en función de la distancia. El estadístico FF es grande (5663) y su p-valor es prácticamente cero, confirmando que la relación es estadísticamente significativa.

```r
log_dist <- log(dist)
log_h <- log(hombres)
modelo_log_h <- lm(log_h ~ log_dist)
summary(modelo_log_h)
```

2.3.4.2 b. Regresión con logaritmos (hombres)

```
##
## Call:
## lm(formula = log_h ~ log_dist)
##
## Residuals:
##       Min        1Q    Median        3Q       Max
## -0.076910 -0.041887  0.003026  0.034941  0.083359
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.88596    0.08066  -35.78 3.18e-08 ***
## log_dist     1.11809    0.01071  104.44 5.19e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.05835 on 6 degrees of freedom
## Multiple R-squared:  0.9995, Adjusted R-squared:  0.9994
## F-statistic: 1.091e+04 on 1 and 6 DF,  p-value: 5.192e-11
```

```r
pred_log_h <- fitted(modelo_log_h)
res_log_h <- resid(modelo_log_h)
SCR_log_h <- sum(res_log_h^2)
R2_log_h <- summary(modelo_log_h)$r.squared
cat("SCR log hombres:", SCR_log_h, "\nR^2:", R2_log_h, "\n")
```

```
## SCR log hombres: 0.02042962
## R^2: 0.9994503
```

```r
par(mfrow=c(1,2))
plot(log_dist, hombres, main="Hombres: tiempo vs distancia")
abline(modelo_h, col="red")
plot(log_dist, res_log_h, main="Residuos vs distancia")
abline(h=0, col="gray")
```

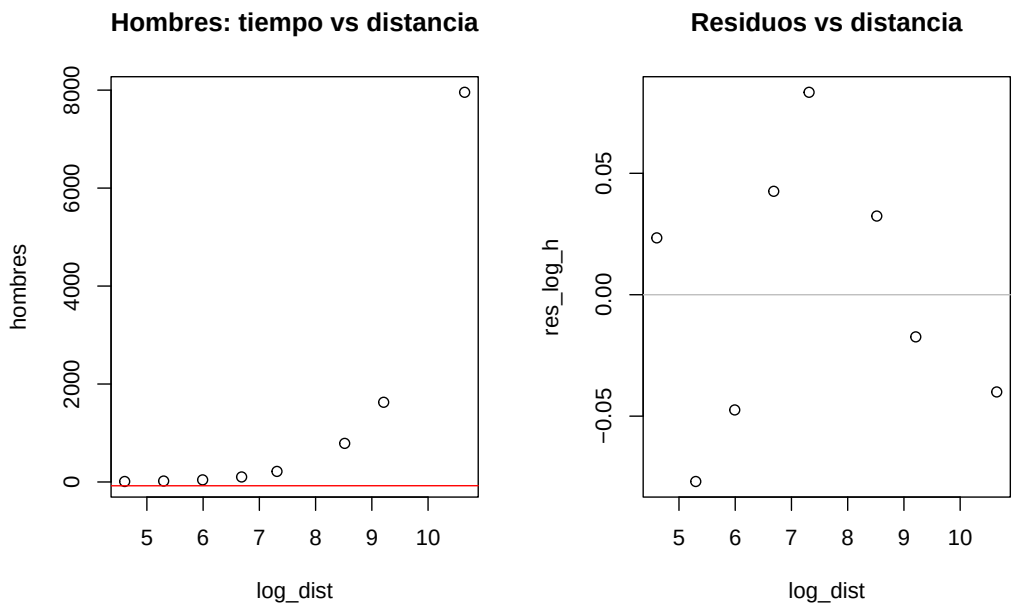


```
plot(pred_log_h, res_log_h, main="Residuos vs predicciones")
abline(h=0, col="gray")
```

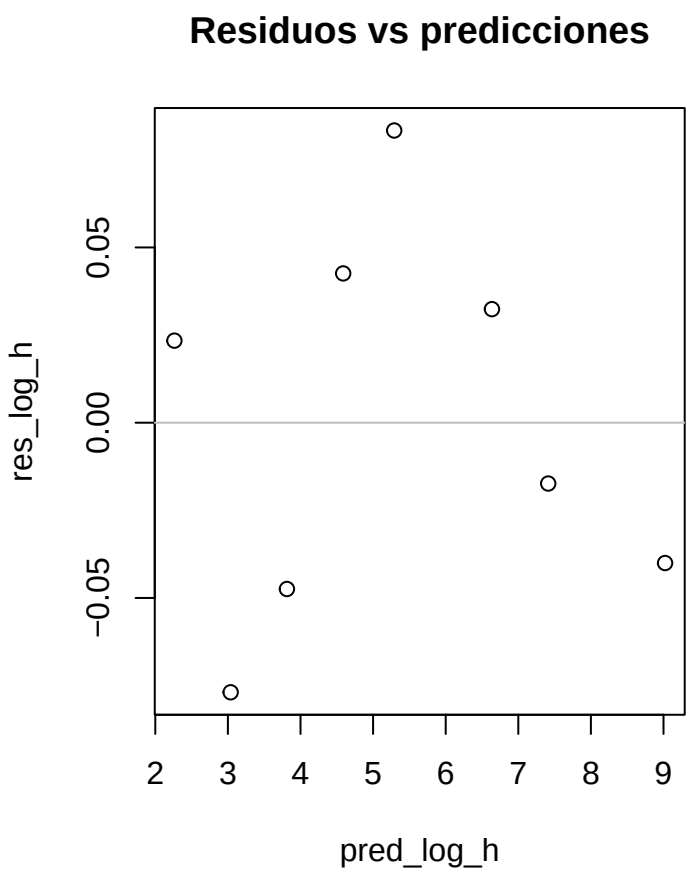

A pesar del alto R^2, es preferible utilizar una transformación logarítmica, que suele ajustar mejor este tipo de datos (relación potencial entre tiempo y distancia) y proporciona residuos más homogéneos y coeficientes interpretables.

```r
modelo_m <- lm(mujeres ~ dist)
summary(modelo_m)
```

2.3.4.3 (c) Repetiremos con los datos para mujeres

```
##
## Call:
## lm(formula = mujeres ~ dist)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -150.29  -16.90   30.50   45.25   62.67
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -72.579108  32.206936  -2.254   0.0651 .
## dist          0.208450   0.002085  99.960 6.76e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 79.55 on 6 degrees of freedom
## Multiple R-squared:  0.9994, Adjusted R-squared:  0.9993
## F-statistic:  9992 on 1 and 6 DF,  p-value: 6.756e-11
```

```r
pred_m <- fitted(modelo_m)
res_m <- resid(modelo_m)
SCR_m <- sum(res_m^2)
R2_m <- summary(modelo_m)$r.squared
cat("SCR mujeres:", SCR_m, "\nR^2:", R2_m, "\n")
```

```
## SCR mujeres: 37973.26
## R^2: 0.9993999
```

```r
par(mfrow=c(1,2))
plot(dist, mujeres, main="Mujeres: tiempo vs distancia")
abline(modelo_m, col="red")
plot(dist, res_m, main="Residuos vs distancia")
abline(h=0, col="gray")
```

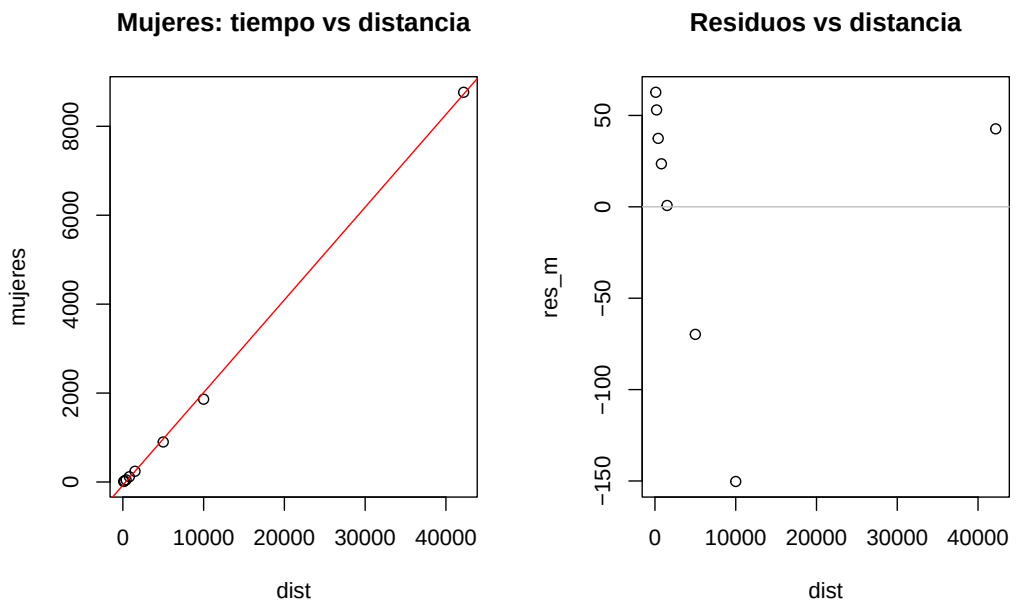


```r
plot(pred_m, res_m, main="Residuos vs predicciones")
abline(h=0, col="gray")
```

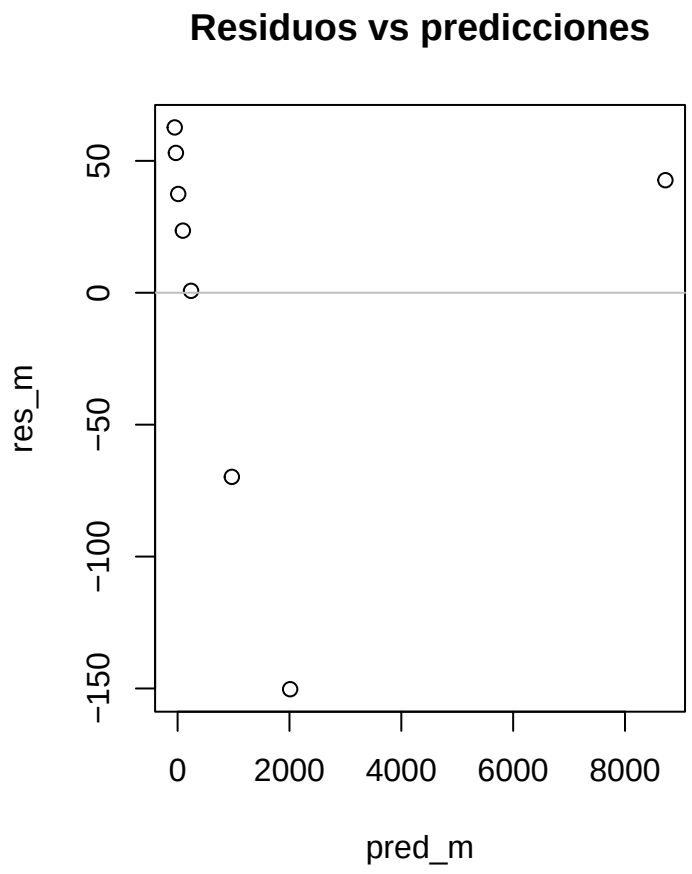

Encontraremos el mismo problema encontrado con los datos de hombres. Seguramente el F-estadístico será mejor utilizando la transformación logarítmica

```r
log_dist <- log(dist)
log_m <- log(mujeres)
modelo_log_m <- lm(log_m ~ log_dist)
summary(modelo_log_m)
```

```
##
## Call:
## lm(formula = log_m ~ log_dist)
##
## Residuals:
##       Min        1Q    Median        3Q       Max
## -0.063794 -0.058885  0.002453  0.049190  0.072736
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -2.75908    0.08390  -32.88 5.26e-08 ***
## log_dist     1.11721    0.01114  100.33 6.61e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0607 on 6 degrees of freedom
## Multiple R-squared:  0.9994, Adjusted R-squared:  0.9993
## F-statistic: 1.007e+04 on 1 and 6 DF,  p-value: 6.609e-11
```

```r
pred_log_m <- fitted(modelo_log_m)
res_log_m <- resid(modelo_log_m)
SCR_log_m <- sum(res_log_m^2)
R2_log_m <- summary(modelo_log_m)$r.squared
cat("SCR log mujeres:", SCR_log_m, "\nR^2:", R2_log_m, "\n")
```

```
## SCR log mujeres: 0.02210668
## R^2: 0.9994042
```

```r
par(mfrow=c(1,2))
plot(log_dist, mujeres, main="Mujeres: tiempo vs distancia")
abline(modelo_m, col="red")
plot(log_dist, res_log_m, main="Residuos vs distancia")
abline(h=0, col="gray")
```

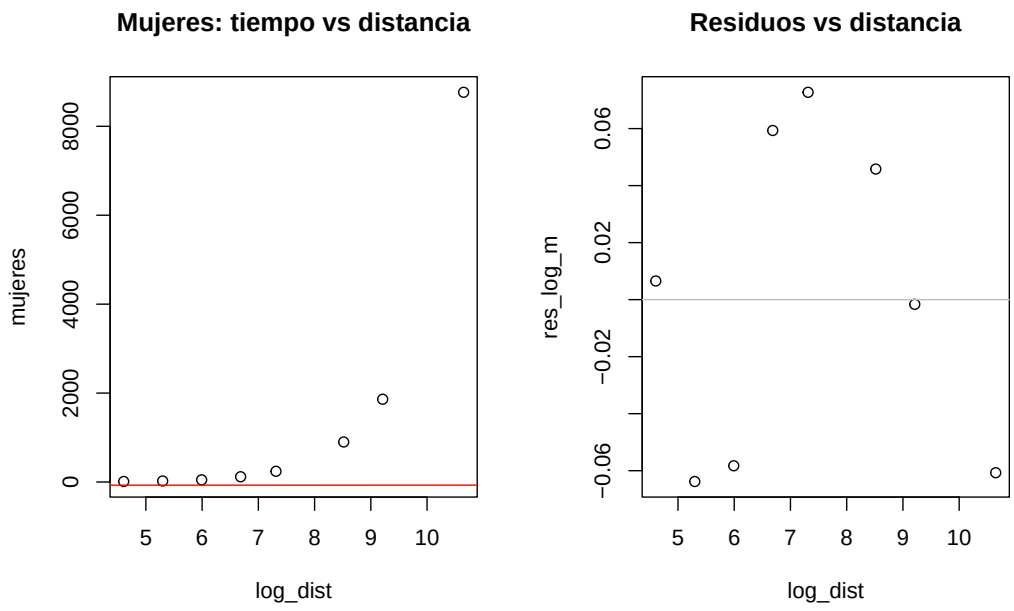


```
plot(pred_log_m, res_log_m, main="Residuos vs predicciones")
abline(h=0, col="gray")
```

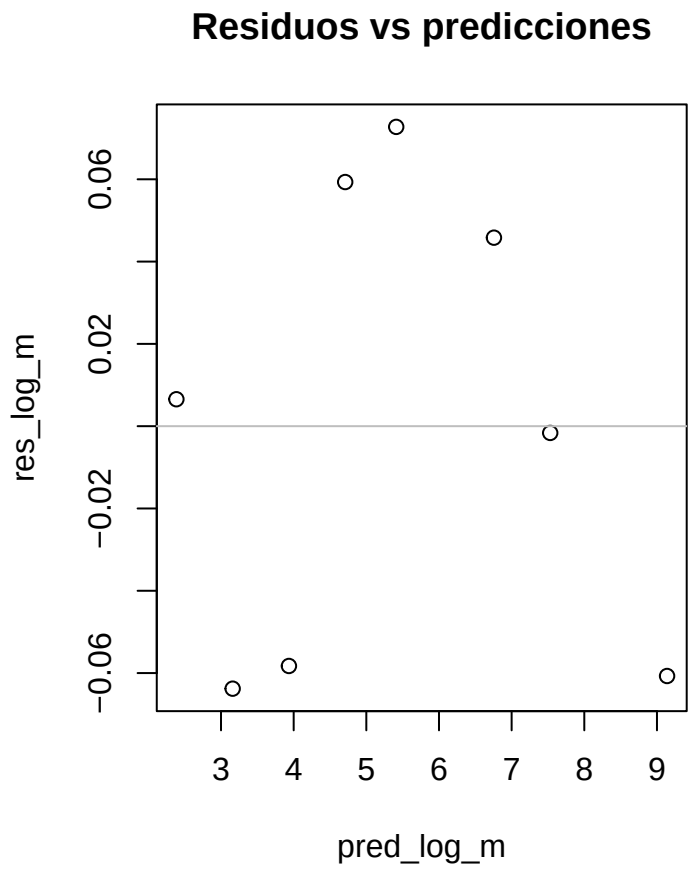

BIBLIOGRAFIA

Materiales complementarios

Faraway, Julian J., Linear Models with R, CRC Press, 2014. 1. Introduction (completo)

Carmona, Francesc, Modelos lineales, Publicaciones UB, 2004. 1. Las condiciones (1.1 - 1.7)

ML [Pages 1 - 57].pdf Descargar ML [Pages 1 - 57].pdf

Curso "Regression Methods" de la Penn-State University Lesson 1: Simple Linear Regression (excepto 1.9) https://online.stat.psu.edu/stat501/lesson/1Links to an external site.

Quick-R (Fitting the Model) https://www.statmethods.net/stats/regression.htmlLinks to an external site.