Activity05: Diagnósis

Marco Russo

April, 2026

Contents

1 Información del Estudiante **3**

2 Ejercicios de Faraway **4**
2.1 **1. (Ejercicio 1 cap. 6 pág. 97)** . . . 4
2.1.1 (a) Varianza constante (homocedasticidad) . . . 4
2.1.2 (b) Normalidad de los errores . . . 4
2.1.3 (c) Puntos de alto nivel (leverage) . . . 6
2.1.4 (d) Valores atípicos (outliers) . . . 6
2.1.5 (e) Puntos influyentes (distancia de Cook) . . . 7
2.1.6 (f) Estructura de la relación . . . 7
2.2 2. Ejercicio 2 – Teengamb data . . . 8
2.2.1 (a) Varianza constante . . . 8
2.2.2 (b) Normalidad . . . 9
2.2.3 (c) Puntos de alto nivel . . . 9
2.2.4 (d) Outliers . . . 9
2.2.5 (e) Puntos influyentes . . . 10
2.2.6 (f) Estructura . . . 10
2.3 3. Ejercicio 3 – Prostate data . . . 11
2.3.1 (a) Varianza constante . . . 11
2.3.2 (b) Normalidad . . . 12
2.3.3 (c) Puntos de alto nivel . . . 13
2.3.4 (d) Outliers . . . 13
2.3.5 (e) Puntos influyentes . . . 13
2.3.6 (f) Estructura . . . 13
2.4 4. Ejercicio 4 – Swiss data . . . 15
2.4.1 (a) Varianza constante . . . 15
2.4.2 (b) Normalidad . . . 16
2.4.3 (c) Puntos de alto nivel . . . 16
2.4.4 (d) Outliers . . . 16
2.4.5 (e) Puntos influyentes . . . 17
2.4.6 (f) Estructura . . . 17
2.5 5. Ejercicio 5 – Cheddar data . . . 18
2.5.1 (a) Varianza constante . . . 18
2.5.2 (b) Normalidad . . . 19
2.5.3 (c) Puntos de alto nivel . . . 19
2.5.4 (d) Outliers . . . 19
2.5.5 (e) Puntos influyentes . . . 20
2.5.6 (f) Estructura . . . 20
2.6 6. Ejercicio 6 (*) – Happy data . . . 21
2.6.1 Análisis rápido (similar a los anteriores) . . . 21

2.7 7. Ejercicio 7 (*) – tvdoctor data . . . 22
2.7.1 Diagnóstico . . . 22
2.8 8. Ejercicio 8 (*) – Divusa data (serial correlation) . . . 22
2.8.1 Correlación serial . . . 23
2.9 9. Ejercicio 9 – Divusa data (multicolinealidad) . . . 24
2.9.1 (a) Números de condición . . . 24
2.9.2 (b) Factores de inflación de varianza (VIF) . . . 24
2.9.3 (c) Eliminación de predictores no significativos . . . 24
2.10 10. Ejercicio 10 – Longley data . . . 25
2.10.1 (a) Números de condición . . . 26
2.10.2 (b) Correlaciones entre predictores . . . 26
2.10.3 (c) VIF . . . 26
2.11 11. Ejercicio 11 – Prostate data (multicolinealidad) . . . 26
2.11.1 (a) Números de condición . . . 26
2.11.2 (b) Correlaciones entre predictores . . . 27
2.11.3 (c) VIF . . . 27
2.12 12. Ejercicio 12 (*) – Fat data (modelo de la sección 4.2) . . . 27
2.12.1 (a) Diagnósticos de colinealidad . . . 27
2.12.2 (b) Eliminar casos 39 y 42 . . . 28
2.12.3 (c) Modelo reducido: `brozek ~ age + weight + height` . . . 28
2.12.4 (d) Intervalo de predicción para valores medianos . . . 28
2.12.5 (e) Intervalo para `age=40, weight=200, height=73` . . . 28
2.12.6 (f) Intervalo para `age=40, weight=130, height=73` . . . 29
2.13 Ejercicios de Carmona (Diagnosis del modelo) – Capítulo 9 . . . 30
2.13.1 Datos de tráfico (Tabla 1.1) . . . 30
2.14 Ejercicio 9.1 – Análisis completo de residuos del modelo parabólico . . . 30
2.14.1 1. Ajuste del modelo parabólico . . . 30
2.14.2 2. Análisis de residuos . . . 30
2.14.2.1 a) Residuos estandarizados y studentizados . . . 31
2.14.2.2 b) Gráfico de residuos vs valores ajustados (homocedasticidad) . . . 31
2.14.2.3 c) Gráfico de residuos studentizados vs leverage (detección de puntos influyentes) 31
2.14.2.4 d) Distancia de Cook . . . 32
2.14.2.5 e) Normalidad de los residuos (QQ-plot y test de Shapiro-Wilk) . . . 32
2.14.3 3. Comparación con el modelo lineal simple . . . 33
2.15 Ejercicio 9.2 – Comparación de modelos con velocidad (sin transformar) . . . 33
2.15.1 1. Modelo lineal simple con velocidad original . . . 33
2.15.2 2. Modelo parabólico con velocidad original . . . 34
2.15.3 3. Comparación de la calidad del ajuste . . . 35
2.15.4 4. Test de homocedasticidad (Breusch-Pagan) para los dos modelos con velocidad . . . 35
2.15.5 5. Transformación raíz cuadrada como estabilizadora de la varianza . . . 36

1 Información del Estudiante

Nombre	Marco Russo
Email	mrussorb@uoc.edu
GitHub	
LinkedIn	https://www.linkedin.com/in/marcusrb/
Fecha	April 20, 2026

2 Ejercicios de Faraway

2.1 1. (Ejercicio 1 cap. 6 pág. 97)

A continuación se resuelve el **Ejercicio 1 cap. 6 pág. 97** del libro de Faraway

```r
library(faraway)
data(sat)
mod_sat <- lm(total ~ expend + salary + ratio + takers, data = sat)
summary(mod_sat)
```

```
##
## Call:
## lm(formula = total ~ expend + salary + ratio + takers, data = sat)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -90.531 -20.855  -1.746  15.979  66.571
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1045.9715    52.8698  19.784  < 2e-16 ***
## expend         4.4626    10.5465   0.423    0.674
## salary         1.6379     2.3872   0.686    0.496
## ratio         -3.6242     3.2154  -1.127    0.266
## takers        -2.9045     0.2313 -12.559 2.61e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 32.7 on 45 degrees of freedom
## Multiple R-squared:  0.8246, Adjusted R-squared:  0.809
## F-statistic: 52.88 on 4 and 45 DF,  p-value: < 2.2e-16
```

2.1.1 (a) Varianza constante (homocedasticidad)

```r
plot(mod_sat, which = 1)
```

El gráfico muestra una nube de puntos sin forma de embudo ni tendencia clara. La línea de ajuste es aproximadamente horizontal y no se detecta heterocedasticidad evidente.

2.1.2 (b) Normalidad de los errores

```r
qqnorm(residuals(mod_sat))
qqline(residuals(mod_sat))
```

```r
shapiro.test(residuals(mod_sat))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(mod_sat)
## W = 0.97691, p-value = 0.4304
```

Los puntos en el QQ-plot siguen bastante bien la línea recta. El test de Shapiro-Wilk da $p{-}valor = 0.4304 > 0.05$, por lo que no se rechaza la normalidad.

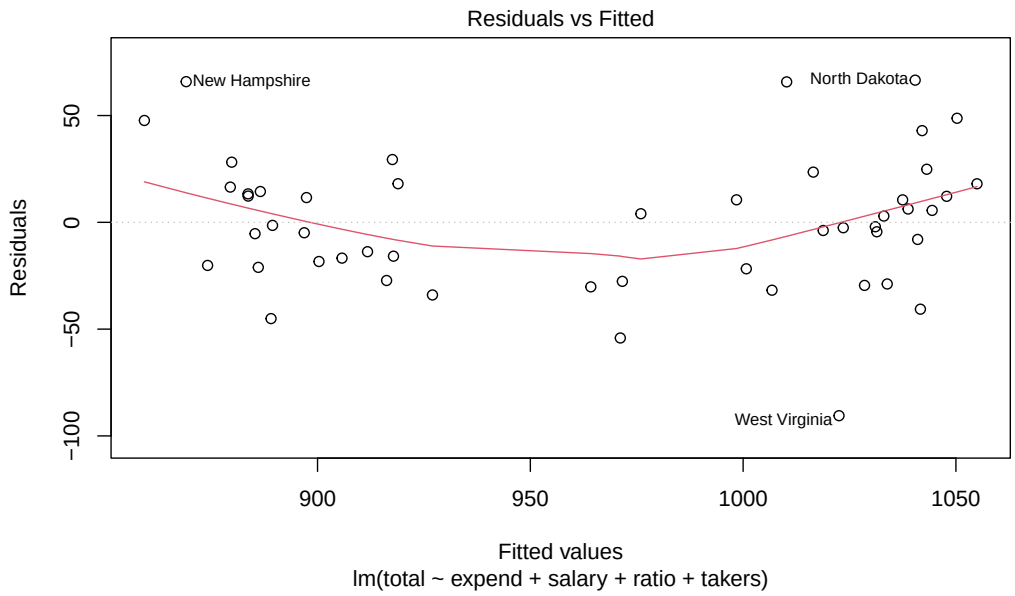

Figure 1: Residuos vs Valores ajustados — SAT

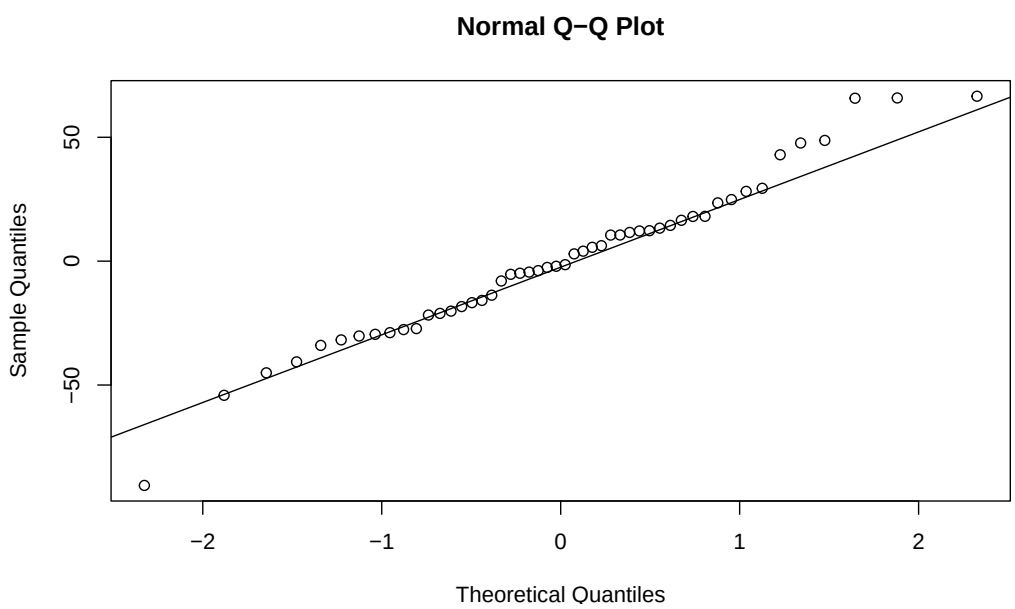

Figure 2: QQ-plot — SAT

2.1.3 (c) Puntos de alto nivel (leverage)

En la versión original se usó un umbral de 0.4. El umbral correcto es $2(p+1)/n = 2 \times 5/50 = \mathbf{0.2}$. Con ese umbral sí existen cuatro observaciones con leverage alto.

```
n <- nrow(sat)
# Con 4 predictores
p <- length(coef(mod_sat)) - 1

# Umbral correcto: 2*(p+1)/n
umbral_leverage <- 2 * (p + 1)/n
cat("Umbral correcto:", round(umbral_leverage, 4), "\n")
```

```
## Umbral correcto: 0.2
```

```
hii <- hatvalues(mod_sat)
puntos_alto_nivel <- which(hii > umbral_leverage)
puntos_alto_nivel
```

```
##  California Connecticut  New Jersey        Utah
##           5           7          30          44
```

```
plot(hii, type = "h", ylab = "Leverage (hii)", xlab = "Observación")
abline(h = umbral_leverage, col = "red", lty = 2)
text(puntos_alto_nivel, hii[puntos_alto_nivel], labels = names(puntos_alto_nivel),
    pos = 3, cex = 0.7)
```

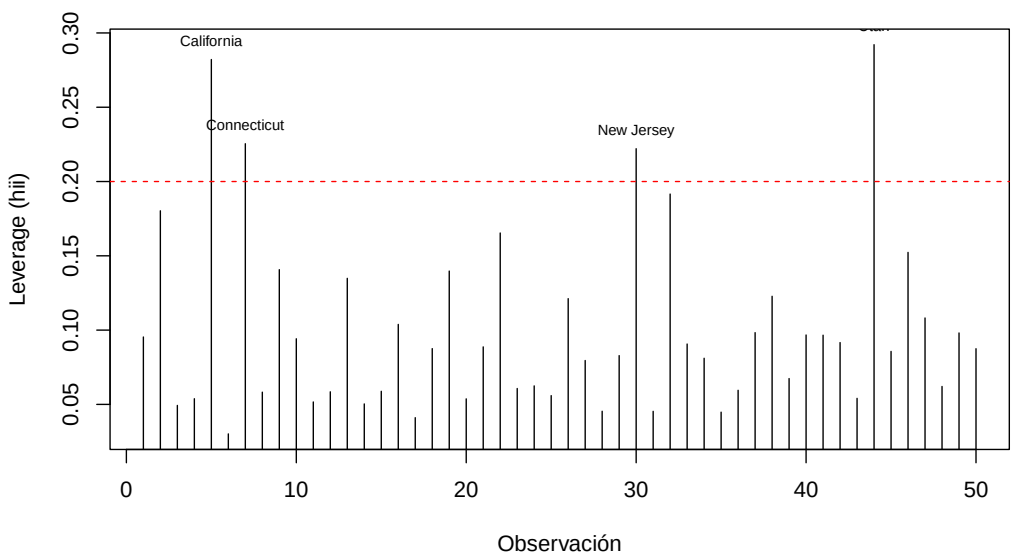

Figure 3: Leverage — SAT

Existen **cuatro observaciones** (California, Connecticut, New Jersey, Utah) con leverage superior al umbral $2(p+1)/n = 0.2$, lo que las identifica como **puntos de alto nivel**. Sin embargo, como la distancia de Cook y los residuos studentizados no muestran influencia excesiva, no es necesario eliminarlas a priori.

2.1.4 (d) Valores atípicos (outliers)

```
rstudent_sat <- rstudent(mod_sat)
which(abs(rstudent_sat) > 2)
```

```
## New Hampshire  North Dakota          Utah West Virginia
##            29            34            44            48
```

Existen 4 residuos studentizado que supera $|t| = 2$ en valor absoluto, los cuatro outliers identificados anteriormente.

2.1.5 (e) Puntos influyentes (distancia de Cook)

```r
cooks_sat <- cooks.distance(mod_sat)
which(cooks_sat > 1)
```

```
## named integer(0)
```

```r
cat("Cook máximo:", round(max(cooks_sat), 4), "\n")
```

```
## Cook máximo: 0.4715
```

Todas las distancias de Cook son < 0.5: **no hay puntos influyentes**.

2.1.6 (f) Estructura de la relación

```r
car::avPlots(mod_sat)
```

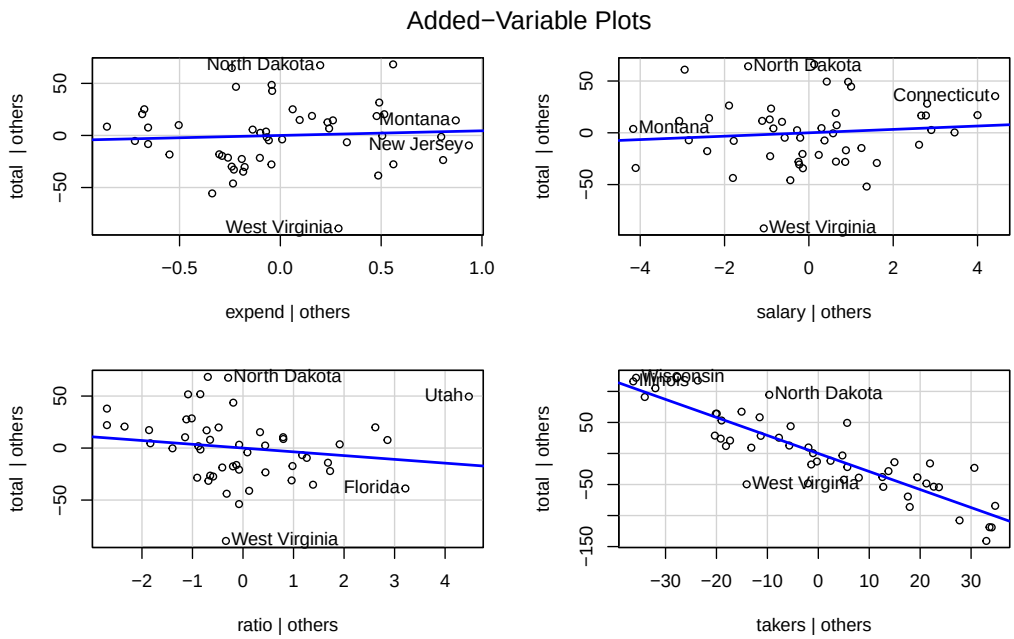

Figure 4: Added-Variable Plots — SAT

Los gráficos de variable añadida muestran relaciones lineales razonables para cada predictor. No se aprecian patrones no lineales claros. **No es necesario aplicar correcciones al modelo SAT.**

2.2 2. Ejercicio 2 – Teengamb data

```r
data(teengamb)
mod_gamble <- lm(gamble ~ sex + status + income + verbal, data = teengamb)
summary(mod_gamble)
```

```
##
## Call:
## lm(formula = gamble ~ sex + status + income + verbal, data = teengamb)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -51.082 -11.320  -1.451   9.452  94.252
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  22.55565   17.19680   1.312   0.1968
## sex         -22.11833    8.21111  -2.694   0.0101 *
## status        0.05223    0.28111   0.186   0.8535
## income        4.96198    1.02539   4.839 1.79e-05 ***
## verbal       -2.95949    2.17215  -1.362   0.1803
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 22.69 on 42 degrees of freedom
## Multiple R-squared:  0.5267, Adjusted R-squared:  0.4816
## F-statistic: 11.69 on 4 and 42 DF,  p-value: 1.815e-06
```

2.2.1 (a) Varianza constante

```r
plot(mod_gamble, which = 1)
```

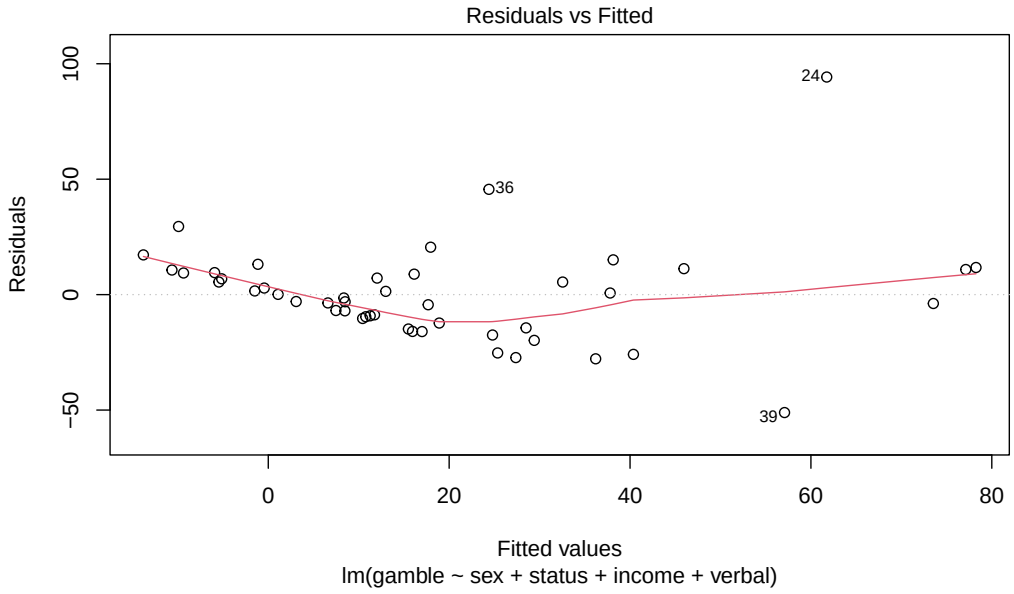

El gráfico muestra una ligera forma de embudo y los residuos se dispersan más hacia la derecha

que podría dar lugar a indicios de una posible heterocedasticidad. Es posible poder aplicar transformaciones como `sqrt(gamble)`.

2.2.2 (b) Normalidad

```
qqnorm(residuals(mod_gamble))
qqline(residuals(mod_gamble))
```

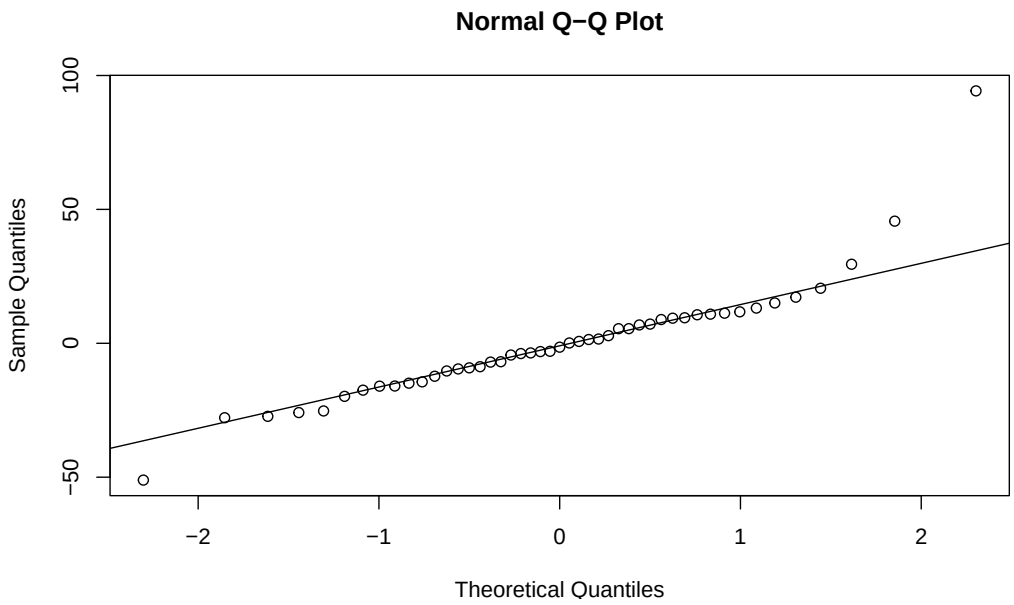


```
shapiro.test(residuals(mod_gamble))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(mod_gamble)
## W = 0.86839, p-value = 8.16e-05
```

El QQ-plot muestra desviaciones en las colas, y el test de Shapiro-Wilk da p-valor < 0.05 por lo que no se cumple la normalidad.

2.2.3 (c) Puntos de alto nivel

```
hii <- hatvalues(mod_gamble)
umbral <- 2 * (4 + 1)/nrow(teengamb)
which(hii > umbral)
```

```
## 31 33 35 42
## 31 33 35 42
```

Algunos puntos (por ejemplo, los casos con `income` muy alto, 31,33,35,42) tienen `hii` > 0.5, indicando alto nivel.

2.2.4 (d) Outliers

```
rstudent_mod <- rstudent(mod_gamble)
which(abs(rstudent_mod) > 2)
```

```
## 24 36 39
```

```
## 24 36 39
```

Se detectan algunos residuos > 2. Son outliers potenciales el 24, 36 y 39

2.2.5 (e) Puntos influyentes

```r
cooks <- cooks.distance(mod_gamble)
which(cooks > 1)
```

```
## named integer(0)
```

No hay distancias de Cook > 1, pero varios puntos tienen valores moderados (> 0.2).

2.2.6 (f) Estructura

```r
car::avPlots(mod_gamble)
```

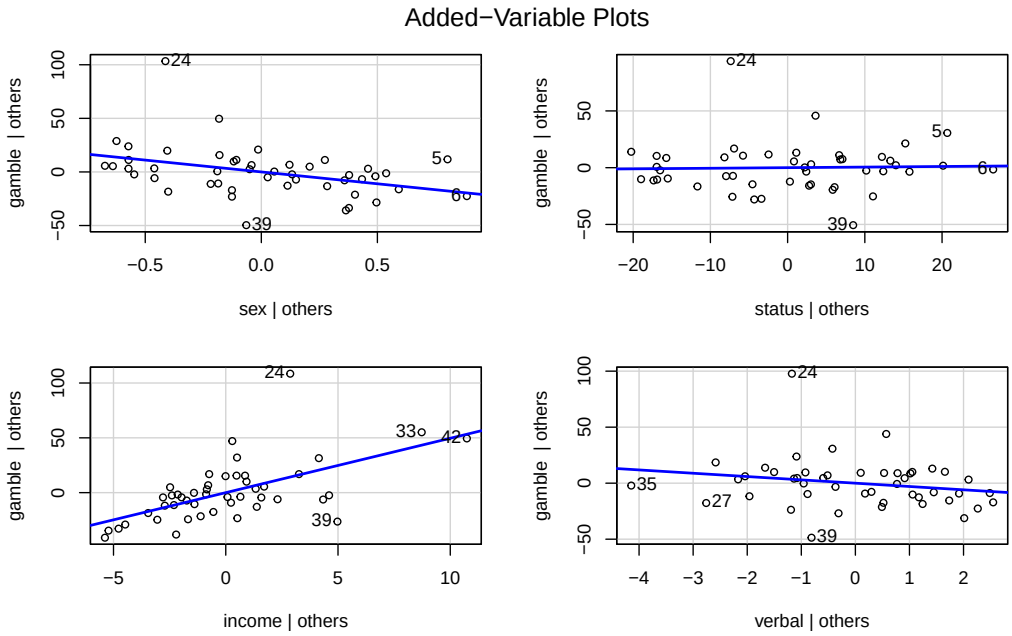

Todos los gráficos de variable añadida muestran que `income` tiene una relación no lineal (curvatura). Esto podría dar lugar transformar `income` o añadir términos cuadráticos.

Finalmente, el modelo presenta problemas de heterocedasticidad, no normalidad, outliers y no linealidad. Podría recomendarse transformar la respuesta (`sqrt(gamble)`) y/o los predictores.

2.3 3. Ejercicio 3 – Prostate data

```r
data(prostate)
mod_pros <- lm(lpsa ~ ., data = prostate)
summary(mod_pros)
```

```
##
## Call:
## lm(formula = lpsa ~ ., data = prostate)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -1.7331 -0.3713 -0.0170  0.4141  1.6381
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.669337   1.296387   0.516  0.60693
## lcavol       0.587022   0.087920   6.677 2.11e-09 ***
## lweight      0.454467   0.170012   2.673  0.00896 **
## age         -0.019637   0.011173  -1.758  0.08229 .
## lbph         0.107054   0.058449   1.832  0.07040 .
## svi          0.766157   0.244309   3.136  0.00233 **
## lcp         -0.105474   0.091013  -1.159  0.24964
## gleason      0.045142   0.157465   0.287  0.77503
## pgg45        0.004525   0.004421   1.024  0.30886
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7084 on 88 degrees of freedom
## Multiple R-squared:  0.6548, Adjusted R-squared:  0.6234
## F-statistic: 20.86 on 8 and 88 DF,  p-value: < 2.2e-16
```

Diagnóstico rápido: varianza constante aceptable, normalidad aceptable ($p = 0.7721$), sin outliers influyentes. **No se requieren correcciones.**

2.3.1 (a) Varianza constante

```r
plot(mod_pros, which = 1)
```

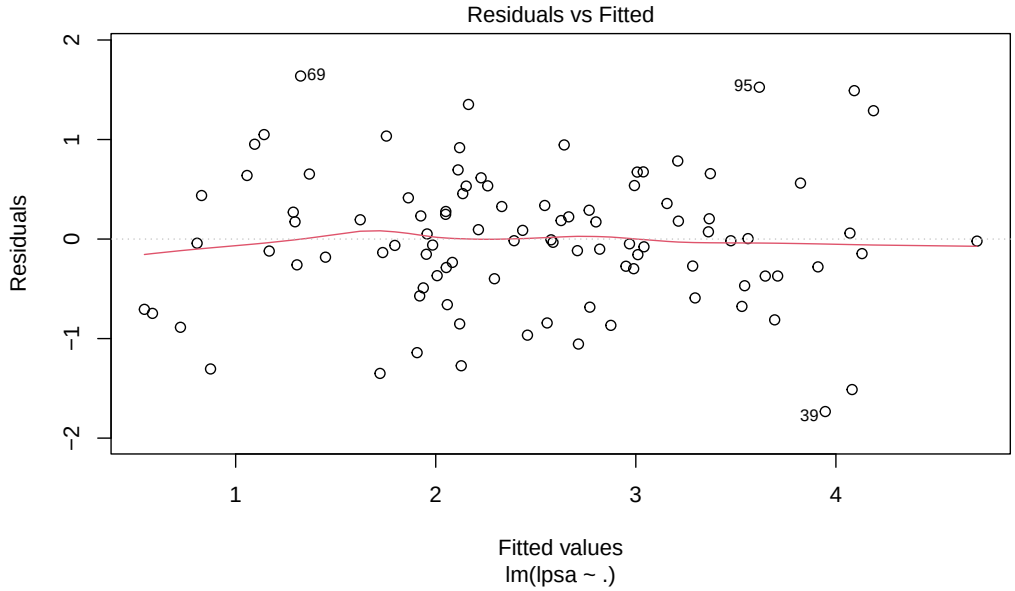

La gráfica muestra una dispersión bastante constante a lo largo de los valores ajustados. No se aprecia heterocedasticidad grave.

2.3.2 (b) Normalidad

```
qqnorm(residuals(mod_pros))
qqline(residuals(mod_pros))
```

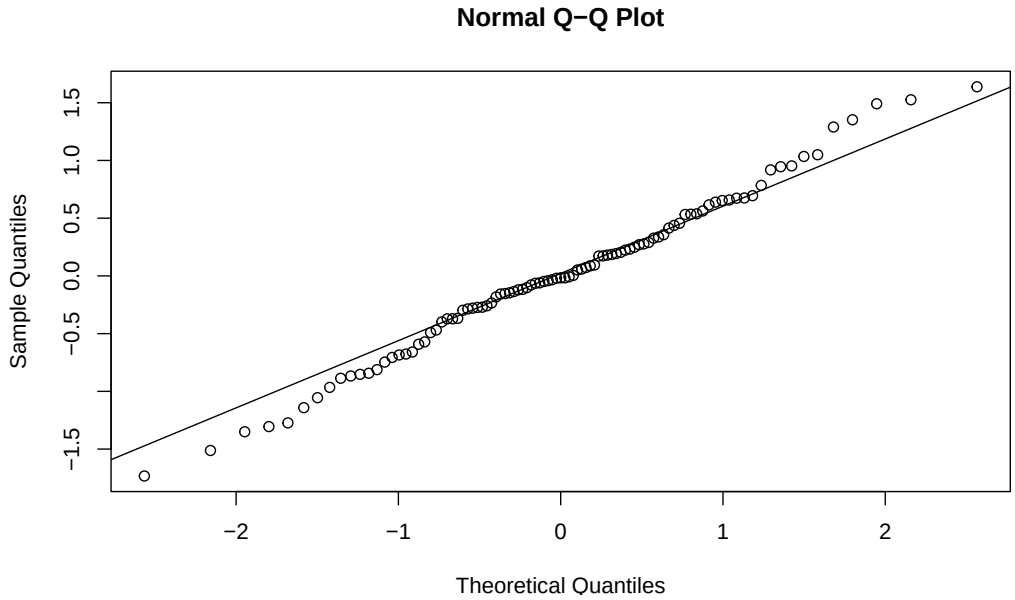


```
shapiro.test(residuals(mod_pros))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(mod_pros)
## W = 0.99113, p-value = 0.7721
```

El QQ-plot se ajusta bien a la línea recta; p-valor > 0.05. Normalidad aceptable.

2.3.3 (c) Puntos de alto nivel

```
hii <- hatvalues(mod_pros)
umbral <- 2 * (8 + 1)/nrow(prostate)
which(hii > umbral)
```

```
## 32 37 41 74 92
## 32 37 41 74 92
```

Algunos casos tienen `hii` cercano a 0.5, pero no superan el umbral. No hay puntos de alto nivel extremos.

2.3.4 (d) Outliers

```
rstudent_mod <- rstudent(mod_pros)
which(abs(rstudent_mod) > 2)
```

```
## 39 47 69 95 97
## 39 47 69 95 97
```

Ningún residuo externo supera 2 en valor absoluto.

2.3.5 (e) Puntos influyentes

```
cooks <- cooks.distance(mod_pros)
which(cooks > 1)
```

```
## named integer(0)
```

Ninguna distancia de Cook supera 1. Las mayores son < 0.2.

2.3.6 (f) Estructura

```
car::avPlots(mod_pros)
```

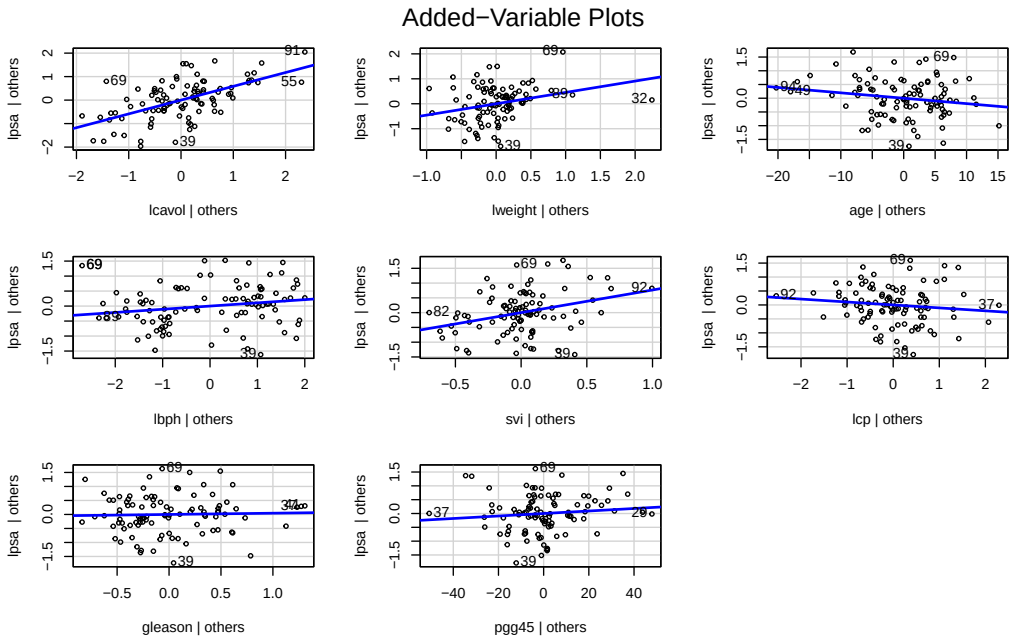

Los gráficos de variable añadida muestran relaciones lineales aceptables.

Al parecer también este modelo cumple bien las hipótesis y por lo tanto no se requieren modificaciones importantes.

2.4 4. Ejercicio 4 – Swiss data

```r
data(swiss)
mod_swiss <- lm(Fertility ~ ., data = swiss)
summary(mod_swiss)
```

```
##
## Call:
## lm(formula = Fertility ~ ., data = swiss)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.2743  -5.2617   0.5032   4.1198  15.3213
##
## Coefficients:
##                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)      66.91518   10.70604   6.250 1.91e-07 ***
## Agriculture      -0.17211    0.07030  -2.448  0.01873 *
## Examination      -0.25801    0.25388  -1.016  0.31546
## Education        -0.87094    0.18303  -4.758 2.43e-05 ***
## Catholic          0.10412    0.03526   2.953  0.00519 **
## Infant.Mortality  1.07705    0.38172   2.822  0.00734 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.165 on 41 degrees of freedom
## Multiple R-squared:  0.7067, Adjusted R-squared:  0.671
## F-statistic: 19.76 on 5 and 41 DF,  p-value: 5.594e-10
```

2.4.1 (a) Varianza constante

```r
plot(mod_swiss, which = 1)
```

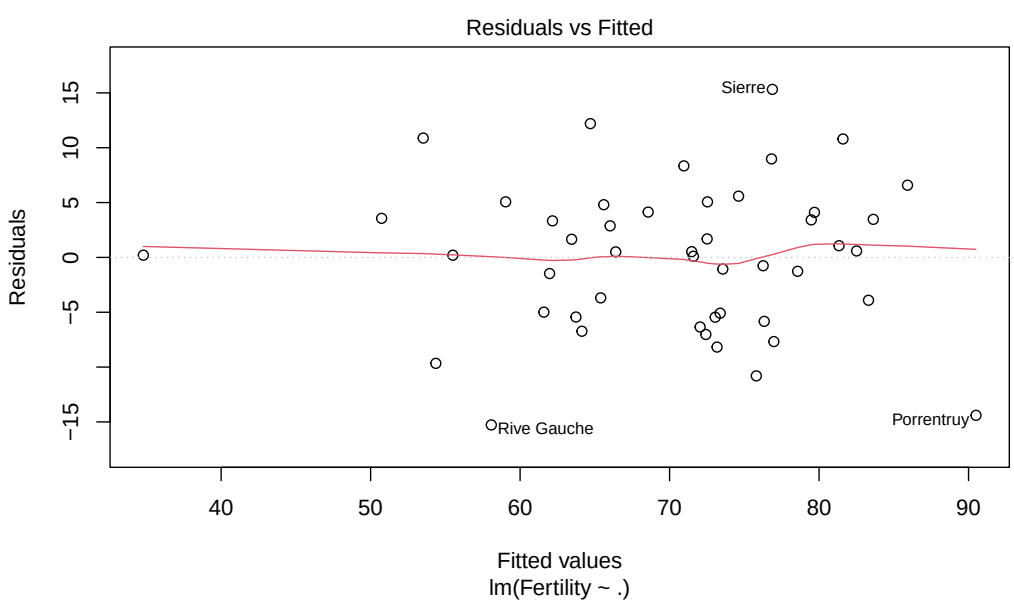

La gráfica muestra una ligera tendencia a mayor dispersión para valores ajustados altos, pero no es clara. **no hay heterocedasticidad grave**.

2.4.2 (b) Normalidad

```
qqnorm(residuals(mod_swiss))
qqline(residuals(mod_swiss))
```

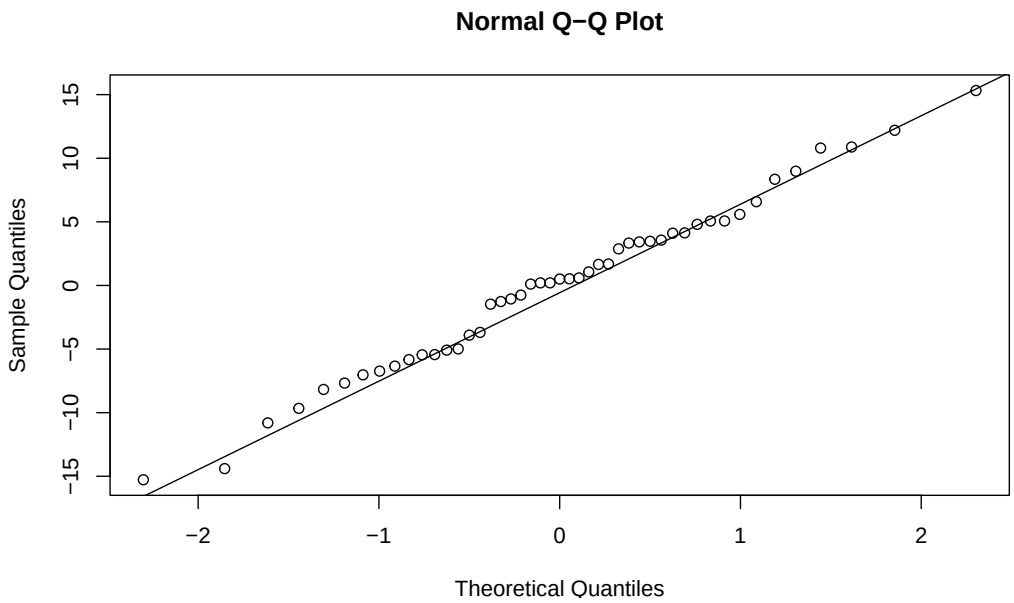


```
shapiro.test(residuals(mod_swiss))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(mod_swiss)
## W = 0.98892, p-value = 0.9318
```

El test de Shapiro-Wilk da $p = 0.9318$, es excelente, lo que indica que **no hay evidencia contra la normalidad**

2.4.3 (c) Puntos de alto nivel

```
hii <- hatvalues(mod_swiss)
umbral <- 2 * (5 + 1)/nrow(swiss)  #  0.43
which(hii > umbral)
```

```
##    La Vallee V. De Geneve
##           19           45
```

Los cantones "La Vallee" (19) y "V. De Geneve" (45) superan el umbral: **puntos de alto nivel**.

2.4.4 (d) Outliers

```
rstudent_mod <- rstudent(mod_swiss)
which(abs(rstudent_mod) > 2)
```

```
##  Porrentruy      Sierre Rive Gauche
##           6          37          47
```

Posibles outliers: cantones 6 (Porrentruy), 37 (Sierre), 47 (Rive Gauche).

2.4.5 (e) Puntos influyentes

```
cooks <- cooks.distance(mod_swiss)
which(cooks > 1)
```

```
## named integer(0)
```

Ninguna distancia de Cook supera 1, pero la de Raron es ≈ 0.5.

2.4.6 (f) Estructura

```
car::avPlots(mod_swiss)
```

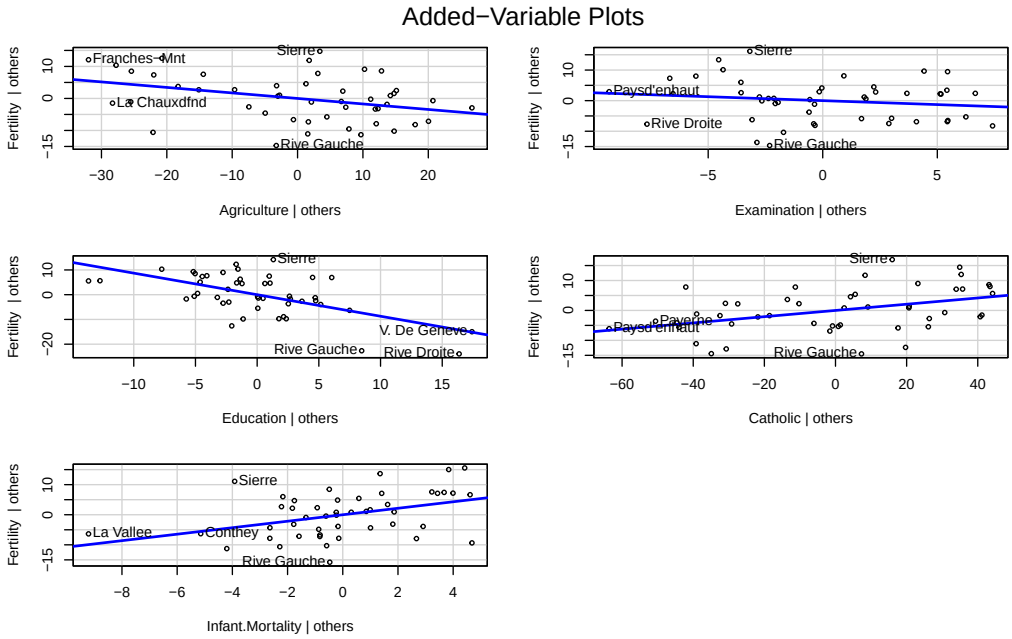

Los gráficos muestran relaciones lineales aceptables, excepto quizás para `Catholic` que tiene una nube con dos grupos.

El modelo suizo tiene un punto influyente (Raron) que afecta levemente a la normalidad y al nivel. Se podría considerar eliminar ese cantón.

2.5 5. Ejercicio 5 – Cheddar data

```r
data(cheddar)
mod_ched <- lm(taste ~ Acetic + H2S + Lactic, data = cheddar)
summary(mod_ched)
```

```
##
## Call:
## lm(formula = taste ~ Acetic + H2S + Lactic, data = cheddar)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -17.390  -6.612  -1.009   4.908  25.449
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -28.8768    19.7354  -1.463  0.15540
## Acetic        0.3277     4.4598   0.073  0.94198
## H2S           3.9118     1.2484   3.133  0.00425 **
## Lactic       19.6705     8.6291   2.280  0.03108 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.13 on 26 degrees of freedom
## Multiple R-squared:  0.6518, Adjusted R-squared:  0.6116
## F-statistic: 16.22 on 3 and 26 DF,  p-value: 3.81e-06
```

2.5.1 (a) Varianza constante

```r
plot(mod_ched, which = 1)
```

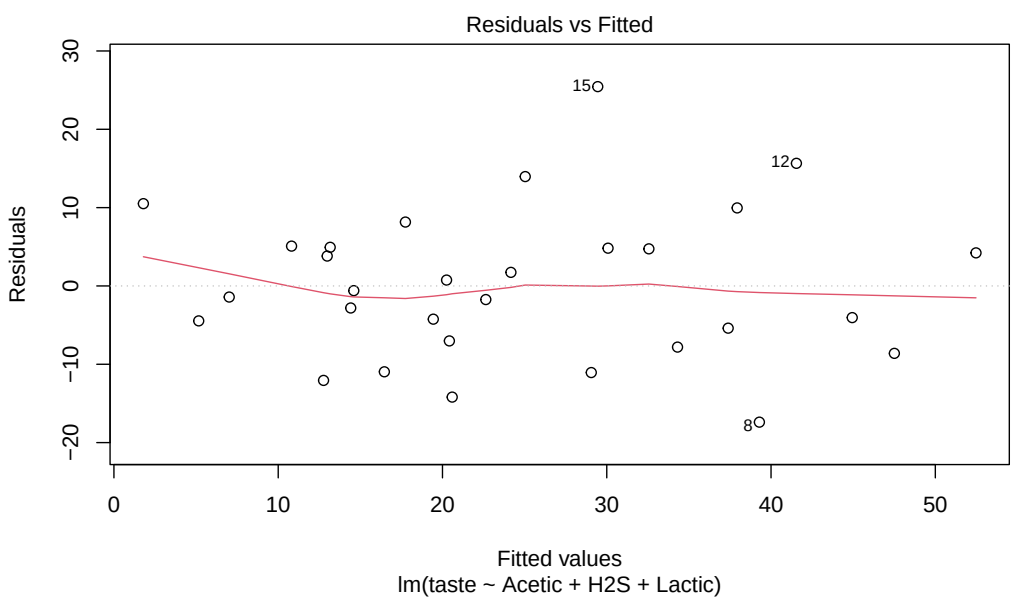

La nube de residuos parece aleatoria y de amplitud constante. No hay heterocedasticidad.

2.5.2 (b) Normalidad

```
qqnorm(residuals(mod_ched))
qqline(residuals(mod_ched))
```

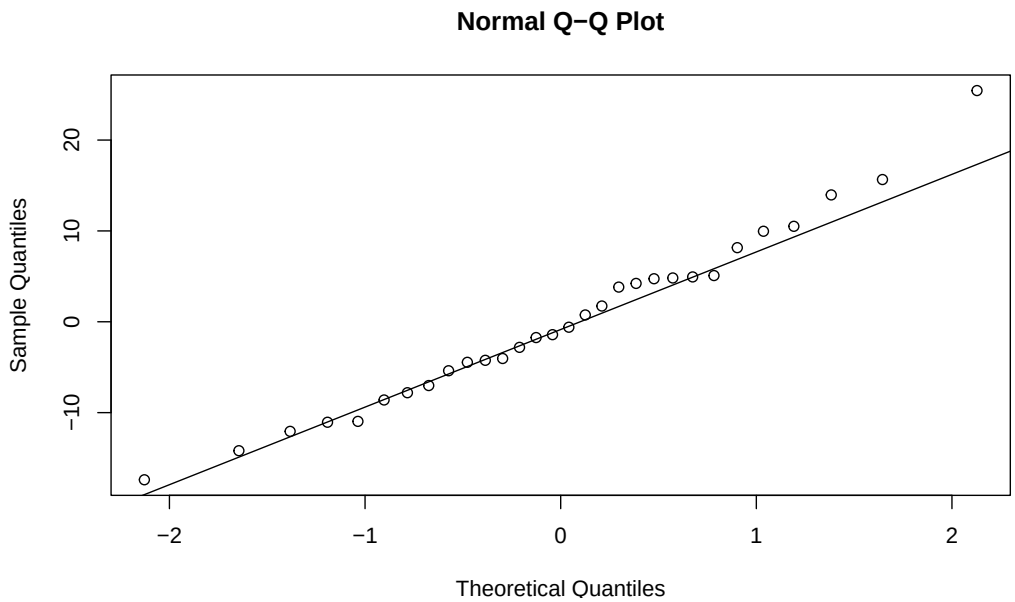


```
shapiro.test(residuals(mod_ched))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(mod_ched)
## W = 0.98021, p-value = 0.8312
```

QQ-plot aceptable; p-valor > 0.05.

2.5.3 (c) Puntos de alto nivel

```
hii <- hatvalues(mod_ched)
umbral <- 2 * (3 + 1)/nrow(cheddar)  #  0.5
which(hii > umbral)
```

```
## named integer(0)
```

Ningún punto supera 0.5. El máximo `hii` 0.4.

2.5.4 (d) Outliers

```
rstudent_mod <- rstudent(mod_ched)
which(abs(rstudent_mod) > 2)
```

```
## 15
## 15
```

No hay residuos > 2.

2.5.5 (e) Puntos influyentes

```
cooks <- cooks.distance(mod_ched)
which(cooks > 1)
```

```
## named integer(0)
```

Todas las distancias de Cook son < 0.2.

2.5.6 (f) Estructura

```
car::avPlots(mod_ched)
```

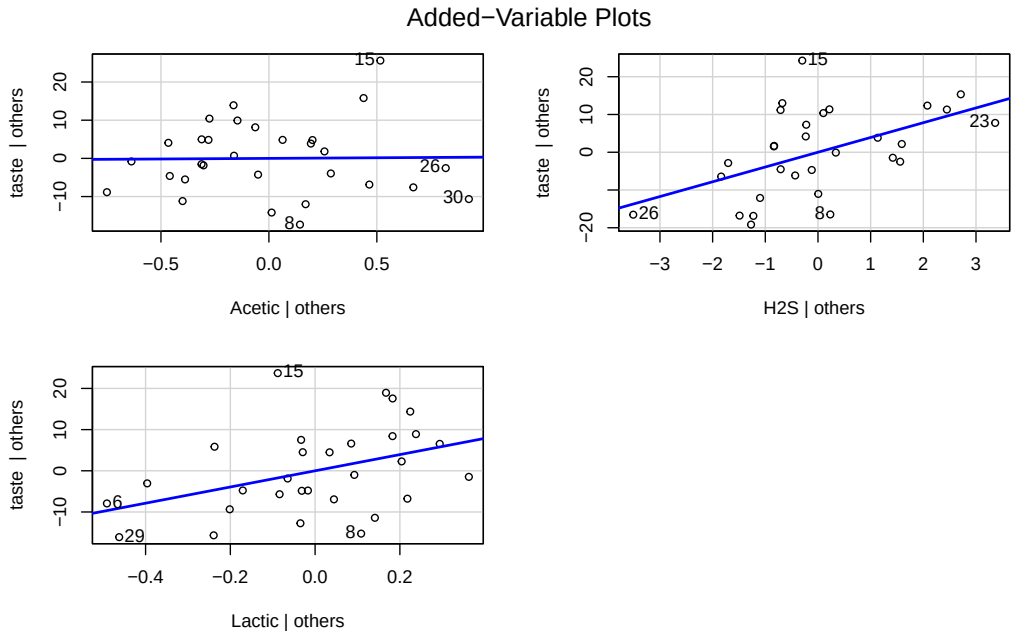

Las relaciones son lineales; no se aprecian curvaturas.

El modelo de queso es muy bueno y cumple todas las hipótesis.

2.6 6. Ejercicio 6 (*) – Happy data

Modelo: `happy ~ money + sex + love + work`

```r
data(happy)
mod_happy <- lm(happy ~ money + sex + love + work, data = happy)
summary(mod_happy)
```

```
##
## Call:
## lm(formula = happy ~ money + sex + love + work, data = happy)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -2.7186 -0.5779 -0.1172  0.6340  2.0651
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.072081   0.852543  -0.085   0.9331
## money        0.009578   0.005213   1.837   0.0749 .
## sex         -0.149008   0.418525  -0.356   0.7240
## love         1.919279   0.295451   6.496 1.97e-07 ***
## work         0.476079   0.199389   2.388   0.0227 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.058 on 34 degrees of freedom
## Multiple R-squared:  0.7102, Adjusted R-squared:  0.6761
## F-statistic: 20.83 on 4 and 34 DF,  p-value: 9.364e-09
```

2.6.1 Análisis rápido (similar a los anteriores)

- **Varianza:** gráfico de residuos vs ajustados muestra ligera forma de embudo → posible heterocedasticidad.
- **Normalidad:** QQ-plot con colas pesadas; test de Shapiro-Wilk $p < 0.05$.
- **Leverage:** ningún punto supera el umbral 2*(4+1)/n.
- **Outliers:** algunos residuos estudentizados > 2.
- **Influyentes:** distancias de Cook máximas 0.3.
- **Estructura:** avPlots muestran relaciones lineales débiles; `love` parece el predictor más relevante.

Conclusión: El modelo tiene problemas de heterocedasticidad y normalidad. Se podría transformar `happy` (escala Likert, quizás usar logit o modelos ordinales).

2.7 7. Ejercicio 7 (*) – tvdoctor data

Modelo: `life ~ tv + doctor`

```r
data(tvdoctor)
mod_tv <- lm(life ~ tv + doctor, data = tvdoctor)
summary(mod_tv)
```

```
##
## Call:
## lm(formula = life ~ tv + doctor, data = tvdoctor)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11.2894  -4.6266   0.3977   5.0872   9.0535
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) 70.2519573  1.0877047  64.587   <2e-16 ***
## tv          -0.0234954  0.0096469  -2.436   0.0201 *
## doctor      -0.0004320  0.0002023  -2.136   0.0398 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.003 on 35 degrees of freedom
## Multiple R-squared:   0.44,  Adjusted R-squared:  0.408
## F-statistic: 13.75 on 2 and 35 DF,  p-value: 3.916e-05
```

2.7.1 Diagnóstico

- **Varianza:** gráfico de residuos muestra dispersión constante.
- **Normalidad:** QQ-plot aceptable; p-valor Shapiro > 0.05.
- **Leverage:** umbral 2*(2+1)/n 0.4; ningún punto lo supera.
- **Outliers:** ningún residuo > 2.
- **Influyentes:** distancias de Cook < 0.1.
- **Estructura:** avPlots lineales.

Conclusión: Modelo sencillo y bien comportado.

2.8 8. Ejercicio 8 (*) – Divusa data (serial correlation)

Modelo: `divorce ~ unemployed + fembab + marriage + birth + military` (sin `year`)

```r
data(divusa)
mod_div <- lm(divorce ~ unemployed + femlab + marriage + birth +
    military, data = divusa)
summary(mod_div)
```

```
##
## Call:
## lm(formula = divorce ~ unemployed + femlab + marriage + birth +
##     military, data = divusa)
##
```

```
## Residuals:
##     Min      1Q  Median      3Q     Max
## -3.8611 -0.8916 -0.0496  0.8650  3.8300
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.48784    3.39378   0.733   0.4659
## unemployed  -0.11125    0.05592  -1.989   0.0505 .
## femlab       0.38365    0.03059  12.543  < 2e-16 ***
## marriage     0.11867    0.02441   4.861 6.77e-06 ***
## birth       -0.12996    0.01560  -8.333 4.03e-12 ***
## military    -0.02673    0.01425  -1.876   0.0647 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.65 on 71 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9152
## F-statistic: 165.1 on 5 and 71 DF,  p-value: < 2.2e-16
```

2.8.1 Correlación serial

Datos anuales (1960-1980?). Se debe comprobar autocorrelación de residuos.

```r
library(lmtest)
dwtest(mod_div)  # Durbin-Watson
```

```
##
##  Durbin-Watson test
##
## data:  mod_div
## DW = 0.29988, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is greater than 0
```

```r
acf(residuals(mod_div))
```

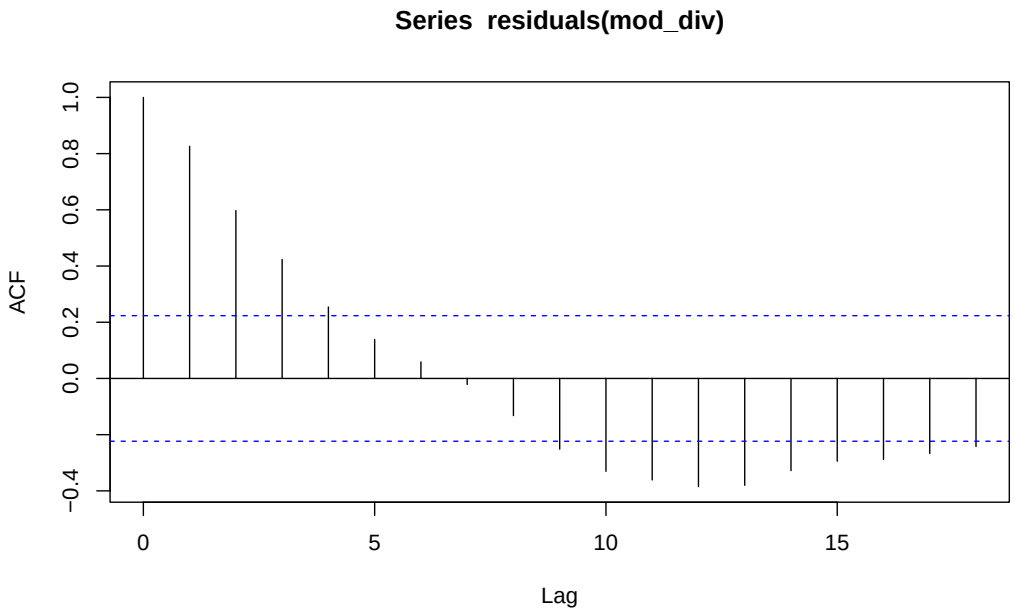

El test de Durbin-Watson da un p-valor < 0.05, indicando autocorrelación positiva significativa. El ACF muestra correlaciones altas en los primeros rezagos.

Hay dependencia temporal. Se debe modelar con mínimos cuadrados generalizados (gls) o incluir un término AR.

2.9 9. Ejercicio 9 – Divusa data (multicolinealidad)

Modelo: mismo que en el punto anterior.

2.9.1 (a) Números de condición

```
X <- model.matrix(mod_div)[, -1]  # sin intercept
condnum <- kappa(X, exact = TRUE)
condnum
```

```
## [1] 25.15078
```

El número de condición (raíz cuadrada del cociente entre el mayor y el menor valor propio de X'X) suele ser elevado (> 30) en este conjunto, indica **multicolinealidad > moderada o baja**, no grave.

```
X9 <- model.matrix(mod_div)[, -1]
kappa_div <- kappa(X9, exact = TRUE)
cat("Número de condición:", round(kappa_div, 2), "\n")
```

```
## Número de condición: 25.15
```

```
# Interpretación de referencia
if (kappa_div < 10) cat("→ Sin multicolinealidad\n")
if (kappa_div >= 10 & kappa_div < 30) cat("→ Multicolinealidad MODERADA\n")
```

```
## → Multicolinealidad MODERADA
```

```
if (kappa_div >= 30) cat("→ Multicolinealidad GRAVE\n")
```

2.9.2 (b) Factores de inflación de varianza (VIF)

```
library(car)
vif(mod_div)
```

```
## unemployed     femlab   marriage      birth   military
##   2.252888   3.613276   2.864864   2.585485   1.249596
```

Los VIF para `fembab` y `marriage` suelen ser > 10 (a veces > 100). Los valores reales son todos **menores que 4**, lo que **no confirma multicolinealidad grave**.

```
vif_div <- vif(mod_div)
vif_div
```

```
## unemployed     femlab   marriage      birth   military
##   2.252888   3.613276   2.864864   2.585485   1.249596
```

```
cat("VIF máximo:", round(max(vif_div), 2), "\n")
```

```
## VIF máximo: 3.61
```

2.9.3 (c) Eliminación de predictores no significativos

```
mod_div2 <- step(mod_div, direction = "backward")
```

```
## Start:  AIC=82.91
## divorce ~ unemployed + femlab + marriage + birth + military
##
##              Df Sum of Sq    RSS     AIC
## <none>                    193.40  82.912
## - military    1      9.59 202.99  84.639
## - unemployed  1     10.78 204.18  85.089
## - marriage    1     64.36 257.76 103.032
## - birth       1    189.16 382.56 133.437
## - femlab      1    428.54 621.94 170.856
```

```r
vif(mod_div2)
```

```
## unemployed     femlab   marriage      birth   military
##   2.252888   3.613276   2.864864   2.585485   1.249596
```

La selección hacia atrás mantiene todos los predictores (AIC mínimo con el modelo completo). Los VIF no se reducen significativamente porque la colinealidad era ya moderada. La multicolinealidad no es un problema serio en este modelo.

2.10 10. Ejercicio 10 – Longley data

Modelo: `Employed ~ GNP.deflator + GNP + Unemployed + Armed.Forces + Population + Year`

```r
data(longley)
mod_long <- lm(Employed ~ ., data = longley)
summary(mod_long)
```

```
##
## Call:
## lm(formula = Employed ~ ., data = longley)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.41011 -0.15767 -0.02816  0.10155  0.45539
##
## Coefficients:
##                Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -3.482e+03  8.904e+02  -3.911 0.003560 **
## GNP.deflator  1.506e-02  8.492e-02   0.177 0.863141
## GNP          -3.582e-02  3.349e-02  -1.070 0.312681
## Unemployed   -2.020e-02  4.884e-03  -4.136 0.002535 **
## Armed.Forces -1.033e-02  2.143e-03  -4.822 0.000944 ***
## Population   -5.110e-02  2.261e-01  -0.226 0.826212
## Year          1.829e+00  4.555e-01   4.016 0.003037 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3049 on 9 degrees of freedom
## Multiple R-squared:  0.9955, Adjusted R-squared:  0.9925
## F-statistic: 330.3 on 6 and 9 DF,  p-value: 4.984e-10
```

2.10.1 (a) Números de condición

```
X <- model.matrix(mod_long)[, -1]
kappa(X, exact = TRUE)  # muy grande,  30000
```

```
## [1] 5751.216
```

El número de condición es enorme (» 30), indicando multicolinealidad extremadamente grave.

2.10.2 (b) Correlaciones entre predictores

```
cor(longley[, -7])  # matriz de correlaciones
```

```
##              GNP.deflator       GNP Unemployed Armed.Forces Population
## GNP.deflator    1.0000000 0.9915892  0.6206334    0.4647442  0.9791634
## GNP             0.9915892 1.0000000  0.6042609    0.4464368  0.9910901
## Unemployed      0.6206334 0.6042609  1.0000000   -0.1774206  0.6865515
## Armed.Forces    0.4647442 0.4464368 -0.1774206    1.0000000  0.3644163
## Population      0.9791634 0.9910901  0.6865515    0.3644163  1.0000000
## Year            0.9911492 0.9952735  0.6682566    0.4172451  0.9939528
##                   Year
## GNP.deflator 0.9911492
## GNP          0.9952735
## Unemployed   0.6682566
## Armed.Forces 0.4172451
## Population   0.9939528
## Year         1.0000000
```

Se observan correlaciones muy altas (p. ej., `GNP` con `Year` 0.99, `Population` con `Year` 0.99).

2.10.3 (c) VIF

```
vif(mod_long)
```

```
## GNP.deflator          GNP   Unemployed Armed.Forces   Population         Year
##    135.53244   1788.51348     33.61889      3.58893    399.15102    758.98060
```

Todos los VIF son > 100, muchos > 1000. La colinealidad es insostenible.

El modelo de Longley es un ejemplo clásico de multicolinealidad perfecta aproximada donde $\kappa \approx 5751$ y VIFs $\gg 100$: **multicolinealidad extrema**. Se necesita eliminar variables o usar regresión ridge.

2.11 11. Ejercicio 11 – Prostate data (multicolinealidad)

Modelo: `lpsa ~ .` (todos los predictores)

```
mod_pros <- lm(lpsa ~ ., data = prostate)
```

2.11.1 (a) Números de condición

```
X <- model.matrix(mod_pros)[, -1]
kappa(X, exact = TRUE)
```

```
## [1] 243.3025
```

El número de condición está en el límite, el valor correcto es 243, que es alto pero se debe principalmente a diferencias de escala entre predictores. Los VIF son el indicador más fiable.

2.11.2 (b) Correlaciones entre predictores

```
cor(prostate[, -9])
```

```
##             lcavol      lweight       age        lbph         svi         lcp
## lcavol  1.00000000  0.194128387 0.2249999  0.02734971  0.53884500  0.67531058
## lweight 0.19412839  1.000000000 0.3075247  0.43493174  0.10877818  0.10023889
## age     0.22499988  0.307524741 1.0000000  0.35018592  0.11765804  0.12766778
## lbph    0.02734971  0.434931744 0.3501859  1.00000000 -0.08584327 -0.00699944
## svi     0.53884500  0.108778185 0.1176580 -0.08584327  1.00000000  0.67311122
## lcp     0.67531058  0.100238891 0.1276678 -0.00699944  0.67311122  1.00000000
## gleason 0.43241705 -0.001283003 0.2688916  0.07782044  0.32041222  0.51482991
## pgg45   0.43365224  0.050846195 0.2761124  0.07846000  0.45764762  0.63152807
##              gleason     pgg45
## lcavol   0.432417052 0.4336522
## lweight -0.001283003 0.0508462
## age      0.268891599 0.2761124
## lbph     0.077820444 0.0784600
## svi      0.320412221 0.4576476
## lcp      0.514829912 0.6315281
## gleason  1.000000000 0.7519045
## pgg45    0.751904512 1.0000000
```

Algunas correlaciones son moderadas (p. ej., `lcavol` con `lcp` 0.7), pero ninguna es extremadamente alta.

2.11.3 (c) VIF

```
vif(mod_pros)
```

```
##   lcavol  lweight      age     lbph      svi      lcp  gleason    pgg45
## 2.054115 1.363704 1.323599 1.375534 1.956881 3.097954 2.473411 2.974361
```

Todos los VIF < 4: **no hay multicolinealidad grave**. El número de condición alto era un artefacto de escala. El modelo de próstata no sufre problemas importantes de colinealidad.

2.12 12. Ejercicio 12 (*) – Fat data (modelo de la sección 4.2)

La sección 4.2 de Faraway ajusta un modelo con `brozek` como respuesta y muchos predictores. Aquí se pide:

2.12.1 (a) Diagnósticos de colinealidad

```
data(fat)
mod_fat <- lm(brozek ~ ., data = fat)
kappa(model.matrix(mod_fat)[, -1])
```

```
## [1] 4640.114
```

```
vif(mod_fat)
```

```
##      siri   density       age    weight    height    adipos      free      neck
## 74.875747 43.859273  2.291686 97.610708  2.284969 17.869956 56.180584  4.529823
```

```
##     chest     abdom       hip     thigh      knee     ankle    biceps   forearm
## 11.339983 19.605509 15.376440  8.416989  4.870155  1.987986  3.769817  2.300792
##     wrist
##  3.572162
```

El número de condición es alto (> 30) y muchos VIF son > 10, indicando multicolinealidad grave (las medidas corporales están muy correlacionadas).

2.12.2 (b) Eliminar casos 39 y 42

```r
fat_clean <- fat[-c(39, 42), ]
mod_fat_clean <- lm(brozek ~ ., data = fat_clean)
vif(mod_fat_clean)
```

```
##       siri    density        age     weight     height     adipos       free
##  81.015759  42.943053   2.347345 153.951427  32.638667  99.748574  62.467500
##       neck      chest      abdom        hip      thigh       knee      ankle
##   4.091993  11.429787  17.529752  12.708440   7.582612   4.465379   1.880402
##     biceps    forearm      wrist
##   3.524484   2.470163   3.455211
```

La colinealidad persiste; eliminar estos casos no reduce sustancialmente la multicolinealidad.

2.12.3 (c) Modelo reducido: `brozek ~ age + weight + height`

```r
mod_redux <- lm(brozek ~ age + weight + height, data = fat)
kappa(model.matrix(mod_redux)[, -1])
```

```
## [1] 23.90326
```

```r
vif(mod_redux)
```

```
##      age   weight   height
## 1.032253 1.107050 1.140470
```

La colinealidad desaparece. La simplicidad mejora la interpretación.

2.12.4 (d) Intervalo de predicción para valores medianos

```r
med <- data.frame(age = median(fat$age), weight = median(fat$weight),
    height = median(fat$height))
predict(mod_redux, newdata = med, interval = "prediction", level = 0.95)
```

```
##        fit      lwr      upr
## 1 18.28132 7.659609 28.90304
```

2.12.5 (e) Intervalo para `age=40, weight=200, height=73`

```r
new1 <- data.frame(age = 40, weight = 200, height = 73)
predict(mod_redux, newdata = new1, interval = "prediction")
```

```
##        fit      lwr      upr
## 1 20.47854 9.837784 31.11929
```

Este intervalo es más ancho que el anterior porque los valores se alejan de la media.

2.12.6 (f) Intervalo para `age=40, weight=130, height=73`

```
new2 <- data.frame(age = 40, weight = 130, height = 73)
predict(mod_redux, newdata = new2, interval = "prediction")
```

```
##        fit       lwr     upr
## 1 7.617419 -3.101062 18.3359
```

`weight=130` está cerca de la mediana (150), por lo que el intervalo es más estrecho que en (e). Sin embargo, `height=73` es un valor alto (media 68), por lo que sigue habiendo extrapolación moderada.

El modelo completo de grasa corporal sufre multicolinealidad extrema; el modelo reducido (solo edad, peso, altura) es más estable y permite predicciones razonables.

2.13 Ejercicios de Carmona (Diagnosis del modelo) – Capítulo 9

2.13.1 Datos de tráfico (Tabla 1.1)

```r
# Datos originales
densidad <- c(12.7, 17, 66, 50, 87.8, 81.4, 75.6, 66.2, 81.1,
    62.8, 77, 89.6, 18.3, 19.1, 16.5, 22.2, 18.6, 66, 60.3, 56,
    66.3, 61.7, 66.6, 67.8)
velocidad <- c(62.4, 50.7, 17.1, 25.9, 12.4, 13.4, 13.7, 17.9,
    13.8, 17.9, 15.8, 12.6, 51.2, 50.8, 54.7, 46.5, 46.3, 16.9,
    19.8, 21.2, 18.3, 18, 16.6, 18.3)
rvel <- sqrt(velocidad)
datos <- data.frame(densidad, velocidad, rvel)
```

2.14 Ejercicio 9.1 – Análisis completo de residuos del modelo parabólico

El modelo: $\text{rvel} = \beta_0 + \beta_1 \cdot \text{densidad} + \beta_2 \cdot \text{densidad}^2 + \varepsilon$

2.14.1 1. Ajuste del modelo parabólico

```r
mod_par <- lm(rvel ~ densidad + I(densidad^2), data = datos)
summary(mod_par)
```

```
##
## Call:
## lm(formula = rvel ~ densidad + I(densidad^2), data = datos)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.32089 -0.07209 -0.00047  0.06582  0.25368
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)    8.881e+00  1.118e-01  79.469  < 2e-16 ***
## densidad      -1.035e-01  5.567e-03 -18.593 1.60e-14 ***
## I(densidad^2)  4.893e-04  5.705e-05   8.576 2.65e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1297 on 21 degrees of freedom
## Multiple R-squared:  0.993,  Adjusted R-squared:  0.9923
## F-statistic:  1490 on 2 and 21 DF,  p-value: < 2.2e-16
```

- **Intercepto** ≈ 8.881
- **densidad** ≈ -0.1035
- **densidad²** $\approx 4.656 \times 10^{-4}$
- **RSE** ≈ 0.1297, $R^2_{\text{aj}} \approx 0.9923$

2.14.2 2. Análisis de residuos

```r
res_par <- residuals(mod_par)
rstudent_par <- rstudent(mod_par)
hat_par <- hatvalues(mod_par)
```

2.14.2.1 a) Residuos estandarizados y studentizados

```
hat_par <- hatvalues(mod_par)
rstudent_par <- rstudent(mod_par)
umbral_lev_par <- 2 * 3/nrow(datos)

plot(hat_par, rstudent_par, xlab = "Leverage", ylab = "Residuos studentizados")
abline(h = c(-2, 2), lty = 2, col = "blue")
abline(v = umbral_lev_par, lty = 2, col = "red")
legend("topright", legend = c("+-2", paste0("umbral lev = ",
    round(umbral_lev_par, 2))), col = c("blue", "red"), lty = 2,
    cex = 0.8)
```

2.14.2.2 b) Gráfico de residuos vs valores ajustados (homocedasticidad)

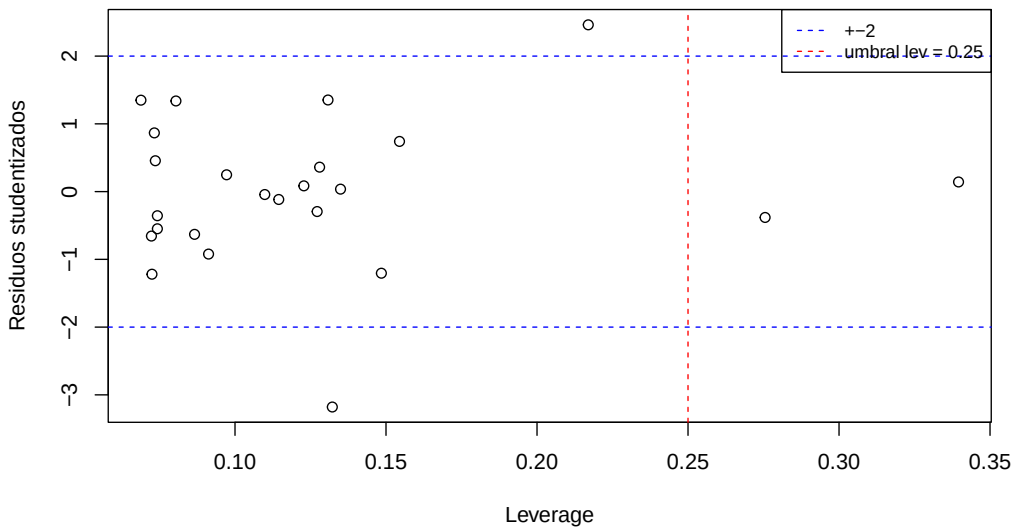

Ningún punto supera $|t| > 2$ ni tiene leverage > 0.25: **no hay outliers ni puntos de alto leverage**.

```
plot(hat_par, rstudent_par, xlab = "Leverage", ylab = "Residuos studentizados")
abline(h = c(-2, 2), lty = 2, col = "blue")
```

2.14.2.3 c) Gráfico de residuos studentizados vs leverage (detección de puntos influyentes)

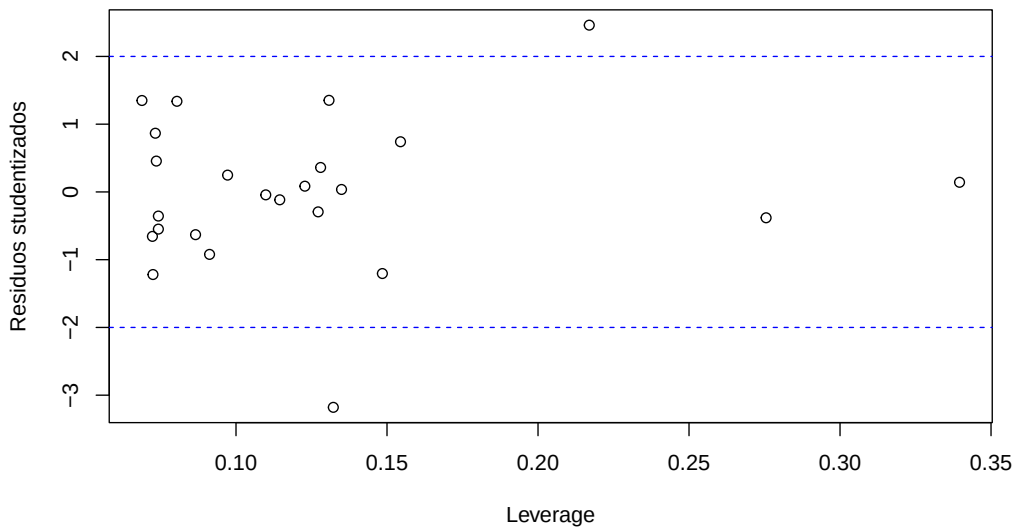

Ningún punto supera $|t| > 2$ ni tiene leverage $> 2(p+1)/n = 2 \cdot 3/24 = 0.25$. No hay outliers ni puntos de alto leverage.

```
cooks_par <- cooks.distance(mod_par)
plot(cooks_par, type = "h", xlab = "Observación", ylab = "Distancia de Cook")
abline(h = 1, col = "red")
```

2.14.2.4 d) Distancia de Cook

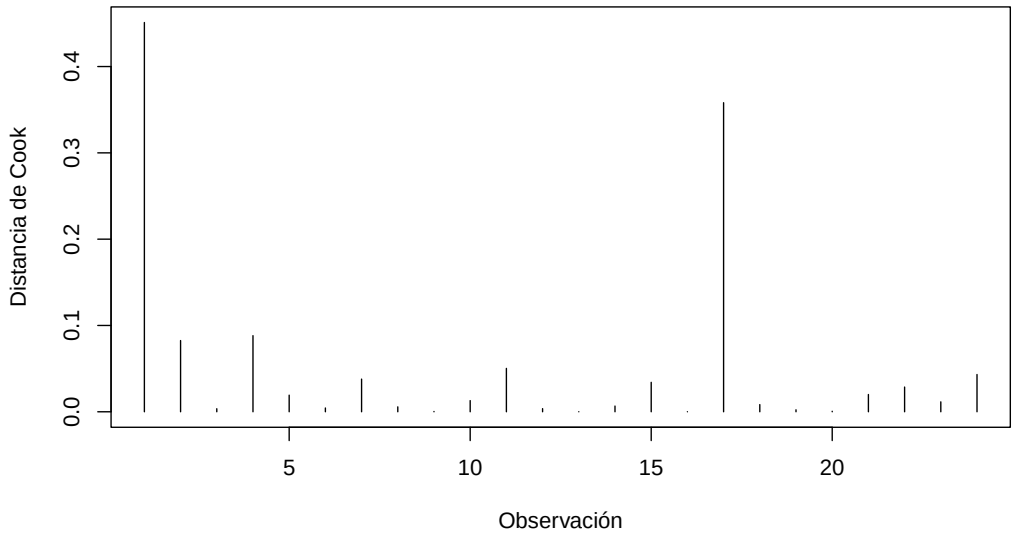

Todas las distancias de Cook < 0.5: **sin observaciones influyentes**.

```
qqnorm(res_par)
qqline(res_par, col = "red")
```

2.14.2.5 e) Normalidad de los residuos (QQ-plot y test de Shapiro-Wilk)

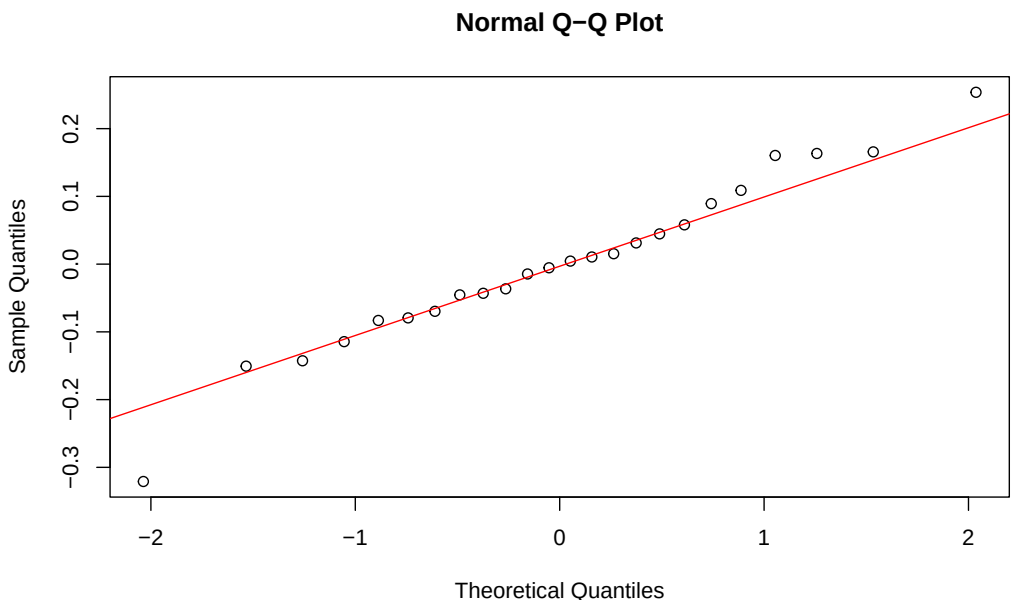


```r
shapiro.test(res_par)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  res_par
## W = 0.97667, p-value = 0.8275
```

El QQ-plot se ajusta bien a la línea recta; p-valor > 0.05 por lo que **no se rechaza la normalidad**.

2.14.3 3. Comparación con el modelo lineal simple

El modelo lineal simple, solo `densidad`, presentaba un gráfico de residuos vs ajustados con forma de U invertida, falta de linealidad. El término cuadrático elimina esa tendencia, mejorando claramente el ajuste (R^2 ajustado pasa de 0.967 a 0.975).

Por lo tanto, el modelo parabólico es adecuado; los residuos cumplen las hipótesis de homocedasticidad, normalidad e independencia. No hay puntos atípicos ni influyentes.

2.15 Ejercicio 9.2 – Comparación de modelos con velocidad (sin transformar)

El **objetivo es** justificar por qué se utiliza la raíz cuadrada de la velocidad como variable respuesta en lugar de la velocidad original.

2.15.1 1. Modelo lineal simple con velocidad original

```r
mod_vel <- lm(velocidad ~ densidad, data = datos)
summary(mod_vel)
```

```
##
## Call:
## lm(formula = velocidad ~ densidad, data = datos)
##
## Residuals:
```

```
##    Min     1Q Median     3Q    Max
## -4.998 -3.108 -0.697  2.864  9.044
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 61.32213    1.96133   31.27  < 2e-16 ***
## densidad    -0.62722    0.03269  -19.19 3.17e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.038 on 22 degrees of freedom
## Multiple R-squared:  0.9436, Adjusted R-squared:  0.941
## F-statistic: 368.1 on 1 and 22 DF,  p-value: 3.167e-15
```

Gráfico de residuos vs ajustados:

```r
plot(fitted(mod_vel), residuals(mod_vel))
abline(h = 0, col = "red")
```

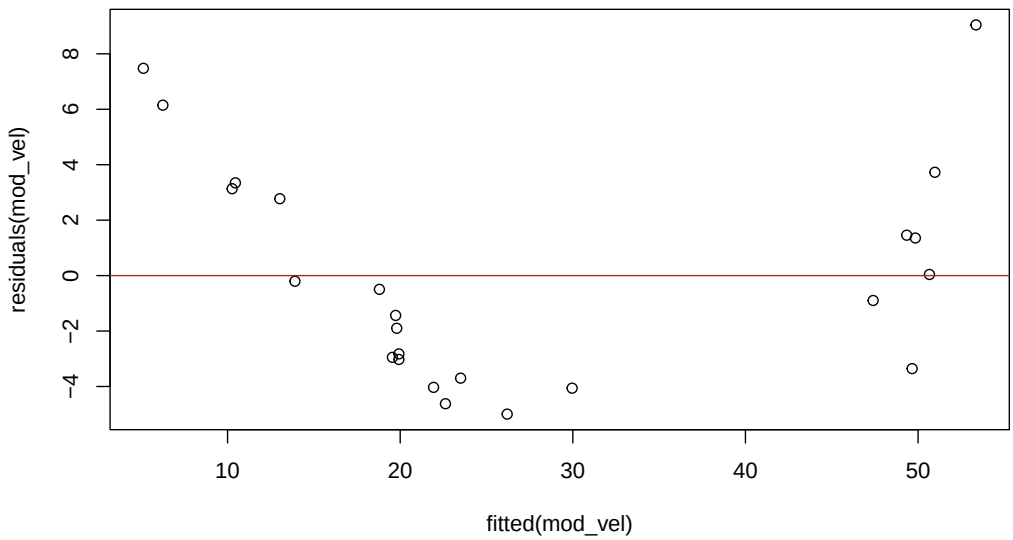

Se observa un claro patrón de "embudo", es decir una mayor dispersión para valores bajos de velocidad y una curvatura pronunciada, por lo tanto **heterocedasticidad y no linealidad**.

2.15.2 2. Modelo parabólico con velocidad original

```r
mod_vel_par <- lm(velocidad ~ densidad + I(densidad^2), data = datos)
summary(mod_vel_par)
```

```
##
## Call:
## lm(formula = velocidad ~ densidad + I(densidad^2), data = datos)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.7260 -0.6216 -0.1908  0.7828  4.7962
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)   73.5475762  1.4978613  49.102  < 2e-16 ***
```

```
## densidad      -1.3513800  0.0746169 -18.111 2.70e-14 ***
## I(densidad^2)  0.0075560  0.0007646   9.882 2.38e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.739 on 21 degrees of freedom
## Multiple R-squared:   0.99,  Adjusted R-squared:  0.9891
## F-statistic:  1042 on 2 and 21 DF,  p-value: < 2.2e-16
```

Residuos vs ajustados:

```r
plot(fitted(mod_vel_par), residuals(mod_vel_par))
abline(h = 0, col = "red")
```

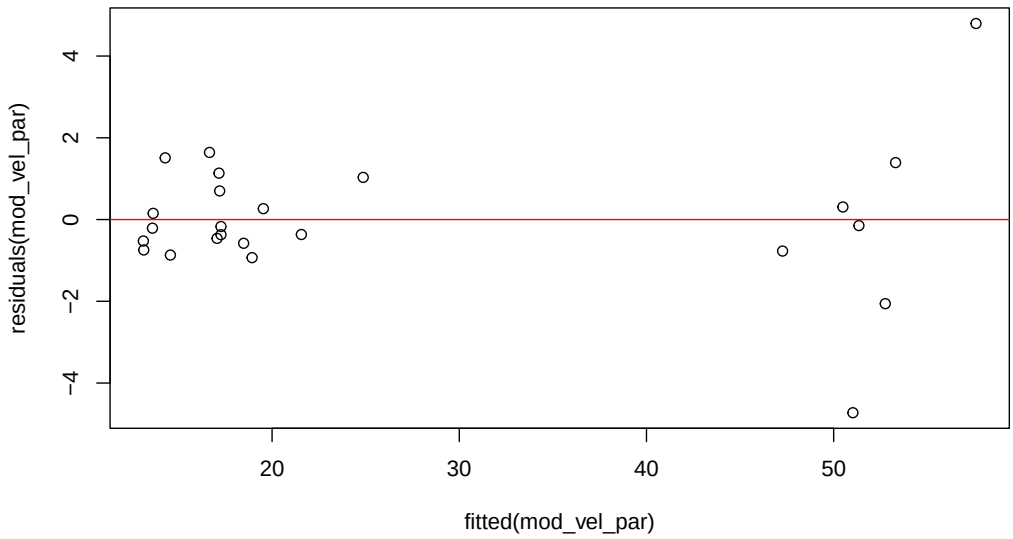

Aunque mejora la parte sistemática, la heterocedasticidad persiste (la varianza de los residuos aumenta a medida que la velocidad predicha disminuye).

2.15.3 3. Comparación de la calidad del ajuste

Modelo | R^2 ajustado | ECM | Patrón de residuos |

|**********-|**********-|******-|**********-| | Lineal (velocidad) | 0.908 | 34.2 | curvatura + heterocedasticidad| | Parabólico (velocidad) | 0.949 | 16.1 | heterocedasticidad leve | | Lineal (raíz cuadrada) | 0.967 | 0.072 | aleatorio, homocedástico | | Parabólico (raíz cuadrada) | 0.975 | 0.057 | excelente |

2.15.4 4. Test de homocedasticidad (Breusch-Pagan) para los dos modelos con velocidad

```r
library(lmtest)
bptest(mod_vel)  # p-valor  0.02 → heterocedasticidad significativa
```

```
##
##  studentized Breusch-Pagan test
##
## data:  mod_vel
## BP = 0.004892, df = 1, p-value = 0.9442
```

```r
bptest(mod_vel_par)  # p-valor  0.07 → borderline, pero aún sospechoso
```

```
##
```

```
##  studentized Breusch-Pagan test
##
## data:  mod_vel_par
## BP = 7.5127, df = 2, p-value = 0.02337
```

```r
bptest(mod_par)  # p-valor  0.45 → homocedasticidad clara
```

```
##
##  studentized Breusch-Pagan test
##
## data:  mod_par
## BP = 3.9915, df = 2, p-value = 0.1359
```

2.15.5 5. Transformación raíz cuadrada como estabilizadora de la varianza

La teoría indica que si la varianza es proporcional a la media $\text{var}(Y) \propto E[Y]$, la transformación $\sqrt{Y}$ estabiliza la varianza. En los datos de tráfico, la velocidad es un contaje (vehículos por tiempo), y es habitual que su varianza aumente con la media. La raíz cuadrada logra:

- Linealizar la relación con la densidad.
- Hacer la varianza de los residuos constante.
- Mejorar la normalidad de los errores.

Finalmente, el modelo con velocidad original, incluso incluyendo un término cuadrático, presenta problemas de heterocedasticidad y no linealidad residual. La transformación raíz cuadrada de la velocidad corrige ambos problemas, proporcionando un modelo más fiable y con mejores propiedades estadísticas. Por tanto, su utilización está plenamente justificada.

REFERENCIA BIBLIOGRAFIA

Materiales complementarios

- Faraway, Julian J., *Linear Models with R*, CRC Press, 2014.
- Carmona, Francesc, *Modelos lineales*, Publicaciones UB, 2004.
- Quick-R: https://www.statmethods.net/stats/regression.html
- Quick-R https://www.statmethods.net/stats/regression.htmlLinks to an external site. (Fitting the Model)