Diagnosis del modelo

Regresión: modelos y métodos

PID_00298355

Francesc Carmona Pontaque

Tiempo mínimo de dedicación recomendado: 3 horas

Universitat Oberta de Catalunya

Francesc Carmona Pontaque

Cómo citar este recurso de aprendizaje con el estilo Harvard:
Carmona Pontaque, F. (2024) *Diagnosis del modelo: Regresión: modelos y métodos*. [Recurso de aprendizaje textual]. 1.ª ed. Barcelona: Fundació Universitat Oberta de Catalunya (FUOC).

Primera edición: febrero 2024
© de esta edición, Fundació Universitat Oberta de Catalunya (FUOC)
Av. Tibidabo, 39-43, 08035 Barcelona
Autoría: Francesc Carmona Pontaque
Producción: FUOC
Todos los derechos reservados

Ninguna parte de esta publicación, incluido el diseño general y la cubierta, puede ser copiada, reproducida, almacenada o transmitida de ninguna forma, ni por ningún medio, sea este eléctrico, mecánico, óptico, grabación, fotocopia, o cualquier otro, sin la previa autorización escrita del titular de los derechos.

Planteamiento y objetivos

Este módulo es la continuación habitual en la mayoría de cursos de modelos lineales o de regresión, aunque parece que debería ser al revés. Recordemos que empezamos el curso planteando las condiciones de Gauss-Markov, necesarias para que los estimadores mínimo cuadráticos sean óptimos en un sentido (los mejores estimadores lineales insesgados o *BLUE*). Después extendimos las condiciones a la normalidad de los residuos (el modelo lineal "normal"), necesaria para poder hacer inferencia sobre los parámetros del modelo. Es decir, hasta el momento hemos ido suponiendo que se verifican estas condiciones. Pero ¿y si no es así? Ahora veremos cómo investigar si se verifican las suposiciones del modelo lineal normal y algunas otras relacionadas. En los módulos siguientes estudiaremos qué se puede hacer cuando las condiciones no se cumplen, como transformar los datos o utilizar métodos alternativos de regresión.

En este módulo estudiaremos la verificación *a posteriori* de las hipótesis de Gauss-Markov y de normalidad sobre el modelo lineal. Para ello se utilizan los residuos del modelo como muestra del error aleatorio desconocido.

Pregunta

Una pregunta que se formula mucho entre el alumnado es si no sería razonable comprobar las suposiciones antes de empezar a trabajar con el modelo. Como vamos a ver, muchas de las comprobaciones se hacen sobre los residuos $e_i = \hat{y}_i - y_i$, por lo que necesitamos haber estimado el modelo para calcularlos.

Un primer objetivo es entender el papel de los residuos en el diagnóstico del modelo. Aunque hasta el momento hemos trabajado con un único tipo de residuo, para realizar los diagnósticos se definen distintos tipos: residuo, residuo estandarizado, residuo studentizado y residuo studentizado externamente. Un segundo objetivo es obviamente conocerlos y comprender sus diferencias y aplicaciones.

La mayor parte de los diagnósticos pueden realizarse gráficamente o de forma numérica, mediante algún test (sobre los residuos, claro está). Es importante conocer ambas aproximaciones y saber cómo interpretar los gráficos y cómo realizar e interpretar los resultados de los tests. Observemos que estos "tests" tienen una función diferente de la de los módulos anteriores. No pretenden servir para hacer inferencias sobre el modelo, sino sobre las suposiciones del modelo.

Ventajas de los gráficos

Los gráficos pueden darnos pistas sobre el tipo de problema y su posible solución. Un p-valor no arroja ninguna luz sobre qué podemos hacer para mejorar el modelo.

Algunas de las condiciones que analizaremos al hacer el diagnóstico del modelo no están explícitas entre las condiciones de Gauss-Markov. Sin embargo, dado que su no cumplimiento puede perjudicar al modelo (a la vez que implicaría el no cumplimiento de las condiciones de Gauss-Markov), también debemos aprender a comprobarlas. Entre las dificultades a analizar se encuentran la existencia de puntos influyentes, la existencia de valores atípicos, la falta de estructura lineal del modelo y, sobre todo, la multicolinealidad (existencia de variables explicativas relacionadas linealmente entre ellas), que es la "némesis" de los modelos lineales.

A modo de resumen, los objetivos del presente módulo son:

- Saber qué condiciones deben verificarse para que las conclusiones que se extraen del análisis de un modelo lineal sean válidas.

- Comprobar de forma gráfica o numérica si se cumplen dichas suposiciones.

- Adquirir práctica en las comprobaciones utilizando el *software* adecuado.

1. Tipos de residuos

Los residuos de un modelo lineal se obtienen como diferencia entre los valores observados de la variable respuesta y las predicciones calculadas para los mismos datos. El vector de residuos es

$$\mathbf{e} = (e_1, \ldots, e_n)' = \mathbf{Y} - \widehat{\mathbf{Y}}$$

y lo podemos considerar como una muestra del conjunto de errores ϵ_i.

Con los datos de las islas Galápagos y el modelo que hemos considerado, los residuos son:

```
e <- residuals(lmod)
mean(e)
```

```
[1] 3.641344e-15
```

Media de los residuos

Aunque numéricamente se aproxima, sabemos que la media exacta de los residuos es cero. Justamente por esto no se calcula en el `summary()` de **R**.

En cuanto a la varianza, sabemos que la varianza teórica de los errores es $\text{var}(\epsilon_i) = \sigma^2$ y el estimador de σ^2 es el ECM. Entonces, se llaman *residuos estandarizados* a

$$d_i = \frac{e_i}{\sqrt{\text{ECM}}} \qquad i = 1, \ldots, n$$

que tienen media cero y varianza aproximada uno. Veamos cuál es la varianza exacta de los residuos.

El vector de residuos aleatorios es

$$\mathbf{e} = \mathbf{Y} - \widehat{\mathbf{Y}} = (\mathbf{I} - \mathbf{P})\mathbf{Y} = (\mathbf{I} - \mathbf{P})\mathbf{X}\boldsymbol{\beta} + (\mathbf{I} - \mathbf{P})\boldsymbol{\epsilon} = (\mathbf{I} - \mathbf{P})\boldsymbol{\epsilon}$$

La matriz proyección

Recordemos que la matriz proyección $\mathbf{P}$ (matriz *hat*) es $\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'$ de forma que $\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\boldsymbol{\beta}} = \mathbf{P}\mathbf{Y}$.

donde $\mathbf{P}$ es la matriz proyección. Así pues, la matriz de varianzas-covarianzas de los residuos es $\text{var}(\mathbf{e}) = \sigma^2(\mathbf{I} - \mathbf{P})$, de manera que

$$\text{var}(e_i) = \sigma^2(1 - h_{ii})$$

donde h_{ii} es el i-ésimo elemento de la diagonal de $\mathbf{P}$.

Así pues, si queremos utilizar los residuos $\mathbf{e}$ como estimaciones de los errores $\boldsymbol{\epsilon}$, es necesario mejorar su estandarización. De modo que muchos autores

recomiendan trabajar con los llamados *residuos studentizados*:

$$r_i = \frac{e_i}{[\text{ECM}(1-h_{ii})]^{1/2}} \qquad i = 1, \ldots, n$$

Además, h_{ii} es una medida de la localización del i-ésimo punto $\mathbf{x}_i$ respecto al punto medio $\bar{\mathbf{x}}$.

En la regresión lineal simple

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

En el modelo de regresión múltiple

$$h_{ii} = \frac{1}{n}[1 + (\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{S}_{\mathbf{xx}}^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})] = \frac{1}{n}(1 + D_i^2)$$

donde D_i es la llamada distancia de Mahalanobis entre $\mathbf{x}_i$ y $\bar{\mathbf{x}}$.

¡Atención!

La varianza de un error e_i depende de la posición del punto $\mathbf{x}_i$. Puntos cercanos al punto central $\bar{\mathbf{x}}$ tienen mayor varianza (pobre ajuste mínimocuadrático) que los puntos alejados.

Como las violaciones de las hipótesis del modelo son más probables en los puntos remotos pero más difíciles de detectar con los residuos e_i (o con los d_i) –porque los residuos son menores–, es mejor trabajar con los residuos r_i, ya que $\text{var}(r_i) = 1$ constante, desde el punto de vista de la localización de los $\mathbf{x}_i$.

Para n grande se puede trabajar con los d_i o con los r_i. Pero como valores altos de e_i y de h_{ii} pueden indicar un punto de alta influencia en el ajuste MC, se recomienda la utilización de los residuos studentizados r_i. Estos residuos se utilizarán en el diagnóstico de valores atípicos.

En **R** los residuos r_i se calculan con la función `rstandard()`.

La función
`hatvalues()`

Esta función calcula los valores h_{ii} de la diagonal de la matriz proyección $\mathbf{P}$.

```
h.ii <- hatvalues(lmod)
resid.stud <- residuals(lmod)/sqrt(summary(lmod)$sigma^2*(1-h.ii))
resid.stud[1:5]
```

```
    Baltra  Bartolome   Caldwell   Champion    Coamano
-1.0034157  0.6584815 -0.4459436  0.2492158  0.6904609
```

```
rstandard(lmod)[1:5]
```

```
    Baltra  Bartolome   Caldwell   Champion    Coamano
```

```
-1.0034157  0.6584815 -0.4459436  0.2492158  0.6904609
```

Para calcular los residuos studentizados r_i hemos utilizado ECM como estimador de la varianza σ^2. Se trata de una estimación *interna*, puesto que para calcularla se utilizan todos los n puntos.

Otra aproximación consiste en estimar σ^2 con el conjunto de datos sin la i-ésima observación. Sea $s^2_{(i)}$ la estimación de σ^2 así obtenida. Una para cada punto. Si utilizamos estos estimadores de σ^2 en lugar de ECM, tenemos los llamados *residuos studentizados externamente*:

$$t_i = \frac{e_i}{[s^2_{(i)}(1-h_{ii})]^{1/2}} \qquad i = 1, \ldots, n \tag{1}$$

La función `influence()`

Esta función calcula, entre otras cosas, el vector de estimaciones $s_{(i)}$ con `influence(lmod)$sigma`

En la mayoría de situaciones, los residuos t_i no diferirán de los residuos studentizados r_i. Sin embargo, si la i-ésima observación es influyente, entonces $s^2_{(i)}$ puede ser significativamente distinto de ECM y el estadístico t_i será más sensible para este punto.

Bajo las hipótesis estándar $t_i \sim t_{n-p-2}$, de modo que podemos considerar un procedimiento formal para la detección de valores atípicos mediante el contraste de hipótesis y utilizando algún método múltiple. En la práctica, un diagnóstico sencillo es considerar que un residuo es atípico (*outlier*) si $|t_i| > 2$.

Además, la detección de los valores atípicos está ligada a la detección de puntos influyentes.

Los residuos t_i se obtienen en **R** con la función `rstudent()`.

```
rstudent(lmod)[1:5]
```

```
    Baltra  Bartolome   Caldwell   Champion    Coamano
-1.0035650  0.6505203 -0.4383743  0.2442848  0.6827383
```

Con el criterio sencillo, las islas atípicas son

```
rownames(gala)[abs(rstudent(lmod))>2]
```

```
[1] "Isabela"   "Pinta"     "SantaCruz"
```

Siguiendo con la misma idea, también podemos calcular los residuos en función de las predicciones calculadas con el modelo de regresión sin la i-ésima observación (*leave-one-out cross validation residuals*). Sean $e_{(i)}$ los residuos así obtenidos, entonces su suma de cuadrados es

$$\text{PRESS} = \sum_{i=1}^{n} e_{(i)}^2$$

y se llama *prediction error sum of squares*. También algunos autores llaman *error cuadrático de validación* a esta suma de cuadrados por ser una medida externa de la precisión del modelo.

En **R**, los residuos $e_{(i)}$ se calculan así

```
rstandard(lmod, type="pred")[1:4]
```

```
   Baltra Bartolome  Caldwell  Champion
-63.74382  42.12105 -28.08048  15.77767
```

¡Atención!

Observemos que la función `rstandard()` con la opción `type="pred"` obtiene los residuos $e_{(i)}$ sin estandarizar.

y el error cuadrático de validación es

```
PRESS <- sum(rstandard(lmod, type="pred")^2)
```

Se puede comprobar que

$$e_{(i)} = \frac{e_i}{1-h_{ii}} \qquad \text{var}(e_{(i)}) = \frac{\sigma^2}{1-h_{ii}} \tag{2}$$

de modo que la estandarización de estos residuos

$$\frac{e_{(i)}}{[\text{var}(e_{(i)})]^{1/2}} = \frac{e_i}{[\sigma^2(1-h_{ii})]^{1/2}}$$

también depende del estimador que utilicemos para estimar σ^2. Si utilizamos el estimador interno ECM, recuperamos los residuos studentizados r_i y si utilizamos el estimador externo $s_{(i)}^2$ obtenemos los residuos studentizados externamente t_i.

```
residuals(lmod)[1:4]/(1-h.ii[1:4])
```

```
   Baltra Bartolome  Caldwell  Champion
-63.74382  42.12105 -28.08048  15.77767
```

Los residuos asociados con puntos para los que h_{ii} sea grande, tendrán residuos $e_{(i)}$ grandes. Estos puntos serán puntos de alta influencia. Una gran diferencia entre el residuo ordinario e_i y el residuo $e_{(i)}$ indicará un punto en el que el modelo, con ese punto, se ajusta bien a los datos, pero un modelo construido sin ese punto "predice" pobremente.

2. Gráficos con los residuos

Algunos gráficos de los residuos nos van a ayudar en el diagnóstico del modelo aplicado.

En primer lugar, el análisis de datos univariante de los residuos y, en particular, los gráficos como histogramas, diagramas de caja, diagramas de tallo y hojas, etc., nos mostrarán algunos detalles. Por ejemplo, en el diagrama de caja podemos estudiar la centralidad, la simetría y la presencia de valores atípicos.

Nota

Los valores atípicos en un diagrama de caja son los que superan los márgenes $[Q_1 - 1.5 \cdot \text{IQR}, Q_3 + 1.5 \cdot \text{IQR}]$. En un modelo correcto es mejor utilizar el criterio $|t_i| > 2$.

```
boxplot(residuals(lmod), horizontal=T, main="Boxplot",
                         xlab="Residuos")
```

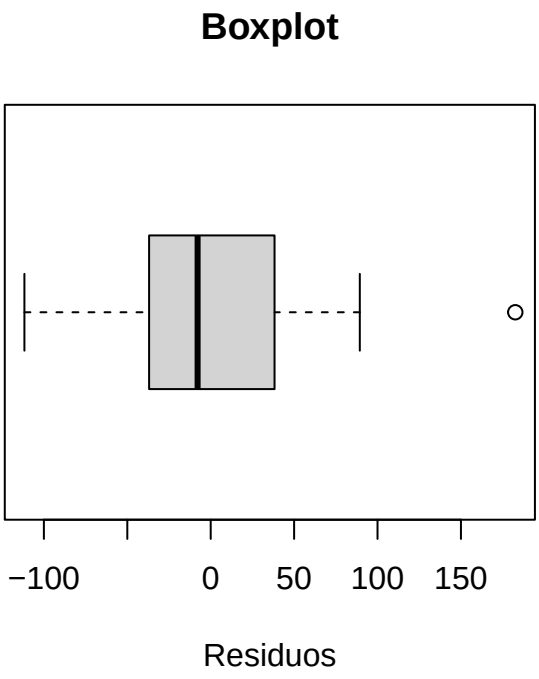

Otros gráficos adecuados para el análisis de la regresión son:

- Gráfico de dispersión de los residuos respecto al índice $i = 1, \ldots, n$.

  Este diagrama puede indicar algún tipo de correlación no deseada entre los residuos o alguna agrupación contraria a la supuesta aleatoriedad (figura 2 a).

- Gráfico de los residuos versus los datos de la variable respuesta.

  Permite observar los residuos desde los valores observados de la variable respuesta.

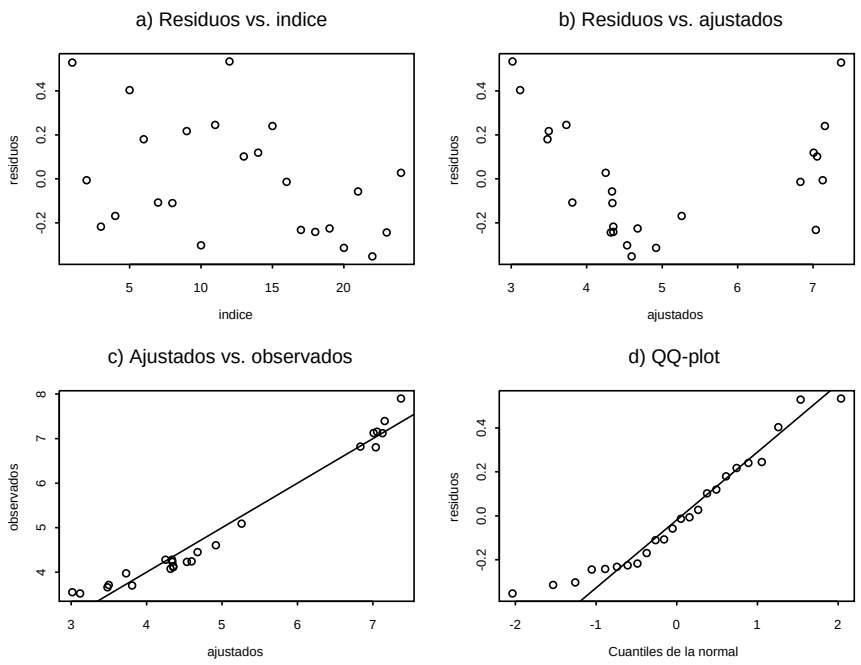

Figura 2: Algunos gráficos en el análisis de una regresión.

- Gráfico de los residuos versus los valores ajustados.

  Este gráfico es muy importante porque debe mostrar una total aleatoriedad. La dispersión horizontal no debe presentar ninguna tendencia. Una curvatura indica la violación del supuesto de linealidad del modelo, como vemos en el caso de la figura 2 b. Una forma triangular indica una posible heterogeneidad o violación de la hipótesis de varianza constante de los errores.

- Gráficos de los residuos versus las observaciones de la variable o variables regresoras.

  Sirven para detectar si las variables regresoras o explicativas han de incluirse en el modelo con alguna transformación no lineal.

- Gráfico de los valores observados versus los valores ajustados.

  La proximidad de los puntos a la bisectriz muestra el ajuste de la regresión (figura 2 c).

- Gráfico de los cuantiles de la distribución normal o QQ-plot y gráfico de las probabilidades acumuladas de la distribución normal o PP-plot.

  Con estos gráficos se pretende visualizar el ajuste de la distribución muestral de los residuos a la ley normal. En el QQ-plot se dibujan los puntos asociados a los cuantiles de la distribución normal (estándar en **R** o sin

estandarizar como en SPSS). En el PP-plot se dibujan las probabilidades acumuladas estimadas y teóricas para la distribución normal. En ambos casos se dibuja también una recta que representa el ajuste perfecto a la distribución normal. Los desvíos exagerados de dichas rectas indican una posible violación de la hipótesis de normalidad (figura 2 d).

El estudio de la normalidad de los residuos se debe completar con algún contraste de ajuste como la prueba ji-cuadrado, el test de Kolmogorov o el test de Shapiro-Wilk.

A continuación veremos la utilización de algunos de estos gráficos con más detalle. También mostraremos algunos test y otras técnicas para identificar y corregir los posibles problemas con las hipótesis del modelo lineal.

3. Varianza constante

Esta es una de las condiciones más importantes del modelo lineal. La llamada *heterocedasticidad* o falta de varianza constante para los errores es una situación no deseable que debe ser detectada y, a ser posible, corregida.

El mejor gráfico para detectar este problema es el de los residuos versus los valores ajustados. Si todo es correcto, debemos ver una variabilidad constante u *homocedasticidad* a lo largo del eje de los valores ajustados. Cualquier forma de la nube de puntos que no sea aleatoria y uniforme, significa algún tipo de violación de las hipótesis de Gauss-Markov. Por ejemplo, en la figura 2 b observamos la no linealidad en la parte estructural del modelo.

En **R** tenemos dos gráficos parecidos que se generan con la instrucción `plot()` sobre un modelo lineal.

```
plot(lmod, which = 1)
```

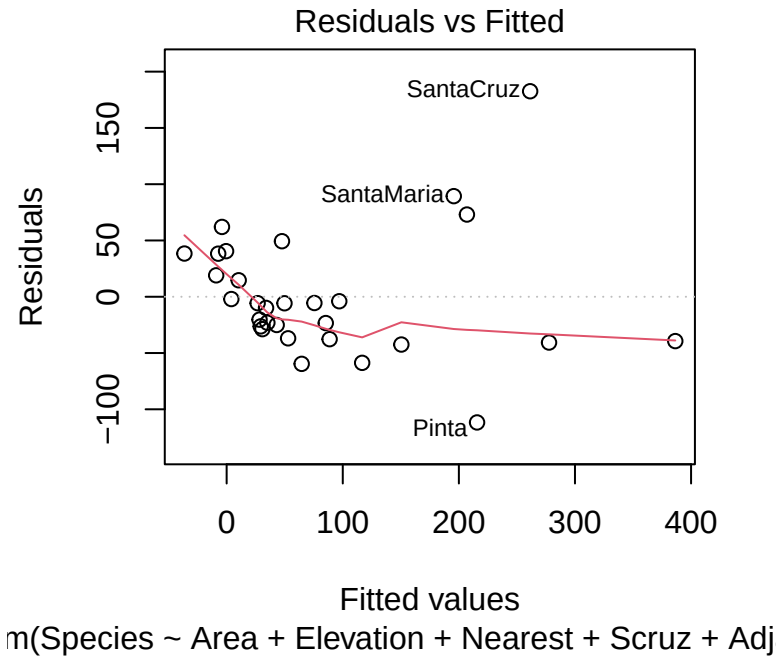

En este gráfico podemos estudiar la linealidad de la parte estructural del modelo y la homocedasticidad.

```
plot(lmod, which = 3)
```

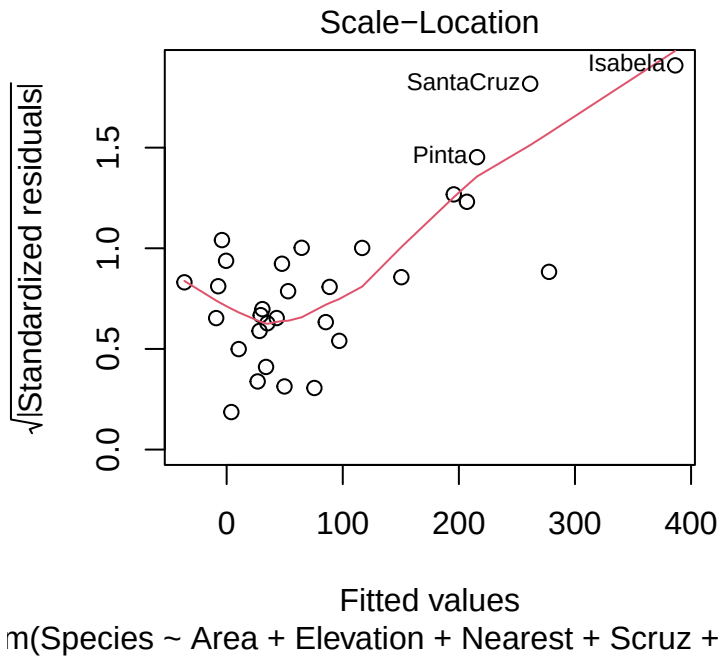

Distribución seminormal

Para un modelo con errores normales, $|e_i|$ debería tener una distribución seminormal (*half-normal*), ya que tiene una densidad que es la mitad superior de una normal. Esta distribución es asimétrica, pero este defecto se puede reducir con la transformación raíz cuadrada.

En este segundo gráfico y en el eje de las ordenadas se presenta la raíz cuadrada de los valores absolutos de los residuos r_i. Esta representación muestra con mayor contundencia la heterocedasticidad de los residuos, si la hay. La linea roja dibujada debería ser horizontal.

Con el paquete `gglm` se pueden obtener los mismos gráficos que hemos visto con la apariencia más elegante de los gráficos `ggplot2`.

```
library(gglm)
# Equivalente a plot(lmod)
gglm(lmod)
# Equivalente a plot(lmod, which=1)
ggplot(data = lmod) + stat_fitted_resid()
# Equivalente a plot(lmod, which=3)
ggplot(data = lmod) + stat_scale_location()
```

Además de la impresión visual, también es posible hacer algún test como el siguiente:

```
summary(lm(sqrt(abs(residuals(lmod))) ~ fitted(lmod)))
```

Sin embargo, este test no es del todo correcto, ya que necesita una regresión ponderada y ajustar los grados de libertad. En todo caso, queda claro que en este modelo hay un problema de heterocedasticidad.

Otra dificultad es que con este test únicamente podemos detectar si hay una tendencia lineal en la variación.

Consultar Faraway (2014, p. 75)

Un test puede ser correcto para detectar un tipo de fallo en la varianza constante de un modelo, pero también puede ser de poca potencia para detectar otro. Los gráficos de residuos son más versátiles porque pueden detectar problemas imprevistos. Un contraste formal da la impresión de seguridad en la decisión, pero puede ser incapaz de detectar problemas insospechados. Las técnicas gráficas son, en este sentido, más eficaces. En general, preferimos el estudio gráfico para el diagnóstico y reservaremos los tests formales para concretar los indicios observados en los gráficos.

Cuando se observe algún tipo de problema en estos gráficos de diagnóstico, se debe modificar el modelo. Si el problema es una estructura no lineal, quizá junto con heterocedasticidad, debemos considerar una transformación de las variables. En particular, de la variable respuesta. La forma del gráfico puede sugerir la transformación a utilizar (Faraway, 2014, capítulo 9).

Si el problema es únicamente de varianza no constante sin indicios de no linealidad, puede ser adecuado utilizar mínimos cuadrados ponderados; véase el apartado 8.1. de Faraway (2014). Alternativamente, cuando se observa heterocedasticidad en el gráfico de los residuos versus las predicciones, una transformación $h(y)$ de la variable respuesta puede estabilizar la varianza. La elección de la función h se puede determinar estudiando la relación entre $\text{var}(y)$ y $E(y)$ (ver Faraway, 2014, p. 77). Por ejemplo, si $\text{var}(y) \propto (Ey)^2$, entonces la sugerencia es $h(y) = \log y$, mientras que si $\text{var}(y) \propto E(y)$, entonces $h(y) = \sqrt{y}$. En la práctica, probaremos con una transformación y, si el diagnóstico falla, con otra.

En el modelo de las islas Galápagos hemos visto varianza no constante y una cierta evidencia de no linealidad. La variable respuesta es un contaje, seguramente con distribución de Poisson. En estas distribuciones sabemos que la varianza es igual a la media, de modo que se propone la transformación raíz cuadrada para la variable respuesta.

El modelo transformado mejora notablemente su diagnóstico.

```
lmodt <- lm(sqrt(Species) ~ Area + Elevation + Scruz +
                                    Nearest + Adjacent, gala)
ggplot(data = lmodt) + stat_scale_location()
```

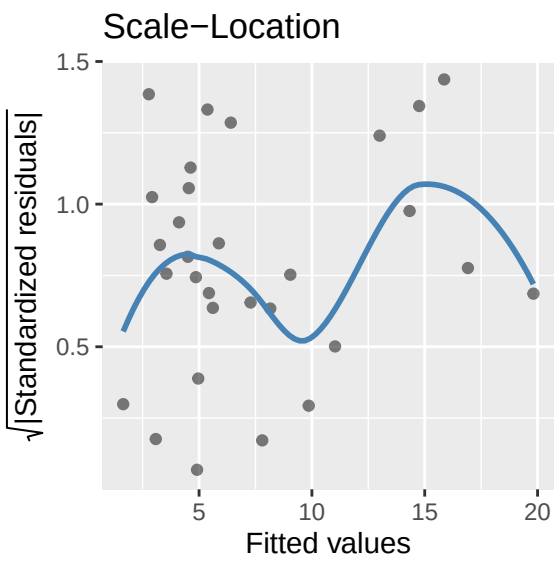

4. Normalidad

La estadística inferencial en los modelos lineales se basa en el supuesto de normalidad de los errores. El mejor gráfico para estudiar la normalidad de los residuos es el QQ-plot.

QQ-plot

Este gráfico muestra los puntos de los residuos ordenados versus los cuantiles teóricos $\Phi^{-1}(i/(n+1))$ para $i = 1, \ldots, n$.
La recta pasa por el primero y el tercero de los cuartiles.

```
plot(lmod, which=2)
```

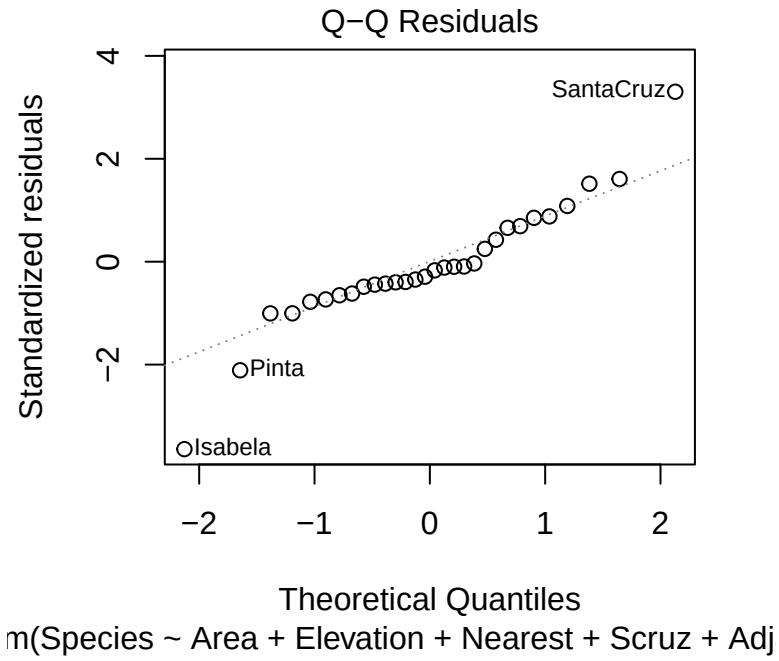

Consultar Faraway (2014, p. 80)

Cuando los errores no son normales, las estimaciones por mínimos cuadrados pueden no ser óptimas. Seguirán siendo las mejores estimaciones lineales insesgadas, pero otros estimadores robustos pueden ser más eficaces. Además, las pruebas y los intervalos de confianza no son exactos. Sin embargo, podemos apelar al teorema del límite central, que garantizará que las pruebas y los intervalos de confianza construidos serán aproximaciones cada vez más exactas para tamaños de muestra mayores. Por lo tanto, podemos permitirnos ignorar el problema, siempre que la muestra sea lo suficientemente grande o la violación no sea especialmente grave.

En el gráfico vemos que las colas no se ajustan demasiado bien o tal vez se trata de simples valores atípicos. Si eliminamos dichos valores atípicos y aparecen otros, el problema de no normalidad es evidente: colas pesadas. Un test como el de Shapiro-Wilk puede confirmar nuestra sospecha.

```
shapiro.test(residuals(lmod))



Shapiro-Wilk normality test

data:  residuals(lmod)
W = 0.91351, p-value = 0.01826
```

El modelo transformado `lmodt` del apartado anterior también corrige este problema.

Utilizar un test en exclusiva, sin un gráfico como el QQ-plot, para detectar la no normalidad de los errores no es una buena idea. El test y su p-valor no indican el motivo del rechazo de la hipótesis de normalidad. Como se ve en la figura 6.6. de Faraway (2014), el gráfico puede mostrar el tipo de distribución asociado a los errores. Cuando trabajamos con un conjunto de datos grande, un test puede detectar incluso desviaciones leves de la no normalidad, pero no es necesario abandonar los mínimos cuadrados porque los efectos de la no normalidad se ven mitigados por el gran tamaño de las muestras. Para tamaños de muestra más pequeños, las pruebas formales carecen de potencia.

Cuando se detecta la no normalidad de los errores, la solución depende del tipo de problema detectado. Para las distribuciones con colas poco pesadas, las consecuencias de la no normalidad no son graves y pueden ignorarse razonablemente. Para errores asimétricos, una transformación de la respuesta puede resolver el problema. Para los errores con colas pesadas, podríamos aceptar la no normalidad y basar la inferencia con otra distribución o utilizar métodos de remuestreo como el *bootstrap* o los test de permutaciones. Otra posibilidad es utilizar métodos robustos, que dan menos importancia a las observaciones extremas pero pueden requerir un nuevo muestreo para la inferencia.

Procedimiento

Es posible que otros diagnósticos sugieran cambios en el modelo. En este modelo modificado, el problema de los errores no normales podría no producirse, por lo que es mejor abordar primero cualquier problema de no linealidad y varianza no constante.

5. Errores incorrelacionados

Vamos a considerar un ejemplo con datos temporales. En concreto con la base de datos `airquality` del paquete `datasets`.

```
library(datasets)
data(airquality)
str(airquality)


'data.frame': 153 obs. of  6 variables:
 $ Ozone  : int  41 36 12 18 NA 28 23 19 8 NA ...
 $ Solar.R: int  190 118 149 313 NA NA 299 99 19 194 ...
 $ Wind   : num  7.4 8 12.6 11.5 14.3 14.9 8.6 13.8 20.1 8.6 ...
 $ Temp   : int  67 72 74 62 56 66 65 59 61 69 ...
 $ Month  : int  5 5 5 5 5 5 5 5 5 5 ...
 $ Day    : int  1 2 3 4 5 6 7 8 9 10 ...
```

En primer lugar, es necesario un análisis descriptivo de los datos, que se deja para el lector, donde se puede comprobar el gran número de observaciones faltantes. El modelo lineal tiene a la variable `Ozone` como respuesta y las otras como regresoras, pero prescinde, a su vez, de las variables temporales.

Valores faltantes

La acción predeterminada en **R** respecto a los valores faltantes para el análisis de regresión es omitir cualquier caso que contenga un valor perdido. La opción `na.action=na.exclude` no utiliza los casos con valores faltantes en el cálculo, pero mantiene un registro de esos casos que faltan en los residuos, los valores ajustados y otras cantidades.

```
fit <- lm(Ozone ~ Solar.R + Wind + Temp, data=airquality,
                          na.action = na.exclude)
```

Con el análisis de los residuos de este modelo se puede comprobar una cierta no linealidad y heterocedasticidad. En consecuencia, realizamos una transformación logarítmica de la variable respuesta que parece mejorar el modelo.

```
fit_log <- lm(log(Ozone) ~ Solar.R + Wind + Temp, data=airquality,
                                    na.action = na.exclude)
```

Para el estudio de la posible correlación de los errores, se pueden utilizar los métodos de análisis de series temporales, pero aquí utilizaremos métodos más específicos al problema del diagnóstico en regresión. Procederemos con una combinación de métodos gráficos y numéricos. La gran dificultad para comprobar dicha correlación es que hay muchos patrones de correlación posibles. La experiencia permite intuir algunos problemas. Por ejemplo, en este caso, los datos recogidos a lo largo del tiempo pueden tener cierta correlación entre errores sucesivos.

Para descubrir esa posible correlación entre errores sucesivos, hacemos un gráfico de los residuos respecto al índice, ya que los datos están ordenados por el tiempo.

```
plot(residuals(fit_log), ylab="Residuals")
abline(h=0, lty=2)
```

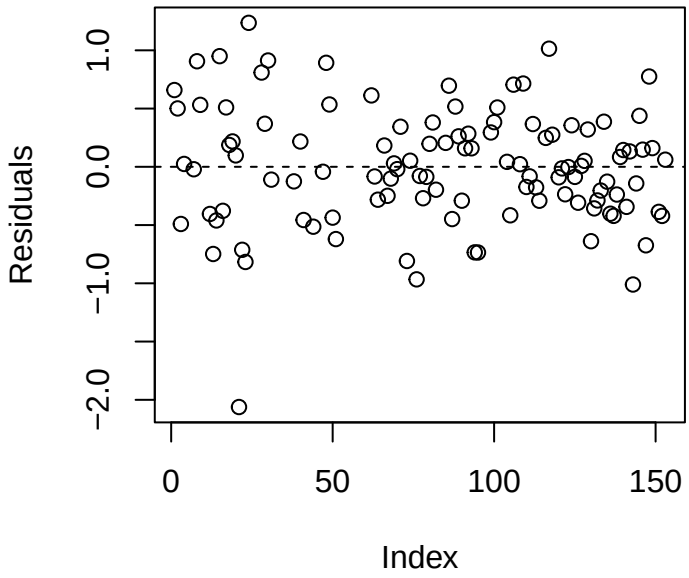

Si existiera correlación, veríamos largas series de residuos por encima o por debajo de la línea para la correlación positiva, o fluctuaciones mayores de lo normal para la correlación negativa. A menos que los efectos sean fuertes, pueden ser difíciles de detectar en este gráfico. Por lo tanto, a menudo es mejor representar gráficamente los residuos sucesivos.

También podemos estudiar el modelo de regresión entre residuos sucesivos y la significación de su recta de regresión sin el intercepto. La recta es así, ya que la media de los residuos es cero y dicha recta debe pasar por el origen de coordenadas.

```
n <- length(residuals(fit_log))
e_i <- head(residuals(fit_log) ,n-1)
e_im1 <- tail(residuals(fit_log), n-1)
recta0 <- lm(e_im1 ~ 0 + e_i)
plot(e_im1 ~ e_i, xlab=expression(e[i]), ylab=expression(e[i+1]))
abline(h=0, v=0, col=grey(0.75))
abline(recta0)
```

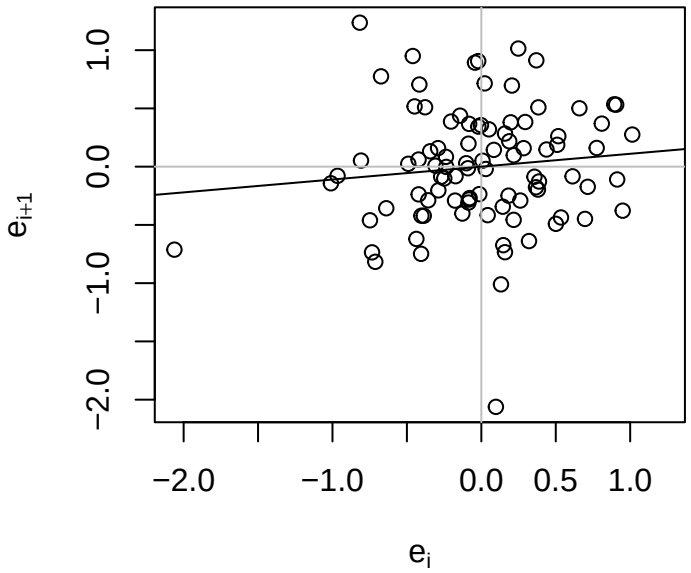


```
faraway::sumary(recta0)


    Estimate Std. Error t value Pr(>|t|)
e_i  0.11038    0.10530  1.0483   0.2973

n = 92, p = 1, Residual SE = 0.50777, R-Squared = 0.01
```

No se aprecia ningún problema evidente de correlación de errores. Sin embargo, hay un valor atípico que podemos intentar identificar. ¿Realmente solo hay un valor atípico?

En este ejemplo no hay mucha correlación, como muestra el coeficiente de determinación R^2 y cuya raíz cuadrada es:

```
cor(e_i, e_im1, use="complete.obs")


[1] 0.1092547
```

Otro ejemplo

En el libro de Faraway (2014, pp. 81-83) se explica un ejemplo de modelo con una fuerte correlación entre errores sucesivos.

Un test adecuado para el contraste de la hipótesis nula de que los errores están incorrelacionados es el de Durbin-Watson. Este test se puede calcular con la función `dwtest()` del paquete `lmtest`.

```
library(lmtest)
dwtest(log(Ozone) ~ Solar.R + Wind + Temp,
                        data=na.omit(airquality))



Durbin-Watson test

data:  log(Ozone) ~ Solar.R + Wind + Temp
DW = 1.8068, p-value = 0.1334
alternative hypothesis: true autocorrelation is greater than 0
```

El p-valor indica que no hay una fuerte evidencia de correlación entre errores sucesivos.

En el caso de un modelo con errores correlacionados, lo más oportuno es introducir esa correlación directamente en el modelo con un cambio estructural y utilizar el método de los mínimos cuadrados generalizados con la función `gls()` en **R**.

6. Diagnóstico de la influencia

Ocasionalmente, hallamos que algún dato o un pequeño subconjunto de datos ejerce una desproporcionada influencia en el ajuste del modelo de regresión. Esto es, los estimadores de los parámetros o las predicciones pueden depender más del subconjunto influyente que de la mayoría de los datos. Queremos localizar estos puntos influyentes y medir su impacto en el modelo. Si por alguna razón concreta son puntos "malos" los eliminaremos, pero si no ocurre nada extraño, su estudio puede darnos algunas claves del modelo.

6.1. Nivel de un punto

Casi siempre los puntos definidos por las variables regresoras o explicativas forman una nube y están razonablemente repartidos alrededor del punto medio. Sin embargo, alguno de ellos o un pequeño grupo puede aparecer muy alejado del resto. Estos valores son potencialmente peligrosos, puesto que pueden afectar excesivamente al ajuste del modelo. Vamos a definir el concepto de nivel (*leverage*) de un punto y señalaremos los que tengan un nivel muy alto (*leverage points*).

El nivel de un punto es una medida de la distancia del punto al centroide del conjunto de datos. Existen varias propuestas, pero la más extendida se basa en los elementos h_{ii} de la diagonal de la matriz proyección $\mathbf{P}$. Estos elementos se calculan con las fórmulas que hemos explicado en el apartado 1 de este módulo.

Propiedad

La matriz proyección $\mathbf{P}$ verifica la propiedad $\text{traza}(\mathbf{P}) = \text{rango}(\mathbf{P})$ como se demuestra en el apéndice A.3.2. de Carmona (2005).

Como

$$\sum_{i=1}^{n} h_{ii} = \text{traza}(\mathbf{P}) = \text{rango}(\mathbf{P}) = p + 1$$

el tamaño medio de cada h_{ii} es $(p+1)/n$, donde p es el número de variables regresoras. Así, cuando un punto verifique $h_{ii} > 2(p+1)/n$ diremos que dicha observación es un punto de alto nivel (*leverage point*).

Estos puntos se deben marcar para su posterior estudio, ya que son potencialmente influyentes.

6.2. Influencia en los coeficientes de regresión

Entre las medidas de influencia sobre los coeficientes de regresión la más utilizada es la distancia de Cook (1977)

$$C_i = \frac{(\widehat{\boldsymbol{\beta}} - \widehat{\boldsymbol{\beta}}_{(i)})'\mathbf{X}'\mathbf{X}(\widehat{\boldsymbol{\beta}} - \widehat{\boldsymbol{\beta}}_{(i)})}{(p+1)\text{ECM}} \qquad i = 1, \ldots, n$$

donde $\widehat{\boldsymbol{\beta}}$ son las estimaciones MC en el modelo con todos los puntos, mientras que $\widehat{\boldsymbol{\beta}}_{(i)}$ son las estimaciones sin el i-ésimo punto.

Otra versión equivalente de esta distancia es

$$C_i = \frac{(\widehat{\mathbf{Y}} - \widehat{\mathbf{Y}}_{(i)})'(\widehat{\mathbf{Y}} - \widehat{\mathbf{Y}}_{(i)})}{(p+1)\text{ECM}}$$

ya que $\widehat{\mathbf{Y}} = \mathbf{X}\widehat{\boldsymbol{\beta}}$ y $\widehat{\mathbf{Y}}_{(i)} = \mathbf{X}\widehat{\boldsymbol{\beta}}_{(i)}$.

Sin embargo, para el cálculo de esta distancia es mejor utilizar la fórmula

$$C_i = \frac{r_i^2}{p+1} \cdot \frac{h_{ii}}{1 - h_{ii}} \tag{3}$$

donde la primera parte depende del ajuste al modelo de la i-ésima predicción, mientras que el segundo factor es una función de la distancia del punto $\mathbf{x}_i$ al centroide del conjunto de observaciones de las variables explicativas. Una demostración de esta fórmula puede verse en el ejercicio 9.19 del libro de Ugarte y Militino (2002).

La búsqueda de puntos influyentes se puede iniciar con la identificación de puntos con distancia de Cook elevada. Sin embargo, no hay reglas fijas para la determinación de los puntos con valor de C_i grande. Los puntos con distancias de Cook grandes pueden ser influyentes y podemos extraerlos del análisis para ver si los cambios son apreciables.

Nota

La distancia de Cook no siempre identifica correctamente las observaciones influyentes. John Fox (2019) explica en su libro que un punto solo puede considerarse un valor atípico potencial si destaca visualmente del resto de los datos.

Como la distancia de Cook está relacionada con la distribución F, un criterio es utilizar la mediana $F_{0.5}(p+1, n-p-1)$ como punto de corte. Dado que este valor es cercano a 1 para n grande, se deduce una directriz operativa simple de $C_i > 1$. Para muestras pequeñas, el criterio para designar un valor como influyente es $C_i > 4/(n-p-1)$. Otros autores prefieren utilizar como punto de corte (*cut-off*) tres veces la media de las distancias de Cook de todas las observaciones. En cualquier caso, debemos ordenar las distancias de Cook y atender a los valores más "grandes".

La mediana

En **R**, la mediana propuesta como punto de corte se calcula con `qf(0.5, p+1, n-p-1)`.

Con el modelo que utilizamos de ejemplo en este módulo, los puntos destacados por la distancia de Cook son:

```
d_Cook <- cooks.distance(fit_log)
d_Cook <- d_Cook[!is.na(d_Cook)]
d_Cook <- d_Cook[order(d_Cook, decreasing = TRUE)]
# d_Cook[d_Cook > 3*mean(d_Cook)]
# d_Cook[d_Cook > 1]
d_Cook[d_Cook > 4/(n-3-1)]
```

```
        21         48         24         76         15
0.36198209 0.11455304 0.06531060 0.05757424 0.05181794
       117         23        148          8         22
0.05084261 0.04592367 0.04277424 0.03992433 0.03856677
        94          9         13         28
0.03856438 0.03487701 0.03312340 0.03097096
```

Otra medida de influencia sobre cada coeficiente de regresión por separado consiste en la diferencia estandarizada entre la estimación MC de dicho parámetro con todas las observaciones y la estimación MC del mismo sin la i-ésima:

$$\text{Dfbetas}_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{s^2_{(i)} c_{jj}}}$$

para $j = 0, 1, \ldots, p$ y $i = 1, \ldots, n$, donde c_{jj} es el j-ésimo elemento de la diagonal de la matriz $(\mathbf{X}'\mathbf{X})^{-1}$ y $s^2_{(i)}$ la estimación MC de la varianza σ^2 sin la i-ésima observación. Observemos que $s^2_{(i)} c_{jj}$ es una estimación de la varianza $\text{var}(\hat{\beta}_j) = \sigma^2 c_{jj}$.

Un valor absoluto desmesurado de esta medida indica una gran influencia de la observación i-ésima sobre la estimación del coeficiente β_j. En la práctica se considera una observación influyente cuando $|\text{Dfbetas}| > 1$ para un pequeño conjunto de datos y $|\text{Dfbetas}| > 2/\sqrt{n}$ en general.

```
dfbetas(fit_log)[1:3,]
```

```
  (Intercept)     Solar.R        Wind         Temp
1 0.250685854  0.05721067 -0.19174191 -0.229095974
2 0.112509469 -0.05364378 -0.09272826 -0.079515948
3 0.007680106  0.02830027 -0.05980806 -0.004875361
```

6.3. Influencia en las predicciones

Como hemos visto, la distancia de Cook es también una medida de la influencia de un punto sobre el conjunto de predicciones.

Otra medida de influencia de la i-ésima observación sobre la predicción de la propia observación i es el estadístico

$$\text{Dffits}_i = \frac{|\hat{y}_i - \hat{y}_{i(i)}|}{\sqrt{s^2_{(i)} h_{ii}}}$$

donde se estandariza la diferencia entre las predicciones de la i-ésima observación con y sin ella misma.

A partir de las ecuaciones 1 y 2 se demuestra que

$$\text{Dffits}_i = |t_i| \sqrt{\frac{h_{ii}}{1 - h_{ii}}} \tag{4}$$

donde t_i son los residuos studentizados externamente.

En general, se considera que la influencia es notable si el Dffits es superior a $2\sqrt{(p+1)/n}$, mientras que para un conjunto de datos reducido basta con que sea mayor que uno.

```
my.dffits <- dffits(fit_log)
my.dffits <- my.dffits[!is.na(my.dffits)]
my.dffits <- my.dffits[order(my.dffits, decreasing = TRUE)]
my.dffits[my.dffits > 2*sqrt(4/n)]
```

```
       48        24        15       117       148         8
0.6849956 0.5240199 0.4611457 0.4578616 0.4165620 0.4040800
        9        28
0.3738932 0.3547434
```

6.4. Análisis gráfico de la influencia

Como ya hemos dicho antes, los gráficos forman una parte esencial del diagnóstico de un modelo lineal, incluso más que los tests formales o los puntos de corte artificiales. En **R** la instrucción `plot()`, aplicada a un objeto del tipo `lm`, proporciona cuatro gráficos por defecto que muestran un análisis de los residuos. El cuarto, que en realidad es el número 5, dibuja los residuos t_i respecto al nivel o *leverage* h_{ii}, pero además muestra los contornos (las líneas

discontinuas) que señalan los valores de 0.5 y 1 para la distancia de Cook.

```
plot(fit_log, which = 5)
```

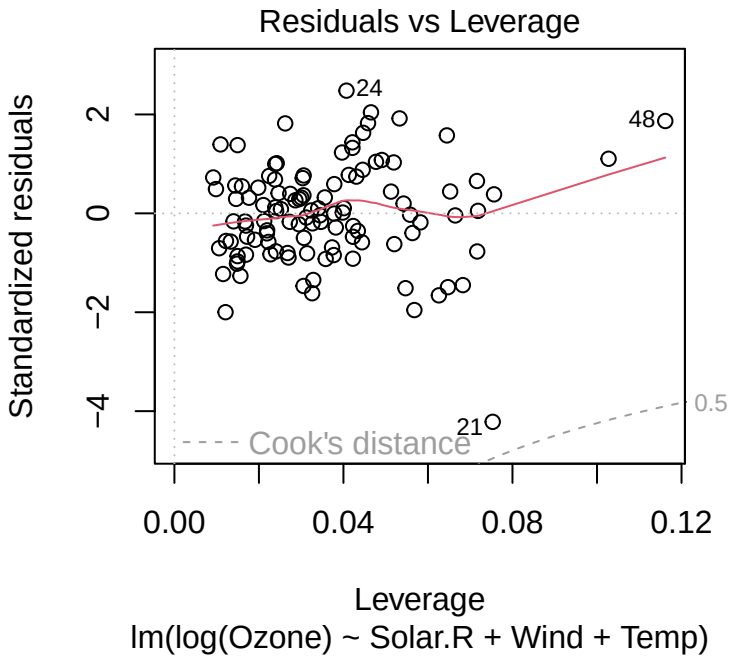

Como vemos, ninguna observación supera la distancia de Cook 0.5 y mucho menos 1. Por otra parte, el gráfico numero 4, que no aparece por defecto, muestra todas las distancias de Cook y señala las tres mayores.

Nota

El parámetro `cook.levels` puede cambiar los niveles de contorno de la distancia de Cook en el gráfico número 5.
El parámetro `id.n` controla el número de puntos para etiquetar en el gráfico número 4.

```
plot(fit_log, which = 4)
```

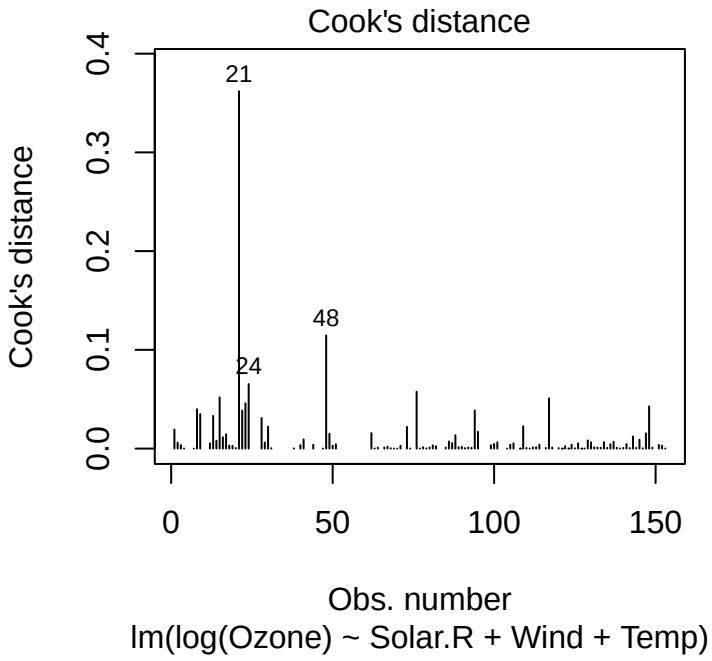

El gráfico número 6 dibuja las distancias de Cook respecto al *leverage* en la forma $h_{ii}/(1-h_{ii})$.

```
plot(fit_log, which = 6)
```

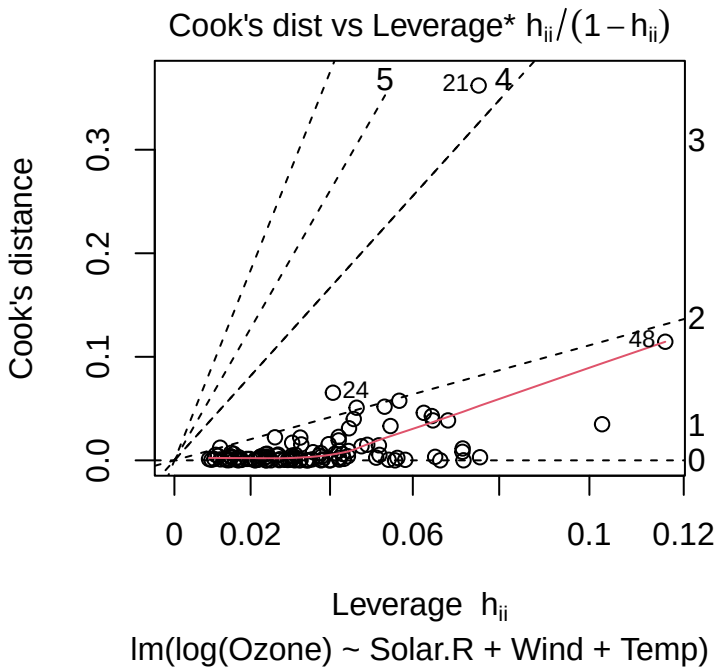

Los contornos

Los contornos del gráfico número 6 son los residuos r_i con igual magnitud en forma de líneas que pasan, a su vez, por el origen de coordenadas gracias a la fórmula 3. Las líneas de contorno se etiquetan con sus magnitudes.

Por otra parte, nada nos impide crear nuestro propio gráfico con el punto de corte preferido.

```
fit_log_comp <- lm(log(Ozone) ~ Solar.R + Wind + Temp,
                                   data=na.omit(airquality))
cut.off <- 3*mean(cooks.distance(fit_log_comp))
ggplot(data=fit_log_comp) + stat_cooks_obs() +
      geom_hline(yintercept=cut.off, linetype="dashed")
```

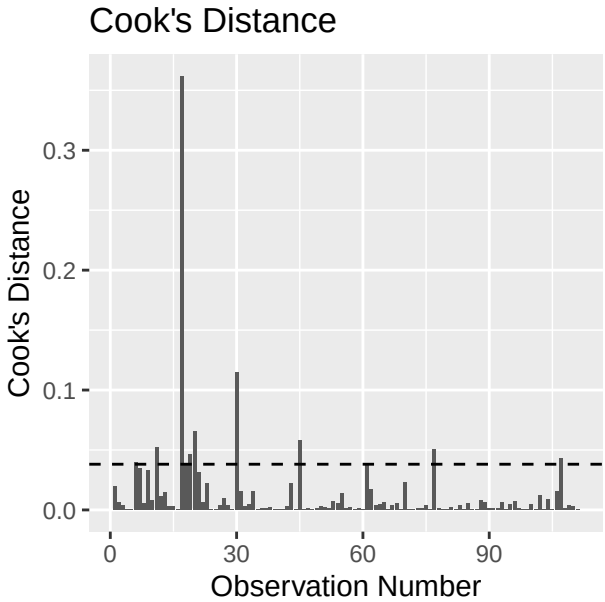

Nota

Para conseguir este gráfico ha sido necesario reducir la base de datos a las observaciones sin valores faltantes.

El paquete `car` contiene algunos gráficos que resumen el diagnóstico de un modelo lineal con residuos atípicos, observaciones con alto *leverage* y distancias de Cook elevadas. En el gráfico `influencePlot()` tenemos el *leverage* en el eje de las abscisas y los residuos t_i en el eje de ordenadas. Las líneas horizontales en -2 y 2 señalan las fronteras de los *outliers*. Las líneas verticales están en 2 y 3 veces la media de los *leverage* (en este caso $(p+1)/n = 4/111$). El radio de los círculos para cada punto es proporcional a la distancia de Cook.

Otros gráficos

En el paquete `faraway` tenemos la función `halfnorm()`, que se explica en la página 84 del libro de Faraway (2014). Sirve para destacar los valores extremos y se puede utilizar con el *leverage* y con las distancias de Cook.
Por otra parte, en el mismo paquete `car` tenemos el gráfico `infIndexPlot()`, que además muestra los p-valores para la detección de *outliers* por el método de comparación múltiple de Bonferroni implementado en la función `outlierTest()`.

```
library(car)
influencePlot(fit_log_comp, id=T, fill=F, main="Influence Plot",
              sub="Circle size is proportial to Cook's Distance")
```

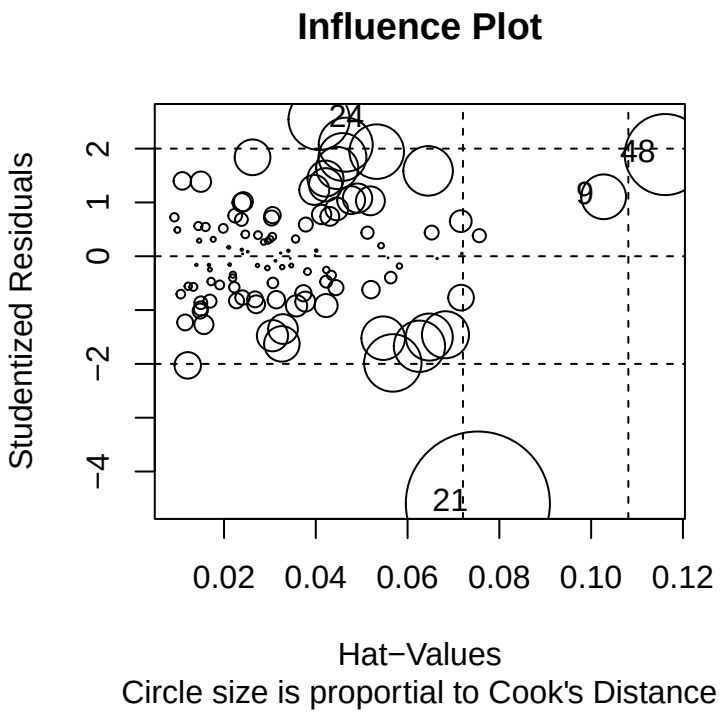


```
     StudRes        Hat      CookD
9   1.104958 0.10273618 0.03487701
21 -4.595571 0.07531628 0.36198209
24  2.543565 0.04071527 0.06531060
48  1.889519 0.11615763 0.11455304
```

De un vistazo apreciamos las observaciones con problemas. En el listado aparecen los más problemáticos por diversas razones. En este caso, la observación 21 es un *outlier*, con alto *leverage* e influyente.

7. Comprobación de la estructura del modelo

La diagnosis del modelo también hay que aplicarla para detectar problemas en la parte estructural donde $E(Y) = \mathbf{X}\boldsymbol{\beta}$. Aquí también juegan un importante papel los residuos y algunos gráficos, mucho mejor que contrastes más formales.

Ya hemos visto que los gráficos de los residuos respecto a las predicciones o las variables regresoras se utilizan para comprobar las condiciones del modelo lineal sobre los errores. Algunos sugieren transformaciones de las variables que redundan en una mejora de la parte estructural del modelo.

También se pueden hacer gráficos de y_i respecto a cada una de las x_i como parte del análisis exploratorio inicial. Sin embargo, es mejor aislar el efecto de cada x_i sobre y_i, ya que las otras regresoras afectan a la relación entre estas dos. Para ello, tenemos los gráficos llamados de variable añadida y los de regresión parcial.

Consideremos la regresión de y con todas las regresoras excepto la x_i y tomamos sus residuos $\hat{\delta}$. Estos residuos representan y sin el efecto de las otras regresoras.
Por otra parte, hacemos la regresión de x_i con las otras variables regresoras y tomamos sus residuos $\hat{\gamma}$. Estos residuos representan x_i sin el efecto de las otras regresoras.
Finalmente, el *gráfico de variable añadida* consiste en dibujar $\hat{\delta}$ respecto a $\hat{\gamma}$ y estudiar su linealidad, valores atípicos o puntos influyentes.

Por ejemplo, para los datos `airquality` y la variable regresora `Wind` tenemos:

```
d_ <- residuals(lm(log(Ozone) ~ Solar.R + Temp,
                       data=na.omit(airquality)))
g_ <- residuals(lm(Wind ~ Solar.R + Temp,
                       data=na.omit(airquality)))
plot(g_, d_, xlab="Wind residuals", ylab="log(Ozone) residuals")
```

El paquete `car`

El paquete `car` contiene la función `avPlots()`, que dibuja los gráficos de variable añadida para todas las regresoras. También tiene la función `crPlots()` para representar los gráficos de residuos parciales.

Al gráfico le podemos añadir la recta de regresión que tiene como pendiente el coeficiente de la regresión múltiple para esta variable.

```
abline(lm(d_ ~ g_))
c(coef(lm(d_ ~ g_))[2], coef(fit_log_comp)[3])
```

```
         g_        Wind
-0.06156247 -0.06156247
```

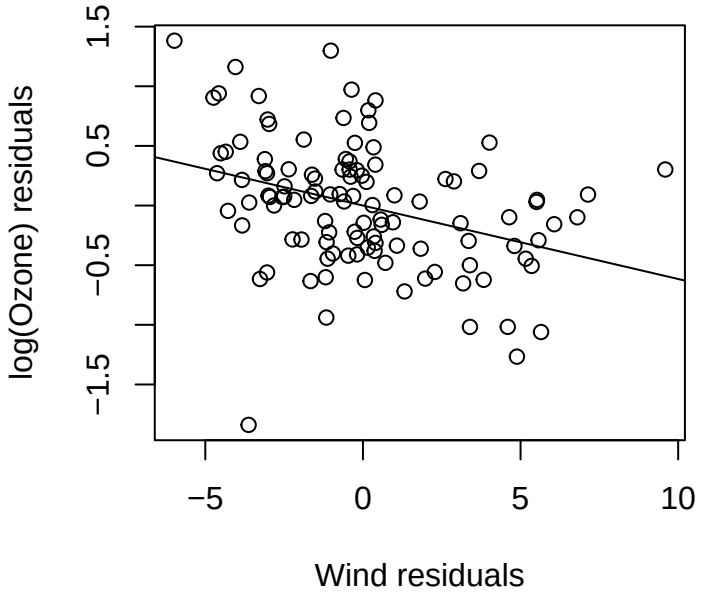

No parece que haya ningún problema en este gráfico. La relación se puede considerar lineal, aunque aparecen un par de puntos dignos de estudio. El mismo gráfico se debe hacer para las otras dos regresoras.

Los *gráficos de regresión parcial* o *de residuos parciales* consisten en dibujar $e_i + \hat{\beta}_i x_i$ respecto a x_i. Con ello tenemos la respuesta sin el efecto de las predicciones de las otras regresoras ya que

$$y - \sum_{j \neq i} x_j \hat{\beta}_j = \hat{y} + e - \sum_{j \neq i} x_j \hat{\beta}_j = x_i \hat{\beta}_i + e$$

Aquí también la pendiente coincide con el coeficiente de la regresión múltiple y la interpretación es la misma.

Nota

Los gráficos de residuos parciales parecen mejores para la detección de problemas de linealidad, mientras que los gráficos de variable añadida se utilizan para investigar posibles *outliers* y puntos influyentes.

Como ejemplo, para la variable `Wind` tenemos:

```
Wind_ <- na.omit(airquality)$Wind
plot(Wind_, coef(fit_log_comp)["Wind"]*Wind_ +
                residuals(fit_log_comp),
           xlab="Wind", ylab="beta*Wind + res")
abline(0, coef(fit_log_comp)["Wind"])
```

El paquete `faraway`

El mismo gráfico se puede tener con la función `prplot()` del paquete `faraway`.

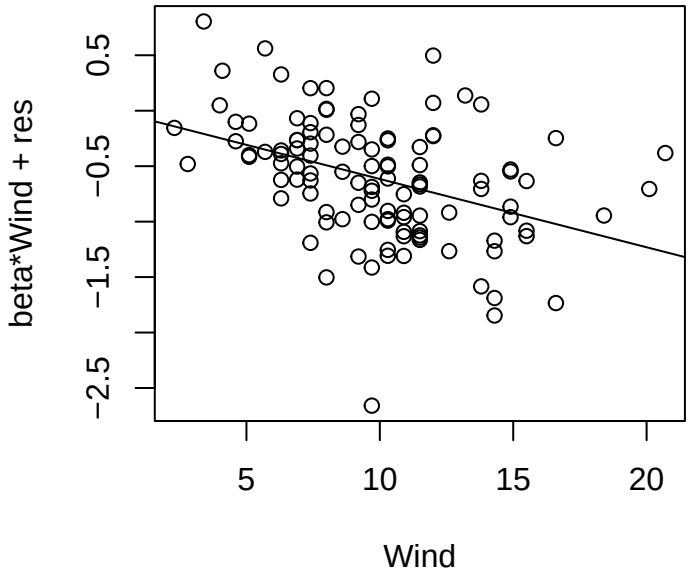

Un gráfico muy similar se puede obtener con la función `termplot()`, pero con los residuos parciales en la forma $e + \hat{\beta}_i(x_i - \bar{x}_i)$, es decir, con los valores de la regresora centrados.

```
termplot(fit_log_comp, partial.resid = TRUE, terms=2)
```

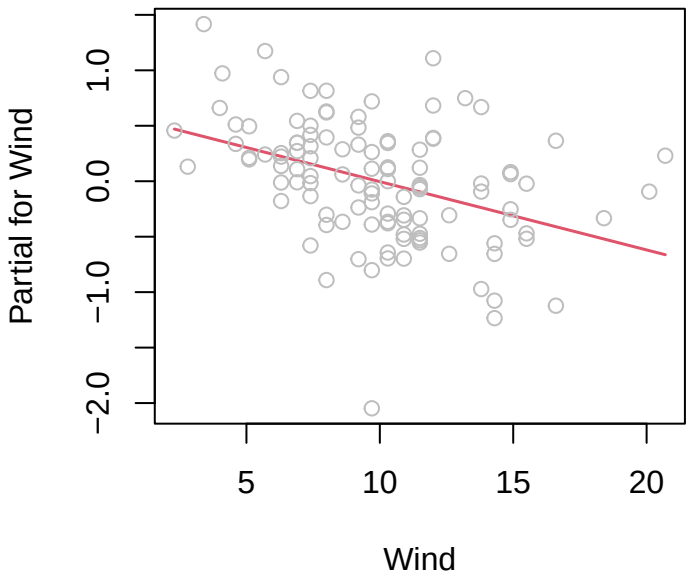

Finalmente, queda decir que también se pueden utilizar algunas técnicas no gráficas para comprobar la forma lineal del modelo o sugerir alguna transformación o combinación de las variables. Esto último se estudiará más adelante.

8. Multicolinealidad

Cuando la matriz de diseño $\mathbf{X}$ no es de rango máximo, sabemos que $\mathbf{X}'\mathbf{X}$ es singular y no podemos calcular su inversa. En esta situación, ya hemos visto que para obtener los coeficientes de regresión hay diversas estrategias, como la utilización de alguna g-inversa, aunque ello implica que la solución de las ecuaciones normales no es única. Este problema se presenta si utilizamos factores como variables explicativas en regresión y no acertamos con una buena codificación. En el caso de utilizar únicamente variables explicativas numéricas no categóricas es difícil, aunque no imposible, que alguna columna sea linealmente dependiente de las demás. Si ocurriera, diríamos que existe colinealidad exacta entre las columnas de $\mathbf{X}$ y su rango no sería máximo. Sin embargo, el término *colinealidad* o *multicolinealidad* se refiere al caso, mucho más frecuente, de que la dependencia entre las columnas no es exacta sino aproximada, es decir, a la quasi-dependencia lineal entre las variables regresoras. Esto puede provocar problemas de computación de los parámetros y en el cálculo de la precisión de los mismos. Es decir, se produce la contradicción de que la varianza de los estimadores mínimo cuadráticos de los parámetros puede ser muy grande, aunque la teoría dice que es mínima.

Lecturas complementarias

Una introducción más matemática se puede leer en el Apéndice A.4. de Carmona (2005).
Este tema también se puede consultar en el apartado 7.3. de Faraway (2014).

Para la detección de este problema hay diversas formas:

- La más sencilla es el cálculo de la matriz de correlaciones entre las variables regresoras. Con ello se puede ver si hay correlaciones próximas a 1 o a -1, lo que indica dependencia lineal entre dos variables explicativas. Sin embargo, la multicolinealidad puede deberse a una relación más compleja entre las variables explicativas y la matriz de correlaciones no la detectaría.

- Otra posibilidad es calcular los valores propios $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_k \geq 0$ de la matriz $\mathbf{X}'\mathbf{X}$, donde $k = p+1$ es el número de columnas de $\mathbf{X}$. Si hay valores propios nulos, significa colinealidad exacta (y utilizar g-inversas). Si hay valores muy pequeños pero no nulos, entonces sí tenemos un problema de multicolinealidad.

  Para decidir si un valor propio es pequeño, utilizaremos el concepto de *número de condición* κ de la matriz $\mathbf{X}$:

  $$\kappa = \sqrt{\frac{\lambda_1}{\lambda_k}}$$

  de forma que cuando $10 \leq \kappa < 30$ se considera que la matriz está *mal condicionada* o *enferma*. Si $\kappa \geq 30$ está *muy grave*. Además, podemos calcular los otros números de condición $\sqrt{\lambda_1/\lambda_j}$ para ver si hay más de una combinación lineal aproximada.

¡Atención!

En la literatura hay una cierta confusión sobre el cálculo de κ en regresión. Algunos autores calculan el número de condición de $\mathbf{X}'\mathbf{X}$, que es justamente el cuadrado del que aquí definimos.

- El efecto de la multicolinealidad se puede observar en la fórmula de la varianza de la estimación de β_j:

$$\text{var}(\hat{\beta}_j) = \sigma^2 \left(\frac{1}{1 - R_j^2} \right) \frac{1}{\sum_i (x_{ij} - \bar{x}_j)^2}$$

Vemos, entonces, que esta varianza depende de la varianza muestral de x_j, pero también de la proximidad de R_j^2 a 1. Cuando $R_j^2 \approx 1$, la variable x_j se puede predecir casi exactamente por una combinación lineal de las otras predictoras, luego hay multicolinealidad.

Nota

Esta ecuación nos dice que para reducir la varianza de los estimadores de los coeficientes podemos utilizar variables explicativas con gran variabilidad y, en especial y siempre que podamos, elegir variables ortogonales con $R_j^2 = 0$.

Definimos como **factor de inflación de la varianza o FIV** (*variance inflation factor* o sus siglas en inglés, VIF)

$$\text{FIV}_j = \frac{1}{1 - R_j^2} \qquad j = 1, \ldots, p$$

El criterio general es considerar un $5 \leq \text{FIV}_j < 10$ como síntoma de multicolinealidad y un $\text{FIV}_j \geq 10$ como caso grave.

- Sin embargo, los FIV_j no identifican exactamente qué variables predictoras provocan la multicolinealidad y, sobre todo, con qué variables predictoras están relacionadas. Belsley (1991) discutió extensamente todas estas dificultades y propuso un método para descubrir y estudiar la multicolinealidad.

El análisis de las proporciones en la descomposición de la varianza o PDV (*variance decomposition proportions* o VDP), obtenidas a partir de los vectores propios de una matriz compuesta por las variables explicativas estandarizadas, pueden identificar las variables multicolineales mostrando el grado de inflación de la varianza según cada índice de condición. Cuando dos o más PDV, que corresponden a un índice de condición común superior a 10 o a 30, son superiores a 0.8 o a 0.9, sus variables explicativas asociadas son multicolineales. La exclusión de las variables explicativas multicolineales conduce a modelos de regresión múltiple estadísticamente estables.

Lecturas complementarias

El análisis VDP queda fuera de este curso. Más detalles y un ejemplo se pueden hallar en el artículo de Kim (2019). El paquete `mctest` de **R** tiene la función `eigprop()`, la cual nos facilita los cálculos de todos los elementos del análisis.

En el libro de Montgomery, Peck y Vining (2012, p. 294) se propone un ejemplo con los datos simulados de Gunst, Webster y Mason (1976). Los datos son:

```
(gunst <- read.csv("gunst.csv", sep=";"))
```

```
        y x1 x2 x3 x4     x5     x6
1  10.006  8  1  1  1  0.541 -0.099
2   9.737  8  1  1  0  0.130  0.070
3  15.087  8  1  1  0  2.116  0.115
4   8.422  0  0  9  1 -2.397  0.252
5   8.625  0  0  9  1 -0.046  0.017
6  16.289  0  0  9  1  0.365  1.504
7   5.958  2  7  0  1  1.996 -0.865
8   9.313  2  7  0  1  0.228 -0.055
9  12.960  2  7  0  1  1.380  0.502
10  5.541  0  0  0 10 -0.798 -0.399
11  8.756  0  0  0 10  0.257  0.101
12 10.937  0  0  0 10  0.440  0.432
```

Observemos que las filas de las variables x_1, x_2, x_3 y x_4 suman 10, excepto la primera fila que suma 11, lo que rompe la colinealidad exacta. Además, el término de intercepción propuesto también es 10.

```
apply(gunst[,2:5],1,sum)
```

```
 [1] 11 10 10 10 10 10 10 10 10 10 10 10
```

Así pues, el rango de la matriz de diseño de la regresión es

```
lmod <- lm(y ~ ., data=gunst)
qr(lmod)$rank
```

```
[1] 7
```

con lo que aparentemente no hay problemas con las estimaciones de los $7 = 6 + 1$ parámetros $\beta_0, \beta_1, \ldots, \beta_6$.

Veamos la matriz de correlaciones de las variables predictoras.

```
round(cor(gunst[,2:7]),3)
```

```
       x1     x2     x3     x4     x5     x6
x1  1.000  0.052 -0.343 -0.498  0.417 -0.192
x2  0.052  1.000 -0.432 -0.371  0.485 -0.317
x3 -0.343 -0.432  1.000 -0.355 -0.505  0.494
x4 -0.498 -0.371 -0.355  1.000 -0.215 -0.087
x5  0.417  0.485 -0.505 -0.215  1.000 -0.123
x6 -0.192 -0.317  0.494 -0.087 -0.123  1.000
```

Ninguna de las correlaciones r_{ij} dos a dos es grande y, en consecuencia, no hay indicios que nos hagan sospechar de alguna dependencia lineal entre las regresoras.

Los FIV son:

```
# library(car)
ss <- summary(lmod)
vif.gunst <- c(NA,vif(lmod))
round(cbind(ss$coef, VIF=vif.gunst),4)
```

```
            Estimate Std. Error t value Pr(>|t|)      VIF
(Intercept)  16.6599    14.0465  1.1861   0.2889       NA
x1           -0.5313     1.3418 -0.3959   0.7085 182.0519
x2           -0.8385     1.4206 -0.5902   0.5807 161.3619
x3           -0.7753     1.4094 -0.5501   0.6059 266.2636
x4           -0.8440     1.4031 -0.6015   0.5737 297.7147
x5            1.0232     0.3909  2.6174   0.0472   1.9200
x6            5.0470     0.7277  6.9360   0.0010   1.4553
```

Hay cuatro valores muy grandes. Sin embargo, esto no implica que debamos excluir cuatro variables explicativas.

Los índices de condición de la matriz de diseño se pueden calcular con los datos estandarizados.

```
gunst.scaled <- as.data.frame(scale(gunst, center = T, scale = T))
n <- dim(gunst.scaled)[1]
lmod0 <- lm(y ~ 0 + ., data=gunst.scaled)
X <- model.matrix(lmod0)/sqrt(n-1)
XtX <- crossprod(X) # X'X = correlation matrix
lambdas <- eigen(XtX)$values
round(lambdas, 4)
```

```
[1] 2.4288 1.5462 0.9221 0.7940 0.3079 0.0011
```

Nota

Dividir la matriz de diseño por $\sqrt{n-1}$ se ha hecho para que la matriz $\mathbf{X}'\mathbf{X}$ sea la matriz de correlaciones entre las variables regresoras. Si no se hace ese cociente, los valores propios son proporcionales con un factor de $n-1$, pero los vectores propios son los mismos. En consecuencia, los índices de condición son también los mismos.

El pequeño valor propio indica dependencia casi lineal de los datos. El número de condición es

```
kappa(X, exact = TRUE)    # == sqrt(lambdas[1]/lambdas[6])
```

```
[1] 46.86052
```

lo que muestra una fuerte multicolinealidad. Además, solo un único índice de condición excede el valor 30, luego solo hay una dependencia casi lineal entre los datos.

Además, el análisis de los valores y vectores propios se puede utilizar para identificar la naturaleza de las dependencias casi lineales entre los datos. Supongamos que $\mathbf{v}_1, \mathbf{v}_2, \ldots, \mathbf{v}_p$ son los vectores propios asociados a los valores propios $\lambda_1, \lambda_2, \ldots, \lambda_p$ de la matriz $\mathbf{X}'\mathbf{X}$. Hemos visto que el más pequeño de los valores propios es $\lambda_6 = 0.0011$, luego los elementos del vector $\mathbf{v}_6$ proporcionan la combinación lineal entre las regresoras. En este caso

```
round(eigen(XtX)$vectors[,6], 5)
```

```
[1] 0.44768 0.42114 0.54169 0.57337 0.00605 0.00217
```

es decir

$$-0.44768x_1 - 0.42114x_2 - 0.54169x_3 - 0.57337x_4 - 0.00605x_5 - 0.00217x_6 = 0$$

Teniendo en cuenta que -0.00605 y -0.00217 son aproximadamente cero, resulta

$$x_1 + 0.941x_2 + 1.120x_3 + 1.281x_4 \approx 0$$

De modo que la suma de las cuatro regresoras dan aproximadamente una constante tal y como se han simulado los datos en origen. De esta forma, el vector $\mathbf{v}_6$ nos ha permitido "descubrir" la relación con la que hemos generado los datos de x_1, x_2, x_3 y x_4. En casos más complejos el análisis de las PDV sirve para este objetivo.

Finalmente, debemos indicar que las posibles soluciones al problema de la multicolinealidad pasan por la eliminación de las variables explicativas redundantes, si se pueden identificar, o por métodos de regresión alternativos como la *ridge regression* que se encargan de minimizar los daños.

Bibliografía

Belsley, D.A. (1991) *Conditioning Diagnostics, Collinearity and Weak Data in Regression*, John Wiley & Sons.

Carmona, F. (2005) *Modelos lineales*. e-UMAB, Universitat de Barcelona.

Faraway, J.J. (2014) *Linear Models with R*. 2.ª ed. Chapman and Hall/CRC.

Fox, J. (2019) *Regression Diagnostics: An Introduction*, Sage Publications.

Gunst, R.F., Webster, J.T., y Mason, R.L. (1976) *A comparison of least squares and latent root regression estimators*, Technometrics, 18(1), 75–83.

Kim, J. H. (2019) *Multicollinearity and misleading statistical results*. Korean journal of anesthesiology, 72(6), 558-569. Disponible en: https://doi.org/10.4097/kja.19087

Montgomery, D. C., Peck, E. A., y Vining, G. G. (2012) *Introduction to linear regression analysis*. John Wiley & Sons.

Ugarte, M. D. y Militino, A. F. (2002) *Estadística aplicada con S-Plus*. Universidad Pública de Navarra.