Regresión, modelos y métodos
Prueba de evaluación continua 1

Susana Barcelo, Geòrgia Escaramís, María Teresa Pay,
Miriam Mota y Francesc Carmona

Fecha publicación del enunciado: 11-04-2026
Fecha límite de entrega de la solución: 26-04-2026

Presentación Esta PEC consta de ejercicios similares a los planteados en los ejercicios con los que podréis contrastar vuestra asimilación de los conceptos y métodos presentados durante el curso.

Objetivos El objetivo de esta PEC es trabajar, principalmente, los conceptos de regresión múltiple trabajados en la primera parte de la asignatura.

Descripción de la PEC Debéis responder cada problema por separado, indicando claramente el número y apartado de la pregunta. Las respuestas han de estar debidamente justificadas y pueden incluir el código **R** utilizado.

Criterios de valoración

1. Cada PEC representa un 50 % de la nota de la asignatura. La presentación de los ejercicios aportará una puntuación que **se sumará** a los puntos obtenidos por las PECs
2. **La respuesta correcta a una pregunta debe incluir no sólo el resultado final, sino también el razonamiento y el proceso que condujeron a dicha conclusión.** Es fundamental que el evaluador o la evaluadora pueda comprender no únicamente el qué, sino también el cómo y el porqué del camino recorrido. Las respuestas que no justifiquen adecuadamente los resultados no podrán obtener la máxima puntuación.
3. Se valorará positivamente la inclusión del **código de R estrictamente necesario** para comprender la solución. Por el contrario, la incorporación de resultados o volcados de datos innecesarios será penalizada. El código auxiliar que no sea esencial para la interpretación de los resultados puede incluirse en un apéndice, debidamente referenciado en el cuerpo principal de la respuesta cuando sea pertinente.

Código de honor

1. Cuando presentáis ejercicios individuales os adherís al código de honor de la UOC, con el que os comprometéis a no compartir vuestro trabajo con otros compañeros o a solicitar de su parte que ellos lo hagan. Asimismo aceptáis que, de proceder así, es decir, en caso de copia probada, la calificación total de la PEC será de cero, independientemente del papel (copiado o copiador) o la cantidad (un ejercicio o todos) de copia detectada.
2. El estudiante se compromete a seguir las indicaciones de la UOC a la hora de realizar las actividades de evaluación y de citar las fuentes y las herramientas de **Inteligencia Artificial** utilizadas.

Advertencia El uso de la inteligencia artificial en la resolución de esta actividad puede conducir a conclusiones erróneas o carentes de fundamento lógico. Por ello, en caso de utilizarla, es imprescindible integrarla con un juicio crítico humano, considerando siempre el contexto biológico del problema.

Formato Para hacer la entrega se tiene que enviar un mensaje al buzón de entregas del aula. En este mensaje debéis adjuntar un fichero PDF (obtenido a partir de vuestra solución en Word, Open Office, LaTeX, LyX o RMarkdown). El nombre del fichero debe ser la composición de vuestro apellido y vuestro nombre seguido de `_Reg_PEC2.pdf` (por ejemplo: si vuestro nombre es "Josep Benet", el fichero debe llamarse `benet_josep_Reg_PEC2.pdf`). También puede ser en formato HTML.

*Es **importante** que el examen sea legible y, a ser posible, elegante. Como si fuera un informe a vuestro jefe o jefa. Por ello valoraremos que separéis el código **R** (no necesario para la comprensión de la resolución) de los resultados y la discusión. Podéis hacerlo por ejemplo dejando ese código en un apéndice. En medio de las explicaciones podéis poner vuestro código pero controlad la longitud de los resultados (evitad por ejemplo páginas enteras que únicamente contienen números). De manera orientativa, la solución en un PDF debe ocupar aproximadamente **25 páginas**, incluidos los gráficos y el código recortado.*

Figura 1: Bradley Efron (nacido el 24 de mayo de 1938) es un laureado estadístico americano especialmente conocido por la técnica de remuestreo *bootstrap*.

En esta PEC trabajaremos con un conjunto de datos de 442 pacientes diabéticos recogidos en el estudio de Efron (2004) y que miden la progresión de la diabetes (y) un año después de tomar 10 variables basales: edad (*age*), sexo (*sex*, 1: "female", 2: "male"), índice de masa corporal (*bmi*), presión arterial promedio (*bp*) y seis mediciones de suero sanguíneo:

- *s1*: total colesterol
- *s2*: low-density lipoproteins
- *s3*: high-density lipoproteins
- *s4*: Total Cholesterol / HDL
- *s5*: Lamotrigine (Log of Serum Triglycerides)
- *s6*: glucose

Los datos están disponibles en `https://web.stanford.edu/~hastie/Papers/LARS/diabetes.data`

Nota: En algunos paquetes de **R** también se pueden conseguir los mismos datos, pero ya estandarizados. Nosotros utilizaremos los datos originales.

Ejercicio 0: Estandarización de los datos (10 pt.)

En el estudio original de Efron (2004), la variable sexo se trató como una variable numérica estandarizada para facilitar el algoritmo LARS. Sin embargo, en un análisis estadístico clásico, se recomienda convertirla a factor.

(0.1) ¿Qué modelo estadístico estamos construyendo si incluimos el sexo como factor junto a covariables continuas (como el BMI o la presión arterial)?

(0.2) ¿Cuál es la consecuencia técnica y de interpretación de no realizar esta conversión y mantener el sexo como una variable numérica estandarizada?

(0.3) Estandarizar los datos de manera conveniente y trabajar con ellos a partir de ahora. Indicar el código **R** utilizado.

Ejercicio 1: Formulación del modelo, estimación y significación global (30 pt.)

(1.1) A partir de las variables predictoras *edad*, índice de masa corporal (*bmi*) y presión arterial (*bp*), plantear el modelo más adecuado para predecir la progresión de la diabetes (y). A este modelo lo llamaremos `modelo1`.

Se debe formular la ecuación detalladamente, definiendo cada variable explicativa, la variable dependiente y los parámetros correspondientes.

(1.2) Dado que las variables cuantitativas han sido transformadas a puntuaciones z (estandarización), explicar el comportamiento teórico del parámetro de intercepto β_0. Sustentar la respuesta basándose en el material bibliográfico de la asignatura.

(1.3) Verificar el cumplimiento de las condiciones de Gauss-Markov en el modelo propuesto. Justificar razonadamente la importancia de validar estos supuestos.

(1.4) Determinar los valores estimados de los parámetros del modelo empleando el método de Mínimos Cuadrados Ordinarios. Finalmente, escribir la ecuación del modelo resultante.

(1.5) Establecer formalmente las hipótesis nula y alternativa correspondientes al contraste de significación global del modelo. Identificar el estadístico de prueba empleado, especificando su distribución teórica bajo la veracidad de H_0 y desglosando sus grados de libertad.

(1.6) ¿Podemos admitir que el modelo es globalmente significativo a un nivel de $\alpha = 0{,}05$? En caso de ser significativo, ¿consideráis que es un buen modelo? ¿En qué os basáis para determinar si lo es?

Ejercicio 2: Inferencia sobre parámetros y comparación de modelos (20 pt.)

(2.1) Determinar si podemos prescindir de algún predictor en el `modelo1`. Justificar la respuesta con los test estadísticos pertinentes a un nivel de significación del 5 %.

(2.2) Determinar qué predictor es más influyente. Justificar la respuesta.

(2.3) Un investigador afirma que, una vez conocidos el IMC y la presión arterial (BP), las mediciones de suero sanguíneo (S1 a S6) no aportan información adicional relevante. Discutir la solución propuesta por el investigador y proponer la mejor solución.

(2.4) Indicar el marco teórico en el que se basa la comparación de modelos anidados y su puntos clave. Referencia los apuntes.

Ejercicio 3: modelo ANCOVA (20 pt.)

Un grupo de médicos afirman por experiencia que el IMC (*bmi*) y el suero *s5* son predictores potentes y sospechan que la progresión de la diabetes no afecta por igual a hombres y mujeres debido a diferencias hormonales y de distribución de grasa corporal.
Decidimos incluir la variable *sex* (factor con niveles "Mujer" y "Hombre") en el modelo para determinar si existe una "brecha" en la progresión de la enfermedad que las variables físicas y analíticas no logran explicar por sí solas. Apartir de la nueva configuración, se pide:

(3.1) ¿Existen diferencias significativas en la progresión de la diabetes entre hombres y mujeres? Indicar contraste, estadístico e interpretación.

(3.2) ¿El impacto del IMC sobre la diabetes es constante independientemente del sexo, o el riesgo asociado al sobrepeso es más agresivo en un sexo que en otro?

(3.3) Partiendo del análisis de interacción entre el IMC y el sexo, derivar la ecuación predictora específica para el subgrupo de mujeres. Identificar e interpretar el significado estadístico de cada coeficiente resultante (intercepto y pendientes) y del término interacción. Indicar también la estimación de sus parámetros.

Ejercicio 4: Diagnóstico (20 pt.)

En este ejercicio se pide hacer un diagnóstico completo del modelo del apartado anterior que llamaremos: `model_ancova_int`.

(4.1) Obtener con la función `plot()` los gráficos básicos de diagnóstico del modelo `model_ancova_int` del apartado 3.3 del ejercicio anterior. Explicar brevemente la información que proporcionan los cuatro gráficos.

(4.2) A partir de los gráficos anteriores, indicar si se detectan posibles problemas en los supuestos del modelo (normalidad de los errores y homocedasticidad). Comprobar con algún test las hipótesis de homocedasticidad y normalidad de los errores. Utilizar dos tests distintos para comprobar la hipótesis de homocedasticidad. En caso afirmativo, explicar qué tipo de acciones se podrían considerar para corregir este tipo de problemas.

(4.3) A partir de los mismos gráficos o con algún otro, indicar si se observan posibles valores atípicos o puntos influyentes. Explicar cómo actuarías en caso de confirmar su presencia.

Referencias

[1] Efron, B., et al. 2004. Least angle regression (with discussion). Ann. Statist. 32:407–499. <DOI:10.1214/009053604000000067>