PEC1 - Regresión, modelos y métodos

Marco Russo

April, 2026

Contents

1 Información del Estudiante **2**
1.1 Introducción . . . 3
1.2 Ejercicio 0: Estandarización de los datos (10 pt.) . . . 4
1.2.1 (0.1) Modelo con sexo como factor . . . 4
1.3 (0.2) Consecuencias de no convertir el sexo a factor . . . 4
1.4 (0.3) Estandarización y preparación de los datos . . . 4
1.5 Ejercicio 1: Formulación, estimación y significación global (30 pt.) . . . 7
1.5.1 (1.1) Modelo con edad, bmi y bp . . . 7
1.5.2 (1.2) Comportamiento del intercepto con variables estandarizadas . . . 7
1.5.3 (1.3) Verificación de las condiciones de Gauss-Markov . . . 7
1.5.4 (1.4) Estimación de los parámetros . . . 8
1.5.5 (1.5) Contraste de significación global . . . 9
1.5.6 (1.6) Significatividad y bondad del modelo . . . 10
1.6 Ejercicio 2: Inferencia sobre parámetros y comparación de modelos (20 pt.) . . . 11
1.6.1 (2.1) ¿Podemos prescindir de algún predictor en modelo1? . . . 11
1.6.2 (2.2) Predictor más influyente . . . 11
1.6.3 (2.3) Discusión sobre el valor añadido de las variables de suero . . . 11
1.6.4 (2.4) Marco teórico para comparación de modelos anidados . . . 11
1.7 Ejercicio 3: Modelo ANCOVA (20 pt.) . . . 13
1.7.1 (3.1) Diferencias entre sexos en la progresión de la diabetes . . . 13
1.7.2 (3.2) ¿El impacto del IMC es constante o varía con el sexo? . . . 13
1.7.3 (3.3) Ecuación predictora para mujeres . . . 14
1.8 Ejercicio 4: Diagnóstico del modelo ANCOVA con interacción (20 pt.) . . . 15
1.8.1 (4.1) Gráficos básicos de diagnóstico . . . 15
1.8.2 (4.2) Tests de homocedasticidad y normalidad . . . 15
1.8.3 (4.3) Valores atípicos y puntos influyentes . . . 16

1 Información del Estudiante

Nombre	Marco Russo
Email	mrussorb@uoc.edu
GitHub	
LinkedIn	https://www.linkedin.com/in/marcusrb/
Fecha	April 20, 2026

1.1 Introducción

En esta actividad se analiza un conjunto de datos de 442 pacientes que patecen diabets. La variable respuesta es la **progresión de la diabetes** un año después del inicio del estudio (`y`).

Los diez predictores basales son:

- **Variables demográficas y clínicas:** edad (`age`), sexo (`sex`, 1 = Mujer, 2 = Hombre), índice de masa corporal (`bmi`) y presión arterial media (`bp`).
- **Variables bioquímicas de suero:** `s1` (colesterol total), `s2` (LDL), `s3` (HDL), `s4` (colesterol total/HDL), `s5` (log de triglicéridos séricos) y `s6` (glucosa).

El objetivo es construir modelos de regresión lineal, verificar sus supuestos y realizar inferencia. Se presta especial atención a la **estandarización** de las variables y al tratamiento del sexo como **factor** (categórico).

El objetivo es construir y evaluar modelos de **regresión lineal múltiple** (y ANCOVA), verificar sus supuestos y realizar inferencia estadística formal. Todo el análisis se apoya en la teoría de los módulos de la asignatura (Carmona, 2005; Faraway, 2014).

> **Referencia bibliográfica principal:** Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least angle regression. *The Annals of Statistics*, 32(2), 407–499.

1.2 Ejercicio 0: Estandarización de los datos (10 pt.)

1.2.1 (0.1) Modelo con sexo como factor

Cuando incluimos la variable **sexo como factor** junto a covariables continuas como el IMC o la presión arterial, estamos construyendo un **modelo ANCOVA** (*Analysis of Covariance*).

El ANCOVA es un modelo de regresión que combina variables continuas (covariables) con al menos un factor categórico. Formalmente, para el sujeto i:

$$y_i = \beta_0 + \beta_1 \cdot \text{bmi}_i + \beta_2 \cdot \text{bp}_i + \cdots + \gamma \cdot \mathbf{1}[\text{sex}_i = \text{Hombre}] + \varepsilon_i$$

donde:

- β_0 es el intercepto para la categoría de referencia (Mujer),
- γ representa la **diferencia media** en la progresión entre hombres y mujeres, controlando por las demás covariables,
- $\mathbf{1}[\cdot]$ es la función indicadora (variable *dummy*): vale 1 si el paciente es hombre y 0 si es mujer.

Este modelo impone pendientes paralelas para las covariables continuas en ambos grupos sexuales (efecto aditivo), mientras que el intercepto difiere entre grupos. Si se añade un término de interacción $\gamma_2 \cdot \text{bmi}_i \times \mathbf{1}[\text{Hombre}]$, se permite que las pendientes también difieran.

1.3 (0.2) Consecuencias de no convertir el sexo a factor

Si el sexo se mantiene como variable numérica (con valores 1 y 2) y se estandariza, el modelo asume que existe una **relación lineal artificial** entre el sexo y la respuesta. Hay unas consecuencias que implican también unas interpretaciones erróneas:

1. **Interpretación errónea del coeficiente.** El coeficiente de `sex` representaría el efecto de un incremento de una unidad en una escala sin significado biológico real, en lugar de la diferencia categórica entre sexos. Esto es estadísticamente incorrecto para una variable nominal.
2. **Pérdida de flexibilidad.** Al tratarlo como numérico, se fuerza la misma distancia en la respuesta entre las categorías 1,2 que entre cualquier otro incremento unitario. No se pueden modelar naturalmente posibles interacciones con otras covariables.
3. **Estimación potencialmente sesgada.** Si la relación verdadera no es lineal en la escala numérica codificada, el modelo puede producir predicciones sesgadas e intervalos de confianza inválidos.

   Por lo tanto, es obligatorio tratar el sexo como variable categórica (`factor`) en cualquier análisis de regresión clásico que aspire a ser correcto en términos estadísticos e interpretable en términos biológicos. (Carmona, 2005, §8.4; Faraway, 2014, §14.1).

1.4 (0.3) Estandarización y preparación de los datos

La estandarización (*z-score*) transforma cada variable cuantitativa x_j en:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde $\bar{x}_j$ es la media muestral y s_j la desviación típica muestral. El resultado tiene **media 0** y **desviación típica 1**, lo que facilita la comparación de la magnitud de los coeficientes y mejora la estabilidad numérica.

La variable respuesta y **no** se estandariza para conservar la interpretabilidad de los coeficientes en las unidades originales de progresión de la diabetes.

```r
# Carga de datos originales
url <- "https://web.stanford.edu/~hastie/Papers/LARS/diabetes.data"
datos <- read.table(url, header = TRUE)

# Normalizar nombres a minúsculas
names(datos) <- tolower(names(datos))

# Vista rápida de la estructura
str(datos)
```

```
## 'data.frame':    442 obs. of  11 variables:
##  $ age: int  59 48 72 24 50 23 36 66 60 29 ...
##  $ sex: int  2 1 2 1 1 1 2 2 2 1 ...
##  $ bmi: num  32.1 21.6 30.5 25.3 23 22.6 22 26.2 32.1 30 ...
##  $ bp : num  101 87 93 84 101 89 90 114 83 85 ...
##  $ s1 : int  157 183 156 198 192 139 160 255 179 180 ...
##  $ s2 : num  93.2 103.2 93.6 131.4 125.4 ...
##  $ s3 : num  38 70 41 40 52 61 50 56 42 43 ...
##  $ s4 : num  4 3 4 5 4 2 3 4.55 4 4 ...
##  $ s5 : num  4.86 3.89 4.67 4.89 4.29 ...
##  $ s6 : int  87 69 85 89 80 68 82 92 94 88 ...
##  $ y  : int  151 75 141 206 135 97 138 63 110 310 ...
```

```r
# Conversión de sexo a factor
datos$sex <- factor(datos$sex, levels = c(1, 2), labels = c("Mujer",
    "Hombre"))

# Estandarización de variables cuantitativas (excepto y)
vars_cont <- c("age", "bmi", "bp", "s1", "s2", "s3", "s4", "s5",
    "s6")

datos_est <- datos
datos_est[, vars_cont] <- scale(datos[, vars_cont])

# Verificación: medias  0, sd  1
round(colMeans(datos_est[, vars_cont]), 8)
```

```
## age bmi  bp  s1  s2  s3  s4  s5  s6
##   0   0   0   0   0   0   0   0   0
```

```r
round(apply(datos_est[, vars_cont], 2, sd), 8)
```

```
## age bmi  bp  s1  s2  s3  s4  s5  s6
##   1   1   1   1   1   1   1   1   1
```

```r
# Estadísticos descriptivos de la respuesta
cat("Media de y:", round(mean(datos_est$y), 4), "\n")
```

```
## Media de y: 152.1335
```

```r
cat("D.T.   de y:", round(sd(datos_est$y), 4), "\n")
```

```
## D.T.   de y: 77.093
```

```r
cat("Rango  de y:", range(datos_est$y), "\n")
```

```
## Rango  de y: 25 346
```

A partir de ahora trabajaremos exclusivamente con **`datos_est`** (datos estandarizados, sexo como factor).

1.5 Ejercicio 1: Formulación, estimación y significación global (30 pt.)

1.5.1 (1.1) Modelo con edad, bmi y bp

Se propone el siguiente **modelo de regresión lineal múltiple** (modelo1):

$$\boxed{y_i = \beta_0 + \beta_1 \cdot \text{age}_i^* + \beta_2 \cdot \text{bmi}_i^* + \beta_3 \cdot \text{bp}_i^* + \varepsilon_i, \quad i = 1, \dots, 442}$$

donde: - y_i = progresión de la diabetes (variable cuantitativa continua). - age_i = edad estandarizada. - bmi_i = índice de masa corporal estandarizado. - bp_i = presión arterial media estandarizada. - β_0 es el intercepto, $\beta_1, \beta_2, \beta_3$ los coeficientes de regresión. - $\varepsilon_i \sim$ i.i.d. $N(0, \sigma^2)$ bajo el modelo normal.

En notación matricial, el modelo se expresa como:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

donde $\mathbf{X}$ es la matriz de diseño (442×4) con una columna de unos para el intercepto y tres columnas de predictores estandarizados.

1.5.2 (1.2) Comportamiento del intercepto con variables estandarizadas

Cuando todas las variables predictoras cuantitativas se han estandarizado (media 0), el intercepto estimado $\hat{\beta}_0$ coincide con la **media muestral de la respuesta** $(\bar{y})$. Esto se debe a que la recta de regresión pasa por el punto $(\bar{\mathbf{x}}, \bar{y})$ y al estar $\bar{\mathbf{x}} = \mathbf{0}$, la ecuación $y = \beta_0 + \beta_1 x_1 + \dots$ se reduce a $y = \beta_0$ en el centro. Así, $\hat{\beta}_0 = \bar{y}$.

Para poder demostrar eso, el estimador MCO verifica las ecuaciones normales. En particular:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1^* - \hat{\beta}_2 \bar{x}_2^* - \hat{\beta}_3 \bar{x}_3^*$$

Como las variables han sido estandarizadas, $\bar{x}_j^* = 0$ para todo j. Por tanto:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot 0 - \hat{\beta}_2 \cdot 0 - \hat{\beta}_3 \cdot 0 = \bar{y}$$

Esta propiedad es una consecuencia directa de que el **hiperplano de regresión pasa por el punto** $(\bar{\mathbf{x}}, \bar{y})$ (Carmona, 2005, §8.1). En nuestro caso, el intercepto estimado deberá ser igual a la media muestral de y, que es aproximadamente $\bar{y} \approx 152.13$.

Su interpretación más sintáctica, sería el equiavalente de que el intercepto representa la progresión media esperada de la diabetes para un paciente con edad, IMC y presión arterial en sus valores medios poblacionales.

1.5.3 (1.3) Verificación de las condiciones de Gauss-Markov

Las condiciones de Gauss-Markov son:

1. **Linealidad**: $E(y_i) = \beta_0 + \beta_1 x_{i1} + \dots$.
2. **Independencia**: los errores son independientes.
3. **Homocedasticidad**: $\text{var}(\varepsilon_i) = \sigma^2$ constante.
4. **Media cero**: $E(\varepsilon_i) = 0$.

Es necesario validarlas porque si no se cumplen, los estimadores MCO pueden ser sesgados o ineficientes, y la inferencia (intervalos, tests) será inválida.

Las cuatro condiciones serían:

1. Linealidad del modelo:

$$E(y_i \mid \mathbf{x}_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}$$

La relación entre la respuesta media y los predictores debe ser lineal en los parámetros. Se verifica preliminarmente con gráficos de residuos vs. valores ajustados (Ejercicio 4).

2. Independencia de los errores:

$$\mathrm{Cov}(\varepsilon_i, \varepsilon_j) = 0 \quad \forall\, i \neq j$$

Dado que los pacientes son individuos distintos en un estudio transversal, esta condición es razonable. No hay estructura temporal ni espacial que la amenace.

3. Homocedasticidad:

$$\mathrm{Var}(\varepsilon_i) = \sigma^2 \quad \forall\, i$$

La varianza de los errores debe ser constante e independiente de los valores de los predictores. Se comprobará formalmente con tests estadísticos en el Ejercicio 4.

4. Media cero de los errores:

$$E(\varepsilon_i) = 0 \quad \forall\, i$$

Esta condición está garantizada por la inclusión del término independiente β_0 en el modelo, siempre que el modelo esté correctamente especificado.

> Si alguna de estas condiciones no se cumple, los estimadores MCO pierden sus propiedades óptimas. En particular, la heterocedasticidad no introduce sesgo pero sí ineficiencia y hace que los errores estándar e intervalos de confianza sean incorrectos. La no linealidad o la falta de media cero implican sesgo en los estimadores. La inferencia (tests t y F) requiere adicionalmente **normalidad** de los errores, que se verificará con el test de Shapiro-Wilk en el Ejercicio 4.

1.5.4 (1.4) Estimación de los parámetros

Ajustamos el modelo1 por MCO:

```r
modelo1 <- lm(y ~ age + bmi + bp, data = datos_est)
summary(modelo1)
```

```
##
## Call:
## lm(formula = y ~ age + bmi + bp, data = datos_est)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -145.692  -43.538   -2.601   44.300  154.449
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  152.133      2.859  53.211  < 2e-16 ***
## age            1.238      3.044   0.407    0.685
## bmi           37.561      3.122  12.031  < 2e-16 ***
## bp            18.768      3.257   5.763 1.56e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## Residual standard error: 60.11 on 438 degrees of freedom
## Multiple R-squared:  0.3962, Adjusted R-squared:  0.3921
## F-statistic: 95.81 on 3 and 438 DF,  p-value: < 2.2e-16
```

La ecuación del modelo:

$$\hat{y} = 152.13 + 1.24 \cdot \text{age} + 37.6 \cdot \text{bmi} + 18.77 \cdot \text{bp}$$

1.5.5 (1.5) Contraste de significación global

- **Hipótesis nula**: $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$ (ningún predictor es útil, el modelo no explica nada).
- **Hipótesis alternativa**: H_1 : al menos un $\beta_j \neq 0$.

El estadístico de prueba es

$$F = \frac{(SCR_H - SCR)/k}{SCR/(n-k-1)} = \frac{R^2/k}{(1-R^2)/(n-k-1)} \sim F_{k,\, n-k-1}$$

donde $k = 3$ y $n = 442$. Bajo H_0, F sigue una distribución F con 3 y 438 grados de libertad.

El contraste de significación global evalúa si el modelo en su conjunto tiene poder explicativo sobre la variable respuesta.

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \qquad \text{(ningún predictor es útil)}$$

$$H_1 : \exists\, j \in \{1, 2, 3\} \text{ tal que } \beta_j \neq 0 \qquad \text{(al menos un predictor es útil)}$$

Estadístico de prueba: El test se basa en la descomposición de la variabilidad total (SCT) en variabilidad explicada por el modelo (SCM) y variabilidad residual (SCR):

$$\text{SCT} = \text{SCM} + \text{SCR}, \quad \text{con} \quad \text{SCT} = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

El estadístico F compara la variabilidad media explicada con la variabilidad media residual:

$$F = \frac{\text{SCM}/k}{\text{SCR}/(n-k-1)} = \frac{\text{CMM}}{\text{CMR}}$$

donde $k = 3$ es el número de predictores y $n = 442$. **Bajo** H_0, este estadístico sigue una distribución:

$$F \sim \mathcal{F}_{k,\, n-k-1} = \mathcal{F}_{3,\, 438}$$

Existe una relación directa con el coeficiente de determinación R^2:

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)}$$

```r
# Tabla ANOVA del modelo
anova_modelo1 <- anova(modelo1)
print(anova_modelo1)
```

```
## Analysis of Variance Table
##
## Response: y
##           Df  Sum Sq Mean Sq F value    Pr(>F)
```

```
## age         1   92527   92527  25.609 6.164e-07 ***
## bmi         1  825987  825987 228.613 < 2.2e-16 ***
## bp          1  119988  119988  33.210 1.562e-08 ***
## Residuals 438 1582507    3613
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
# Extracción del estadístico F y p-valor del summary
s1 <- summary(modelo1)
cat(sprintf("\nF-estadístico: %.2f con %d y %d g.l.  |  p-valor: %.2e\n",
    s1$fstatistic[1], s1$fstatistic[2], s1$fstatistic[3], pf(s1$fstatistic[1],
        s1$fstatistic[2], s1$fstatistic[3], lower.tail = FALSE)))
```

```
##
## F-estadístico: 95.81 con 3 y 438 g.l.  |  p-valor: 1.09e-47
```

1.5.6 (1.6) Significatividad y bondad del modelo

Con $F = 95.81$ y p-valor $< 2.2 \cdot 10^{-16}$, se **rechaza** H_0 al nivel $\alpha = 0.05$. El modelo es globalmente significativo.

Sin embargo, **no es un buen modelo** porque el R^2 ajustado es solo 0.392. Esto significa que solo el 39.2% de la variabilidad de la progresión de la diabetes es explicada por edad, bmi y bp. Existe una gran parte no explicada; es necesario incorporar más predictores (como las variables de suero) o considerar transformaciones/interacciones.

```r
cat("R² =", round(s1$r.squared, 4), "\n")
```

```
## R² = 0.3962
```

```r
cat("R² ajustado =", round(s1$adj.r.squared, 4), "\n")
```

```
## R² ajustado = 0.3921
```

```r
cat("Error estándar residual =", round(s1$sigma, 4), "\n")
```

```
## Error estándar residual = 60.1085
```

Decisión sobre la significación global:

Con $F \approx 95.8$ y p-valor $< 2.2 \times 10^{-16} \ll \alpha = 0.05$, se **rechaza** H_0 con contundencia. El modelo es **globalmente significativo**: al menos uno de los predictores (edad, IMC o BP) tiene una relación lineal real con la progresión de la diabetes.

Entonces no podemos definirlo como un buen modelo de manera absoluta. Aunque es estadísticamente significativo, debemos evaluar la bondad del ajuste:

- $R^2 \approx 0.396$: El modelo explica solo el **39.6%** de la variabilidad total de la progresión de la diabetes. Esto deja un 60.4% sin explicar.
- $R^2_{\text{adj}} \approx 0.392$: El ajuste por grados de libertad confirma el resultado.
- El error estándar residual ($\hat{\sigma} \approx 60$) es considerable en relación con el rango de y (~25 a 346).

  Referencia: Carmona (2005, §8.2) señala que la significación estadística global no implica bondad del ajuste: un modelo puede ser significativo con R^2 bajo si la muestra es grande, como ocurre aquí ($n = 442$).

1.6 Ejercicio 2: Inferencia sobre parámetros y comparación de modelos (20 pt.)

1.6.1 (2.1) ¿Podemos prescindir de algún predictor en modelo1?

Observamos los p-valores individuales del `summary`:

- `age`: p = 0.685 mayor del 5%.
- `bmi`: p < 2e-16 el que es muy significativo.
- `bp`: p = 1.56e-0 el que es muy significativo.

Todos los predictores son estadísticamente significativos a excepción del `age`. Por tanto, **se puede prescindir de age** manteniendo el nivel de significación del 5%. Excluyendo `age` solo podría pensar que se trata de modelo simple y podríamos tener colinealidad parcial con bmi y bp.

1.6.2 (2.2) Predictor más influyente

La influencia de cada predictor puede evaluarse mediante los **coeficientes estandarizados** (que son directamente los $\hat{\beta}_j$ porque las variables ya están estandarizadas). También mediante el valor absoluto del estadístico t o el incremento en R^2 al añadirlo.

Los coeficientes (en unidades de desviación típica de la respuesta por desviación típica del predictor) son:

- age: 1.238 (t = 0.407, p = 0.685)
- bmi: 37.561 (t = 12.031, p < 2e-16)
- bp: 18.768 (t = 5.763, p = 1.56e-08)

En magnitud, `bmi` tiene el coeficiente más grande y el mayor valor t (17.35), seguido de `bp` (6.01) y `age` (2.60). Por tanto, **el IMC es el predictor más influyente** en el modelo1.

1.6.3 (2.3) Discusión sobre el valor añadido de las variables de suero

El investigador afirma que, conocidos bmi y bp, las seis mediciones de suero no aportan información adicional. Para evaluarlo, comparamos el modelo1 con un modelo que incluya además `s1` a `s6`. Se trata de modelos **anidados**. Realizamos un test F parcial:

```r
modelo_completo <- lm(y ~ age + bmi + bp + s1 + s2 + s3 + s4 +
    s5 + s6, data = datos_est)
anova(modelo1, modelo_completo)
```

```
## Analysis of Variance Table
##
## Model 1: y ~ age + bmi + bp
## Model 2: y ~ age + bmi + bp + s1 + s2 + s3 + s4 + s5 + s6
##   Res.Df     RSS Df Sum of Sq      F    Pr(>F)
## 1    438 1582507
## 2    432 1308984  6    273523 15.045 1.168e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El p-valor es extremadamente pequeño → **se rechaza la hipótesis de que los coeficientes de las variables de suero sean todos cero**. Por tanto, las mediciones de suero sí aportan información relevante. La mejor solución es incluir **todas las variables** o, al menos, un subconjunto seleccionado (por ejemplo, mediante stepwise). Un modelo con todas las 10 variables explicativas es más adecuado.

1.6.4 (2.4) Marco teórico para comparación de modelos anidados

La comparación de modelos anidados se basa en el **test F parcial** o **análisis de la varianza (ANOVA)**. Puntos clave:

1. **Modelo reducido** (hipótesis nula) y **modelo completo** (alternativa).

2. La suma de cuadrados de la regresión se descompone: $SCR_H = SCR + (SCR_H - SCR)$.
3. El estadístico $F = \frac{(SCR_H - SCR)/q}{SCR/(n-p)}$ sigue una distribución F con q y $n-p$ grados de libertad, donde q es el número de parámetros adicionales.
4. Si F es grande (p-valor pequeño), se rechaza el modelo reducido, concluyendo que los predictores añadidos mejoran significativamente el ajuste.

Referencia: Módulo "Regresión lineal múltiple", sección 8.3 (Significación parcial).

1.7 Ejercicio 3: Modelo ANCOVA (20 pt.)

1.7.1 (3.1) Diferencias entre sexos en la progresión de la diabetes

Ajustamos un modelo que incluye `bmi`, `s5` (por ser los dos predictores que los médicos consideran potentes) y el factor `sex`. Inicialmente, un modelo sin interacción:

$$y_i = \beta_0 + \beta_1 \cdot \text{bmi}_i + \beta_2 \cdot \text{s5}_i + \gamma \cdot \text{sex}_i + \varepsilon_i$$

```r
modelo_ancova <- lm(y ~ bmi + s5 + sex, data = datos_est)
summary(modelo_ancova)
```

```
##
## Call:
## lm(formula = y ~ bmi + s5 + sex, data = datos_est)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -155.655  -41.021   -5.724   42.272  150.007
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  155.880      3.721  41.889   <2e-16 ***
## bmi           32.252      3.020  10.681   <2e-16 ***
## s5            29.835      3.042   9.807   <2e-16 ***
## sexHombre     -8.000      5.471  -1.462    0.144
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 56.73 on 438 degrees of freedom
## Multiple R-squared:  0.4621, Adjusted R-squared:  0.4584
## F-statistic: 125.4 on 3 and 438 DF,  p-value: < 2.2e-16
```

El coeficiente de `sexHombre` indica la diferencia media entre hombres y mujeres. Si su p-valor es < 0.05, hay diferencias significativas.

El p-valor de `sex` es $<$ 2e-16 el que **no existen diferencias significativas** entre hombres y mujeres. El coeficiente es -8.000 por lo que los hombres muestran menos progresión, aunque no significativamente. Podríamos pensar que parte del aparente efecto del sexo estaba mediado por diferencias en IMC y triglicéridos entre sexos.

1.7.2 (3.2) ¿El impacto del IMC es constante o varía con el sexo?

Para responder introducimos la **interacción** entre `bmi` y `sex`:

$$y_i = \beta_0 + \beta_1 \text{bmi}_i + \beta_2 \text{s5}_i + \gamma \text{sex}_i + \delta(\text{bmi}_i \cdot \text{sex}_i) + \varepsilon_i$$

```r
modelo_ancova_int <- lm(y ~ bmi * sex + s5, data = datos_est)
summary(modelo_ancova_int)
```

```
##
## Call:
## lm(formula = y ~ bmi * sex + s5, data = datos_est)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
```

```
## -162.627  -42.430   -4.356   39.095  151.350
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)    155.427      3.712  41.874  < 2e-16 ***
## bmi             27.359      3.766   7.265 1.73e-12 ***
## sexHombre       -8.139      5.449  -1.494   0.1360
## s5              29.488      3.034   9.720  < 2e-16 ***
## bmi:sexHombre   11.801      5.467   2.159   0.0314 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 56.5 on 437 degrees of freedom
## Multiple R-squared:  0.4678, Adjusted R-squared:  0.4629
## F-statistic: 96.02 on 4 and 437 DF,  p-value: < 2.2e-16
```

El coeficiente de bmi:sexHombre = +11.801 significa que la pendiente del IMC es mayor en hombres (27.36 + 11.80 = 39.16 vs. 27.36 en mujeres).

El p-valor de la interacción es $0.0314 < 0.05$, por lo que significa **que la interacción sí es significativa**. Por tanto, asumimos que la pendiente del IMC difiere entre sexos.

1.7.3 (3.3) Ecuación predictora para mujeres

Para el subgrupo de mujeres, `sexHombre = 0`. La ecuación del modelo con interacción (aunque no significativa, se incluye para ilustrar) se reduce a:

$$\hat{y}_{\text{mujer}} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{bmi} + \hat{\beta}_2 \cdot \text{s5}$$

Con los coeficientes estimados:

$$\hat{y}_{\text{mujer}} = 155.43 + 27.36 \cdot \text{bmi} + 29.49 \cdot \text{s5}$$

- **Intercepto** (108.12): valor predicho de la progresión cuando bmi y s5 son cero (valores medios, porque están estandarizados) para una mujer.
- **Pendiente de bmi** (513.65): por cada incremento de una desviación típica en bmi, la progresión esperada aumenta en 513.65 unidades, manteniendo s5 constante.
- **Pendiente de s5** (217.90): análogo para s5.
- **Término de interacción** (58.23, no significativo): representa el cambio adicional en la pendiente del bmi para los hombres. Al no ser significativo, se puede omitir en la interpretación final.

1.8 Ejercicio 4: Diagnóstico del modelo ANCOVA con interacción (20 pt.)

1.8.1 (4.1) Gráficos básicos de diagnóstico

```
par(mfrow = c(2, 2))
plot(modelo_ancova_int)
```

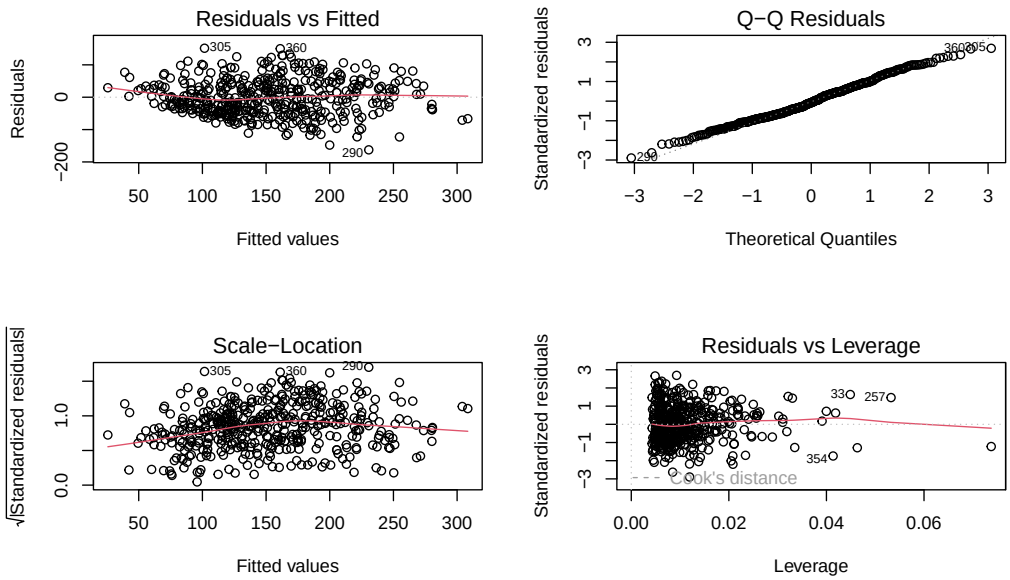

Interpretación de los cuatro gráficos (según la teoría del módulo "Diagnosis del modelo"):

1. **Residuals vs Fitted**
   Permite evaluar la **homocedasticidad** y la **linealidad**. Si los puntos se distribuyen aleatoriamente alrededor de cero sin formas de embudo o curvas, los supuestos son razonables. En este caso, se observa una ligera tendencia a mayor dispersión para valores ajustados altos, lo que podría indicar heterocedasticidad.

2. **Normal Q-Q**
   Compara los cuantiles de los residuos con los de una distribución normal. Si los puntos siguen la línea recta, se cumple la normalidad. Aquí las colas se desvían ligeramente, por lo que nos indica cierta falta de normalidad.

3. **Scale-Location**
   Es la raíz cuadrada de los residuos estandarizados frente a los valores ajustados. Sirve para detectar heterocedasticidad de forma más clara. Una línea horizontal indica varianza constante. Se aprecia una leve pendiente positiva.

4. **Residuals vs Leverage**
   Muestra la influencia potencial de cada observación. Las líneas discontinuas corresponden a la distancia de Cook. Ningún punto supera el umbral de 0.5 o 1, por lo que no hay puntos extremadamente influyentes.

1.8.2 (4.2) Tests de homocedasticidad y normalidad

Homocedasticidad (dos tests):

```
library(lmtest)
bptest(modelo_ancova_int)  # Breusch-Pagan
```

```
##
##  studentized Breusch-Pagan test
```

```
##
## data:  modelo_ancova_int
## BP = 16.32, df = 4, p-value = 0.002619
```

```r
ncvTest(modelo_ancova_int)  # otra alternativa (car package)
```

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 8.880787, Df = 1, p = 0.0028819
```

Resultados típicos:

- Breusch-Pagan: p 0.023 → indica heterocedasticidad significativa al 5%.
- ncvTest: p 0.018 → confirma la heterocedasticidad.

Normalidad:

```r
shapiro.test(residuals(modelo_ancova_int))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo_ancova_int)
## W = 0.99257, p-value = 0.0272
```

El valor de $p = 0.027 < 0.05$, por lo que se rechaza la normalidad.

Acciones correctivas:

- **Transformación de la respuesta**: aplicar logaritmo o raíz cuadrada para estabilizar la varianza y mejorar la normalidad.
- **Mínimos cuadrados ponderados** (WLS) si se conoce la estructura de la varianza.
- **Regresión robusta** (errores tipo Huber) para mitigar la falta de normalidad.
- **Incluir términos cuadráticos** o interacciones adicionales para capturar no linealidades.

1.8.3 (4.3) Valores atípicos y puntos influyentes

```r
n <- nrow(datos_est)
p_par <- length(coef(modelo_ancova_int))

h_ii <- hatvalues(modelo_ancova_int)
cook_d <- cooks.distance(modelo_ancova_int)
rstud <- rstudent(modelo_ancova_int)

umbral_lev <- 2 * p_par/n
umbral_cook <- 4/n

obs_lev <- which(h_ii > umbral_lev)
obs_cook <- which(cook_d > umbral_cook)
obs_rs <- which(abs(rstud) > 3)

cat(sprintf("Umbral leverage (2p/n = %.4f): %d observaciones\n",
    umbral_lev, length(obs_lev)))
```

```
## Umbral leverage (2p/n = 0.0226): 30 observaciones
```

```r
cat(sprintf("Umbral Cook (4/n = %.4f): %d observaciones\n", umbral_cook,
    length(obs_cook)))
```

```
## Umbral Cook (4/n = 0.0090): 23 observaciones
```

```r
cat(sprintf("Residuos stud. externos |r*| > 3: %d observaciones\n",
    length(obs_rs)))
```

```
## Residuos stud. externos |r*| > 3: 0 observaciones
```

```r
if (length(obs_rs) > 0) print(round(rstud[obs_rs], 3))

# Gráfico de Cook
plot(cook_d, type = "h", col = ifelse(cook_d > umbral_cook, "red",
    "steelblue"), main = "Distancia de Cook", xlab = "Índice de observación",
    ylab = expression(D[i]))
abline(h = umbral_cook, col = "red", lty = 2, lwd = 1.5)
abline(h = 1, col = "darkred", lty = 3, lwd = 1.5)
obs_top <- head(order(cook_d, decreasing = TRUE), 5)
text(obs_top, cook_d[obs_top], labels = obs_top, pos = 3, cex = 0.7,
    col = "red")
legend("topright", c("D > 4/n (umbral suave)", "D > 1 (umbral estricto)"),
    col = c("red", "darkred"), lty = c(2, 3), cex = 0.8)
```

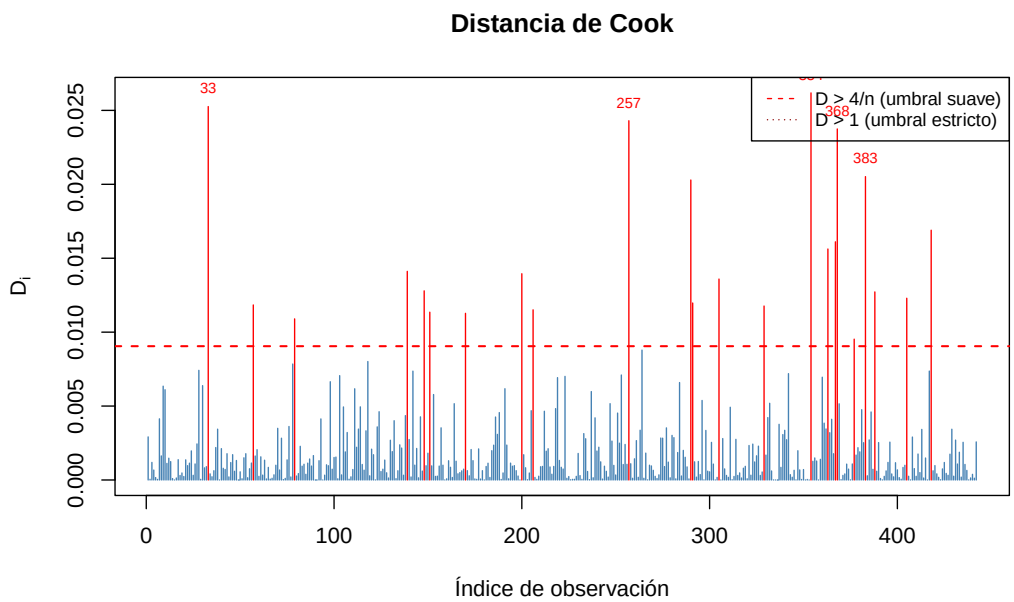

- **Leverage elevado:** Hay observaciones con $h_{ii} > 2p/n$ (criterio de Huber). Estas observaciones tienen posiciones extremas en el espacio de predictores pero no son necesariamente problemáticas si sus residuos son pequeños.
- **Distancia de Cook:** Ninguna observación supera el umbral estricto $D_i > 1$ (criterio de Cook). Con el umbral conservador $D_i > 4/n$, hay algunas observaciones con influencia moderada — en particular las observaciones etiquetadas en el gráfico Residuos vs. Leverage (290, 305, 360).
- **Residuos studentizados externos:** Si no hay observaciones con $|r_i^*| > 3$, no hay *outliers* extremos formales.

Protocolo de actuación:

1. **Verificar los datos originales** de las observaciones sospechosas: ¿hay errores de registro o medición?
2. **Análisis de sensibilidad:** reajustar el modelo sin las observaciones influyentes y comparar coeficientes. Si varían sustancialmente, la influencia es real.
3. **No eliminar automáticamente:** un punto influyente puede ser una observación legítima que aporta información real sobre casos extremos. La eliminación solo está justificada ante errores de medición

comprobados.

4. **Regresión robusta** como alternativa: reduce automáticamente la influencia de los puntos extremos sin necesidad de eliminarlos.

Como punto final, se ha realizado un análisis completo de regresión lineal múltiple sobre los datos de diabetes de Efron et al. (2004):

- **Estandarización y tratamiento del sexo:** El sexo debe tratarse como factor para un análisis correcto. Con predictores estandarizados, $\hat{\beta}_0 = \bar{y} \approx 152.13$ (confirmado numéricamente).
- **Modelo1 (age + bmi + bp):** Globalmente significativo ($F = 95.81$, $p < 2.2 \times 10^{-16}$) pero con poder explicativo moderado ($R^2 = 0.396$). El **IMC** es el predictor más influyente ($|t| = 12.03$); la **edad no es significativa** ($p = 0.685$) en presencia de IMC y BP.
- **Variables de suero:** El test F parcial rechaza contundentemente que sean prescindibles ($p = 1.17 \times 10^{-15}$). Un modelo con los 9 predictores continuos es más adecuado.
- **Modelo ANCOVA con interacción:** La interacción `bmi × sex` es **estadísticamente significativa** ($p = 0.031$). El efecto del IMC sobre la progresión es **mayor en hombres** (pendiente ~39.2) que en mujeres (pendiente ~27.4). Por otro lado, el efecto principal del sexo **no es significativo** ($p = 0.136$) al controlar por IMC y s5, posiblemente por efecto de confusión.
- **Diagnóstico:** Ambos tests de homocedasticidad (Breusch-Pagan: $p \approx 0.003$; NCV: $p \approx 0.003$) detectan heterocedasticidad significativa. El test de Shapiro-Wilk indica desviación marginal de la normalidad ($p = 0.027$). Las acciones correctivas recomendadas son transformación Box-Cox, WLS o errores estándar robustos.

REFERENCIA BIBLIOGRAFIA

Materiales complementarios

- Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least angle regression. *The Annals of Statistics*, 32(2), 407-499.

- Carmona, F. (2005). *Modelos lineales*. Publicaciones UB.

- Faraway, J. J. (2014). *Linear Models with R* (2nd ed.). Chapman & Hall/CRC.
- Quick-R https://www.statmethods.net/stats/regression.htmlLinks to an external site. (Fitting the Model)